


# ΑΛΓΟΡΙΘΜΟΙ ΑΝΑΛΥΣΗΣ ΙΑΤΡΙΚΗΣ ΕΙΚΟΝΑΣ

## Τόμος Α: Προγραμματισμός Εφαρμογών

$$f_{corr1} = \frac{\left[ \sum_{i=1}^{Ng} \sum_{j=1}^{Ng} (ij)p(i,j) \right] - \mu_x \mu_y}{\sigma_x \sigma_y}$$

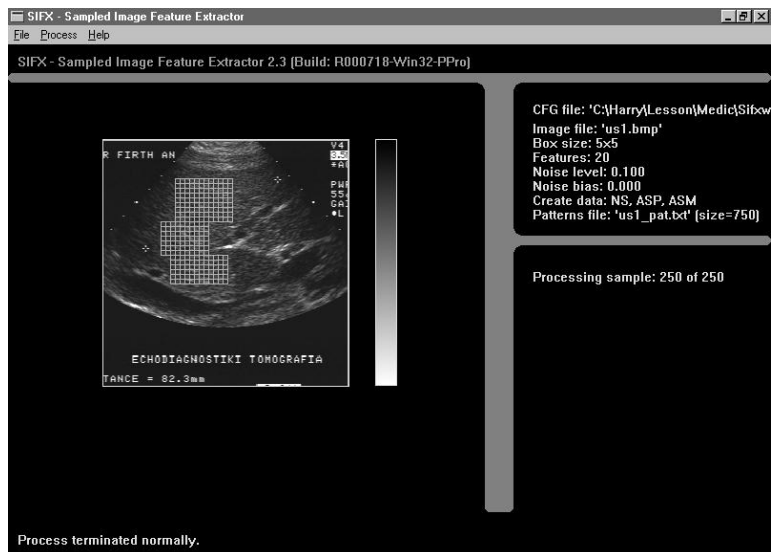



Χάρης Β. Γεωργίου

# ΑΛΓΟΡΙΘΜΟΙ ΑΝΑΛΥΣΗΣ ΙΑΤΡΙΚΗΣ ΕΙΚΟΝΑΣ

## Τόμος Α: Προγραμματισμός Εφαρμογών

$$f_{corr1} = \frac{\left[ \sum_{i=1}^{Ng} \sum_{j=1}^{Ng} (ij)p(i,j) \right] - \mu_x \mu_y}{\sigma_x \sigma_y}$$



Χάρης Β. Γεωργίου

Copyright (c) 2012, Harris V. Georgiou

# **ΑΛΓΟΡΙΘΜΟΙ ΑΝΑΛΥΣΗΣ ΙΑΤΡΙΚΗΣ ΕΙΚΟΝΑΣ**

**Τόμος Α: Προγραμματισμός Εφαρμογών**

Χάρης Β. Γεωργίου (MSc, PhD)

<http://xgeorgio.info>

Copyright (c) 2012, Harris V. Georgiou

## Περιεχόμενα

Ευχαριστίες

**Πρόλογος** 11

**Μέρος-1: Θεωρητικό Υπόβαθρο** 15

1.1 Ιατρική Υπερηχογραφική Εικόνα 15

1.2 Τοποθέτηση Προβλήματος 15

1.3 Ανάλυση Εικόνας 17

1.4 Στατιστική Αναγνώριση Προτύπων 19

1.5 Θεωρητικές Μέθοδοι Απόφασης 21

1.5.1 Ταξινομητές Ελάχιστης Απόστασης (MDC) 21

1.5.2 Τεχνητά Νευρωνικά Δίκτυα (ANN) 28

1.5.2.1 Ο αλγόριθμος Back-Propagation 31

1.5.2.2 Προβλήματα και βελτιώσεις του αλγορίθμου Back-Propagation 37

1.5.2.3 Τεχνικές σχεδίασης νευρωνικών δικτύων 39

1.6 Μεθοδολογία 43

1.6.1 Δημιουργία Χαρακτηριστικών (Feature Generation) 44

1.6.2 Επιλογή Χαρακτηριστικών (Feature Reduction) 49

1.6.3 Ομαδοποίηση Χαρακτηριστικών (Feature Selection) 51

**Μέρος-2: Περιγραφή Λογισμικού** 55

2.1 Ταξινομητές – Υλοποίηση 55

2.1.1 Ταξινομητής Ελάχιστης Απόστασης (MDC) 56

2.1.2 Ταξινομητής Νευρωνικού Δικτύου (NNC) 60

2.2 Τεκμηρίωση Λογισμικού 63

2.2.1 SIFX: Sample Image Feature Extractor 63

2.2.1.1	Εισαγωγή	63
2.2.1.2	Λειτουργία	63
2.2.1.3	Έκδοση κονσόλας	63
2.2.1.4	Έκδοση γραφικού περιβάλλοντος	64
2.2.1.5	Αρχιτεκτονική και δομή	65
2.2.2	FCD: Feature Classifier Design	67
2.2.2.1	Εισαγωγή	67
2.2.2.2	Λειτουργία	67
2.2.2.3	Έκδοση κονσόλας	67
2.2.2.4	Έκδοση γραφικού περιβάλλοντος	68
2.2.2.5	Αρχιτεκτονική και δομή	69
2.2.3	BPM: Neural Network Classifier Design	70
2.2.3.1	Εισαγωγή	70
2.2.3.2	Λειτουργία	71
2.2.3.3	Έκδοση κονσόλας	71
2.2.3.4	Έκδοση γραφικού περιβάλλοντος	72
2.2.3.5	Αρχιτεκτονική και δομή	73
2.2.4	MLP: Neural Network Executor	75
2.2.4.1	Εισαγωγή	75
2.2.4.2	Λειτουργία	75
2.2.5	SHUFFLE: Patterns Set Randomizer	76
2.2.5.1	Εισαγωγή	76
2.2.5.2	Λειτουργία	76
<b>Μέρος-3: Παρουσίαση &amp; Σχολιασμός Αποτελεσμάτων</b>		79
3.1	Παρουσίαση & Αξιολόγηση Αποτελεσμάτων	79
3.1.1	Διατύπωση Στόχων	79

3.1.2 Μεθοδολογία, Οργάνωση & Εξαγωγή Αποτελεσμάτων	80
3.1.3 Πληροφορίες Διαμόρφωσης & Παραμέτρων Εκπαίδευσης	81
3.1.4 Αναλυτικά Αποτελέσματα	84
3.1.4.1 Φάση Α – Αποτελέσματα	84
3.1.4.2 Φάση Β – Αποτελέσματα	84
3.1.4.3 Φάση Γ – Αποτελέσματα	85
3.1.4.4 Φάση Δ – Αποτελέσματα	87
3.2 Αξιολόγηση Απόδοσης Ταξινομητών	90
3.2.1 Αξιολόγηση MDC	90
3.2.2 Αξιολόγηση NNC	90
3.3 Σχολιασμός Αποτελεσμάτων	95
3.4 Συμπεράσματα	97
<b>Παράρτημα-Α: Τεκμηρίωση Λογισμικού</b>	99
Α. Προγραμματιστικές Βιβλιοθήκες Συναρτήσεων	99
Α.1 SIFX: Sample Image Feature Extractor	99
Α.1.1 Εισαγωγή	99
Α.1.2 Ανάλυση Κώδικα	99
Α.1.3 Τεχνικές Πληροφορίες	107
Α.2 FCD: Feature Classifier Design	107
Α.2.1 Εισαγωγή	107
Α.2.2 Ανάλυση Κώδικα	108
Α.2.3 Τεχνικές Πληροφορίες	116
Α.3 BPM: Neural Network Classifier Design	116
Α.3.1 Εισαγωγή	116
Α.3.2 Ανάλυση Κώδικα	117
Α.3.3 Τεχνικές Πληροφορίες	125



A.4 MLP: Neural Network Executor	126
A.4.1 Εισαγωγή	126
A.4.2 Ανάλυση Κώδικα	126
A.4.3 Τεχνικές Πληροφορίες	126
A.5 SHUFFLE: Patterns Set Randomizer	127
A.5.1 Εισαγωγή	127
A.5.2 Ανάλυση Κώδικα	127
A.5.3 Τεχνικές Πληροφορίες	127
<b>Βιβλιογραφία – Αναφορές</b>	129

## **Ευχαριστίες**

Ευχαριστώ θερμά συνεργάτες και φίλους που με τις παρατηρήσεις και τις προτάσεις τους συνέβαλαν στο ποιοτικό επίπεδο του υλικού στο σύνολό του. Επίσης ευχαριστώ τους φοιτητές μου που κατά καιρούς είχαν την ευκαιρία να διαβάσουν και να εφαρμόσουν όσα περιγράφονται εδώ. Τέλος, ευχαριστώ την οικογένειά μου για την ανεκτίμητη υποστήριξη και συμπαράστασή τους με κάθε τρόπο.

Copyright (c) 2012, Harris V. Georgiou

## Πρόλογος

Η δραματική τεχνολογική εξέλιξη των ηλεκτρονικών υπολογιστών στις τελευταίες δύο δεκαετίες, η εφαρμογή αυτοματοποιημένων μεθόδων επεξεργασίας μεγάλου όγκου δεδομένων με πολύ υψηλή ταχύτητα οδηγεί αναπόφευκτα στην ολοένα εντεινόμενη προσπάθεια για εκμετάλλευση του πολύτιμου αυτού νέου εργαλείου σε διάφορους τομείς της έρευνας και των πρακτικών εφαρμογών.

Ο τομέας της Ιατρικής χαρακτηρίζεται από μεγάλη εξειδίκευση ως προς το πεδίο της θεωρητικής και πρακτικής εμπειρίας κάθε ειδικευμένου επιστήμονα, ως συνέπεια της πολυπλοκότητας και της ποικιλομορφίας των διαφόρων πεδίων έρευνας. Η σημερινή εμπειρία σε οποιοδήποτε ιατρικό πεδίο δύσκολα μετασχηματίζεται σε ποσοτική πληροφορία αξιοποιήσιμη από συστήματα ηλεκτρονικών υπολογιστών. Ωστόσο, η θεωρητική έρευνα στο πεδίο της επεξεργασίας σήματος και ανάπτυξης “έξυπνων” προσαρμοστικών συστημάτων, καθώς και η εκθετική αύξηση των δυνατοτήτων των υπολογιστικών συστημάτων σε επίπεδο υλικού, επιτρέπουν την διερεύνηση και υλοποίηση νέων μεθόδων προς αυτή την κατεύθυνση.

Η ανάλυση ιατρικής εικόνας συνίσταται στην επεξεργασία της πληροφορίας που περιέχεται στην ψηφιοποιημένη εικόνα, όπως ακτινογραφικές, υπερηχογραφικές, κτλ. Η επεξεργασία βασίζεται στην εξαγωγή της χρήσιμης πληροφορίας, την αποδοτική αναπαράσταση και την εκμετάλλευση των χαρακτηριστικών της για την διεξαγωγή ανώτερων διεργασιών, όπως ο χαρακτηρισμός δείγματος ιστού και αυτόματη διάγνωση. Η υλοποίηση παρόμοιων αυτοματοποιημένων μεθόδων απαιτεί την μετατροπή της ποιοτικής-υποκειμενικής πληροφορίας που χρησιμοποιεί ο ειδικευμένος επιστήμονας σε ποσοτική-αντικειμενική πληροφορία που είναι δυνατό να χρησιμοποιηθεί από ηλεκτρονικό υπολογιστή. Ο μετασχηματισμός αυτός συνίσταται ουσιαστικά από τον καθορισμό κατάλληλων μεθόδων για την ανάδειξη εκείνων των χαρακτηριστικών των πηγαιών δεδομένων που αναδεικνύουν ακριβώς τις ιδιότητες που διέπουν την ποιοτική πληροφορία.

Δύο είναι οι βασικές κατευθύνσεις έρευνας για την ανάπτυξη αυτόματων συστημάτων ανάλυσης ιατρικής εικόνας. Το πρώτο αφορά στη διατύπωση αποτελεσματικών μετασχηματισμών των δεδομένων για την ανάδειξη χρήσιμης πληροφορίας που χαρακτηρίζει την εκάστοτε περίπτωση παθολογείας, ενώ το δεύτερο αφορά στην ανάπτυξη κατάλληλης μεθοδολογίας, δομών και τεχνικών για την βέλτιστη εκμετάλλευσή τους με σκοπό τη σχεδίαση αυτόματων συστημάτων ανάλυσής τους. Η έρευνα αναφορικά με την πρώτη κατεύθυνση

έχει αναδείξει χρήσιμες μεθοδολογίες που αποδεικνύονται ιδιαίτερα αποτελεσματικές σε πολλούς τομείς της ανάλυσης ιατρικής εικόνας. Στο πεδίο της υπερηχογραφικής εικόνας τα χαρακτηριστικά της υφής (texture) φαίνεται να αποτελούν ουσιαστικό στοιχείο στην απόφαση σχετικά με το χαρακτηρισμό δειγμάτων ιστού και τη διάγνωση παθολογίας. Επιπλέον, στην κατεύθυνση της ανάπτυξης αποδοτικών μεθοδολογιών για την εκμετάλλευση αυτής της πληροφορίας, τα τελευταία χρόνια έχει σημειωθεί τεράστια εξέλιξη σε προηγμένες τεχνικές επεξεργασίας σήματος. Σε συνδυασμό με την επαρκή πλέον υπολογιστική ισχύ που είναι διαθέσιμη σε ευρεία κλίμακα σήμερα, η κατασκευή πρακτικά αξιοποιήσιμων σύνθετων συστημάτων είναι πλέον εφαρμόσιμη ακόμα και σε επίπεδο κλινικών εφαρμογών.

Λόγω της σχετικά πρόσφατης πείρας στο συγκεκριμένο πεδίο της πρακτικής εφαρμογής διαφόρων μεθοδολογιών στην αυτόματη ανάλυση ιατρικής εικόνας (περίπου δύο δεκαετίες), είναι απαραίτητη η διεξοδική διερεύνηση όλων των προοπτικών και εντοπισμό αυτών που εμφανίζουν τη μεγαλύτερη δυναμική ανάπτυξης. Η περιοχή των μη γραμμικών συστημάτων και ιδιαίτερα ο τομέας των νευρωνικών δικτύων αποτελεί σήμερα έναν από τους πιο πολλά υποσχόμενους τομείς έρευνας στην Αναγνώριση Προτύπων (Pattern Recognition). Η μέχρι τώρα εφαρμογή τους σε προβλήματα ανάλυσης ιατρικής εικόνας φαίνεται να δίνει πολύ καλύτερα αποτελέσματα από όλες σχεδόν τις υπόλοιπες μεθοδολογίες που έχουν εφαρμοστεί μέχρι σήμερα.

Η παρούσα εργασία (τόμος Α) αποτελεί το πρώτο μέρος ενός δίτομου έργου που αφορά σε όλα τα στάδια επεξεργασίας σε ένα σύστημα υποβοηθούμενης (Computer Aided Diagnosis – CAD) ή πλήρως αυτοματοποιημένης διάγνωσης (Automated Computer Diagnosis – ACD), εστιασμένο κυρίως στην ανάπτυξη αντίστοιχου λογισμικού εφαρμογών, καλύπτοντας παράλληλα όλες τις απαραίτητες θεωρητικές έννοιες και αλγορίθμους Ανάλυσης Ιατρικής Εικόνας (Image Analysis & Medical Imaging) και Αναγνώρισης Προτύπων (Pattern Recognition). Το υλικό του βιβλίου είναι πλήρως αυτόνομο και επικεντρώνεται στην ανάλυση υπερηχογραφικής εικόνας ανθρώπινου ήπατος με σκοπό τον αυτόματο χαρακτηρισμό δειγμάτων ιστού, χρησιμοποιώντας μεθοδολογίες που βασίζονται στο ευρύτερο πεδίο της Αναγνώρισης Προτύπων. Στόχοι της έρευνας είναι να διερευνήσει την χρησιμότητα των χαρακτηριστικών υφής (texture statistics) ως βασική πληροφορία εισόδου, καθώς επίσης και η αξιολόγηση υλοποιήσεων ταξινομητών προτύπων (pattern classifiers) σε πρακτικό επίπεδο. Τα αποτελέσματα και τα συμπεράσματα της μελέτης αποτελούν εν δυνάμει τη βάση περαιτέρω έρευνας και πειραματισμών.

Τα περιεχόμενα του βιβλίου είναι οργανωμένο σε τρεις ανεξάρτητες ενότητες που αναφέρονται σε διαφορετικά τμήματα του συνόλου της παρούσης εργασίας. Το υλικό που παρουσιάζεται μπορεί να χρησιμοποιηθεί τμηματικά ή στο σύνολο

του, τόσο ως εισαγωγή στη σχεδίαση ταξινομητών σε προβλήματα ανάλυσης ιατρικής εικόνας, όσο και ως εγχειρίδιο αναφοράς για τον κώδικα του λογισμικού των εφαρμογών.

Το πρώτο μέρος αναφέρεται στο απαραίτητο θεωρητικό υπόβαθρο και την τοποθέτηση του προβλήματος. Γίνεται παρουσίαση του υλικού και των μεθόδων ανάλυσης ιατρικής εικόνας, συνοπτική θεώρηση των μεθόδων και των τεχνικών αναγνώρισης προτύπων, καθώς επίσης και περιγραφή της συστηματικής μεθοδολογίας σχεδίασης γραμμικών και μη γραμμικών στατιστικών ταξινομητών.

Το δεύτερο μέρος περιλαμβάνει όλες τις λεπτομέρειες υλοποίησης και πρακτικής εφαρμογής του λογισμικού που αναπτύχθηκε στα πλαίσια της παρούσας μελέτης. Η υλοποίηση πραγματικών γραμμικών ταξινομητών (ελάχιστης απόστασης – MDC) και μη γραμμικών ταξινομητών (νευρωνικού δικτύου – NNC) με τη χρήση των συνοδευτικών προγραμμάτων περιγράφεται εκτενώς σε επίπεδο τελικού χρήστη (end-user guide).

Το τρίτο μέρος αποτελεί ουσιαστικά την συνοπτική περιγραφή της διαδικασίας σχεδίασης και αξιολόγησης γραμμικών και μη γραμμικών ταξινομητών για το συγκεκριμένο πρόβλημα, εφαρμόζοντας διαφορετικές διαμορφώσεις και σύνολα εκπαίδευσης. Γίνεται αναλυτική παρουσίαση των αρχικών στόχων και τα σημεία όπου επικεντρώθηκε η τελική φάση της μελέτης, ενώ παράλληλα γίνεται αναφορά σε λεπτομέρειες οργάνωσης και εκτέλεσης των διαφορετικών φάσεων αξιολόγησης. Τέλος γίνεται παρουσίαση των τελικών αποτελεσμάτων και των συμπερασμάτων με την ολοκλήρωση της μελέτης.

Το βιβλίο συμπληρώνεται με μια εκτενής αναφορά στον υλοποιημένο κώδικα των προγραμμάτων που αποτελούν το συνοδευτικό λογισμικό της εργασίας. Αν και το πακέτο του λογισμικού είναι οργανωμένο ως ένα σύνολο αυτόνομων εφαρμογών, η αναλυτική περιγραφή της δομής και της λειτουργίας κάθε υπορουτίνας στις 12.000 και πλέον γραμμές του πηγαίου κώδικα αποτελεί ουσιαστικά το εγχειρίδιο χρήσης τους ως έτοιμες προγραμματιστικές βιβλιοθήκες συναρτήσεων για την υλοποίηση παρόμοιων εφαρμογών.

Μέρος του υλικού που παρουσιάζεται στο βιβλίο βασίζεται σε παλαιότερη μεταπτυχιακή εργασία μου (2000) με θέμα "Αλγόριθμοι Ανάλυσης Ιατρικής Εικόνας", η οποία εκπονήθηκε στο Τμήμα Πληροφορικής και Τηλεπικοινωνιών του Εθνικού Καποδιστριακού Πανεπιστημίου Αθηνών (ΕΚΠΑ). Έκτοτε χρησιμοποιήθηκε από εμένα ως υλικό διδασκαλίας σε προπτυχιακό και μεταπτυχιακό επίπεδο, τόσο σε ότι αφορά αλγορίθμους Μηχανικής Μάθησης και Ανάλυσης Εικόνας, όσο και προγραμματισμού (C/C++) αλγορίθμων Αναγνώρισης Προτύπων.

Σήμερα, μια δεκαετία και πλέον μετά, το υλικό εξακολουθεί να είναι χρήσιμο σε φοιτητές και επαγγελματίες του χώρου. Το βιβλίο αυτό αποτελεί μια προσπάθεια πιο οργανωμένης και συστηματικής διάθεσης αυτού του υλικού προς κάθε ενδιαφερόμενο, με την ελπίδα ότι θα εξακολουθεί να είναι χρήσιμο για τουλάχιστον δέκα χρόνια ακόμα.

Χάρης Β. Γεωργίου (MSc, PhD)

Αθήνα, Οκτώβριος 2012

## **Μέρος – 1**

### **Θεωρητικό Υπόβαθρο**

#### **1.1 Ιατρική Υπερηχογραφική Εικόνα**


Τα πρωτογενή δεδομένα που χρησιμοποιούνται από το σύστημα είναι ψηφιοποιημένες υπερηχογραφικές εικόνες. Τα δεδομένα εξόδου από έναν τυπικό υπερηχογράφο B χρησιμοποιούνται για την καταγραφή και αποθήκευση εικόνων B-scan ανθρώπινου ήπατος. Τυπικά χαρακτηριστικά της υπερηχογραφικής συσκευής αποτελούν η συχνότητα (2.5 MHz), η διάμετρος (19 mm), καθώς και οι διατάξεις ενίσχυσης και καταγραφής του σήματος. Πολλές σύγχρονες συσκευές περιλαμβάνουν διατάξεις ψηφιοποίησης του αναλογικού σήματος σε ψηφιακό με ανάλυση που ξεπερνά τα 8-bit, η τελική όμως μορφή της ψηφιοποιημένης εικόνας είναι συνήθως σε μορφή μονόχρωμου raster, με βάθος απόχρωσης κλίμακας γκρι 8-bit, δηλαδή 256 διαβαθμίσεις [05]. Έχει διαπιστωθεί πως ψηφιοποίηση της εικόνας της υπερηχογραφικής συσκευής με ανάλυση κόκκου 100μm και βάθος απόχρωσης 12-bit (4096 επίπεδα) κλίμακας γκρι είναι αρκετά για την ανάλυση εικόνας σε οποιαδήποτε ιατρική εφαρμογή, ενώ οι πραγματικές απαιτήσεις κυμαίνονται σε ανάλυση κόκκου το πολύ 300μm και 8-bit (256 επίπεδα) κλίμακα γκρι [02]. Το πραγματικό μέγεθος της εκάστοτε υπό εξέταση περιοχής είναι περίπου 80 mm και το μέγεθος της παραγόμενης ψηφιοποιημένης (στατικής) εικόνας είναι περίπου 66 Kbytes με διαστάσεις 256x256 pixels.

#### **1.2 Τοποθέτηση Προβλήματος**

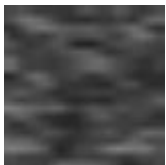
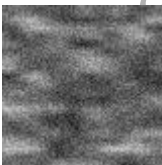
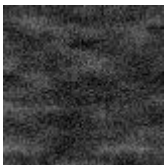
Υπερηχογραφικές εικόνες τύπου B-scan αποτελούν ένα χρήσιμο και ευρύτατα διαδεδομένο διαγνωστικό εργαλείο για ασθένειες του ήπατος. Το βασικό πρόβλημα συνίσταται σε πρώτο επίπεδο στην διάκριση των προς χαρακτηρισμό δειγμάτων σε φυσιολογικό ή παθολογικό ιστό, ενώ σε επόμενα στάδια μπορεί να γίνει περαιτέρω διαχωρισμός σε επιμέρους υποκατηγορίες, κυρίως σε ότι αφορά τους διάφορους τύπους παθογένειας.

Παρά την χρησιμότητά τους, οι υπερηχογραφικές εικόνες χαρακτηρίζονται εν γένει από υψηλή εξάρτηση των δεδομένων από τον χειριστή της υπερηχογραφικής συσκευής, γεγονός που οδηγεί αναπόφευκτα στην υψηλή διαφοροποίηση των εξαγόμενων αποτελεσμάτων, κάτι που είναι ήδη γνωστό στη διεθνή βιβλιογραφία [01].





Υπερηχογραφική εικόνα ήπατος

 <p><b>Δείγμα</b> <b>φυσιολογικού</b> <b>ιστού</b></p>	 <p><b>Δείγμα με</b> <b>λιπώδη διήθηση</b></p>	 <p><b>Δείγμα με</b> <b>κίρρωση</b></p>
---	---	---

**Σχήμα 1.1:** Δείγματα εικόνας, υγιούς και παθολογικών ιστών

Σε μια προσπάθεια εύρεσης ποσοτικών μεθοδολογιών για την διάγνωση μέσω υπερηχογραφίας, έχει αποδειχθεί πειραματικά ότι η εφαρμογή τεχνικών στατιστικής αναγνώρισης προτύπων δίνει τα καλύτερα αποτελέσματα σε σχέση με άλλες μεθόδους, σε υπερηχογραφικές εικόνες τύπου A-scan ή B-scan. Επιπλέον, υπερηχογραφικές εικόνες τύπου B-scan είναι διαθέσιμες σε ευρεία κλίμακα και η πρόσβαση σε αυτές εξασφαλίζεται σε μορφή κινούμενης εικόνας (video) ή σε μορφή συμβατή με το πρωτόκολλο DICOM, σύμφωνα με τις διεθνείς προδιαγραφές κατασκευής και λειτουργίας των σύγχρονων υπερηχογραφικών συσκευών. Η ποσοτικοποίηση πληροφοριών της ψηφιοποιημένης εικόνας σε στατιστικά χαρακτηριστικά μπορεί να περιλαμβάνει τεχνικές που επικεντρώνονται σε πολλά διαφορετικά στοιχεία, όπως είναι η υφή, η δομή ή το φάσμα της υπό μελέτη περιοχής της εικόνας.

Κύριες επιδιώξεις οποιασδήποτε αυτοματοποιημένης μεθοδολογίας αποτελούν η εξασφάλιση της ελεγχιμότητας των αποτελεσμάτων, καθώς επίσης η επίτευξη ικανοποιητικής απόδοσης, συγκρίσιμης με την αντίστοιχη απόδοση εξειδικευμένου ανθρώπινου δυναμικού. Η παρούσα εργασία έχει ως στόχο να αναδείξει μεθοδολογίες που επιτυγχάνουν αυτές τις απαιτήσεις, παρουσιάζοντας τεχνικές για την αυτόματη επιλογή χαρακτηριστικών με τη βέλτιστη διαχωριστική ικανότητα και κατόπιν τη χρήση τους στην κατασκευή αποδοτικών ταξινομητών για την αυτόματη κατηγοριοποίηση δειγμάτων.

### 1.3 Ανάλυση Εικόνας

Ανάλυση εικόνας ονομάζεται η διαδικασία ανακάλυψης, αναγνώρισης και κατανόησης προτύπων, τα οποία σχετίζονται με την απόδοση μιας διεργασίας που βασίζεται σε επεξεργασία πληροφορίας από εικόνα. Ένας από τους βασικούς στόχους της ανάλυσης εικόνας με υπολογιστή είναι να γίνει εφικτή σε μια μηχανή η προσέγγιση ως ένα βαθμό της αντίστοιχης ανθρώπινης ικανότητας στο συγκεκριμένο πεδίο μελέτης. Στην περίπτωση ανάλυσης ιατρικής εικόνας το αντικείμενο μελέτης είναι η ιατρική πληροφορία και ο βασικός στόχος είναι η απόδοση του υπολογιστή να προσεγγίζει την αντίστοιχη απόδοση ανθρώπων ειδικευμένων για τη συγκεκριμένη εργασία.

Ένα σύστημα αυτοματοποιημένης ανάλυσης εικόνας θα πρέπει να παρουσιάζει διάφορους βαθμούς ευφυΐας. Ο όρος ευφυΐα είναι εν γένει αφηρημένος ως έννοια και ειδικότερα όταν ορίζεται ως χαρακτηριστικό μιας μηχανής όπως ο ηλεκτρονικός υπολογιστής. Παρόλα αυτά, είναι σχετικά εύκολο να οριστεί κάποιο σύνολο χαρακτηριστικών, στα οποία επικεντρώνεται η προσοχή όταν πρόκειται για την αυτοματοποίηση μιας συγκεκριμένης διεργασίας όπως η ανάλυση εικόνας. Τα χαρακτηριστικά αυτά περιλαμβάνουν: (α) την ικανότητα εξαγωγής της χρήσιμης πληροφορίας από το σύνολο των αρχικών δεδομένων, (β) την ικανότητα εκμάθησης της συγκεκριμένης διεργασίας με βάση ένα πεπερασμένο σύνολο παραδειγμάτων και τη δυνατότητα γενίκευσης της αποκτηθείσας γνώσης ώστε να είναι εφαρμόσιμη σε ευρύτερο πεδίο, και (γ) την ικανότητα εξαγωγής συμπερασμάτων με βάση ελλιπή ή ασαφή πληροφορία [20].

Συστήματα αυτόματης ανάλυσης εικόνας με τα παραπάνω χαρακτηριστικά είναι δυνατό να κατασκευαστούν με βάση τα σημερινά τεχνολογικά δεδομένα, με μεγάλη όμως εξειδίκευση ως προς την ευρύτητα του πεδίου εφαρμογής τους. Επιπλέον, η απόδοσή τους εξαρτάται σε μεγάλο βαθμό από την καταλληλότητα και τους περιορισμούς ή υποθέσεις των μεθόδων τις οποίες εφαρμόζουν, κάτι που προκαλεί σε πολλές περιπτώσεις εσφαλμένα αποτελέσματα. Καθώς η ανθρώπινη αντίληψη και εξειδίκευση σε κάποιο συγκεκριμένο τομέα, όπως η ανάλυση ιατρικής εικόνας, δεν περιορίζεται αποκλειστικά σε ένα σύνολο καλώς καθορισμένων παραμέτρων που να μπορούν να μοντελοποιηθούν και να οργανωθούν με σαφήνεια σε ένα μοναδικό θεωρητικό μοντέλο, υλοποιήσιμο σε μορφή λογισμικού υπολογιστή, είναι φυσικό η απόδοση των αυτοματοποιημένων αυτών μεθόδων μονάχα να προσεγγίζει την ανθρώπινη απόδοση. Η έρευνα στο πεδίο της γνωστικής λειτουργίας της ανθρώπινης όρασης, καθώς και η εφαρμογή νέων θεωριών στην υλοποίηση μεθόδων επεξεργασίας πληροφορίας

με υπολογιστή, έχουν οδηγήσει σήμερα στο συμπέρασμα ότι οι πιο αποδοτικές τεχνικές είναι αυτές που χρησιμοποιούν ευρετικούς αλγορίθμους, κατάλληλα προσαρμοσμένους για το εκάστοτε πρόβλημα. Τέτοια συστήματα μπορεί να παρουσιάζουν πολλές φορές απόδοση συγκρίσιμη ή ακόμα και καλύτερη από την ανθρώπινη, όμως το βασικό τους μειονέκτημα είναι ότι χαρακτηρίζονται από υψηλό βαθμό εξειδίκευσης και η επέκταση της εφαρμογής τους σε άλλες παρόμοιες περιπτώσεις είναι προβληματική.

Για την καλύτερη μελέτη και κατανόηση των συστατικών που συνθέτουν ένα σύστημα ανάλυσης εικόνας, πολλές φορές οι βασικές του λειτουργίες διαχωρίζονται σε τρεις κατηγορίες σύμφωνα με το είδος και το επίπεδο επεξεργασίας που εφαρμόζει κάθε τεχνική. Οι τρεις κατηγορίες είναι: (α) επεξεργασία χαμηλού επιπέδου, (β) επεξεργασία μεσαίου επιπέδου, και (γ) επεξεργασία υψηλού επιπέδου. Αν και ο χαρακτήρας των κατηγοριών δεν καθορίζει σαφή όρια μεταξύ τους, παρόλα αυτά η διαχωρισμός αυτός είναι ιδιαίτερα χρήσιμος για την οργάνωση και τη δόμηση ενός αυτόνομου συστήματος ανάλυσης εικόνας [20].

Η επεξεργασία χαμηλού επιπέδου περιλαμβάνει λειτουργίες προεπεξεργασίας που πολλές φορές θεωρούνται αυτονόητες πριν την κυρίως επεξεργασία στο σύστημα. Οι λειτουργίες αυτές δεν απαιτούν κάποιο ιδιαίτερο επίπεδο ευφυίας από την πλευρά του συστήματος, καθώς είναι γενικά απλές και εκτελούν κάποιας μορφής επεξεργασία στα δεδομένα σε χαμηλό επίπεδο. Λειτουργίες όπως η καταγραφή και ανάγνωση των δεδομένων εισόδου, η κανονικοποίηση αριθμητικών συνόλων, η καταφλίσωση σε δεδομένα εικόνας, καθώς και η αφαίρεση θορύβου ή οποιασδήποτε μορφής άχρηστης για το σύστημα πληροφορίας, μπορούν να θεωρηθούν διεργασίες οι οποίες εκτελούν επεξεργασία χαμηλού επιπέδου.

Η επεξεργασία μεσαίου επιπέδου σχετίζεται με διεργασίες που έχουν σαν στόχο την εξαγωγή και χαρακτηρισμό συστατικών στοιχείων από τα δεδομένα εξόδου των διεργασιών χαμηλού επιπέδου. Πριν την εφαρμογή τεχνικών ανάλυσης σε ανώτερα του συστήματος είναι απαραίτητη η αξιολόγηση και αξιοποίηση της προεπεξεργασμένης πληροφορίας, με σκοπό την κατασκευή των συνιστωσών που αποτελούν την πληροφορία ανώτερου επιπέδου. Η αναγνώριση ορίων αντικειμένων και ο χαρακτηρισμός των ίδιων των αντικειμένων αποτελούν διεργασίες επεξεργασίας αυτού του επιπέδου.

Τέλος, η επεξεργασία υψηλού επιπέδου περιλαμβάνει την αναγνώριση και την ερμηνεία των αντικειμένων που καθορίστηκαν στο προηγούμενο επίπεδο. Οι διεργασίες αυτές σχετίζονται με την έννοια της ευφυούς γνωστικής λειτουργίας. Η πλειοψηφία των μεθόδων που εφαρμόζονται σε χαμηλό ή μεσαίο επίπεδο επεξεργασίας χαρακτηρίζονται από σχετικά καλώς καθορισμένο θεωρητικό και πρακτικό υπόβαθρο. Αντίθετα, για τις λειτουργίες της αναγνώρισης και πολύ περισσότερο της ερμηνείας η παρούσα γνώση και τεχνολογία δεν είναι αρκετή για τη διατύπωση σαφούς θεωρητικού υποβάθρου που να καθορίζει τις αρχές που τις διέπουν. Έτσι η διατύπωση και υλοποίηση μεθοδολογιών στο πεδίο αυτό είναι αναγκαστικά περισσότερο υποθετικός και εικαστικός, παρά ακριβής και θεωρητικά αποδεδειγμένος. Η σχετική έλλειψη γνώσης στο συγκεκριμένο πεδίο τελικά έχει ως αποτέλεσμα την υιοθέτηση περιορισμών και υποθέσεων που έχουν σαν ουσιαστικό στόχο τον περιορισμό της πολυπλοκότητας του

συγκεκριμένου προβλήματος σε εφικτά επίπεδα. Το τελικό αποτέλεσμα είναι η κατασκευή ενός συστήματος που παρουσιάζει μεγάλη εξειδίκευση ως προς τις λειτουργικές του δυνατότητες.

Η παρούσα εργασία ασχολείται με την υλοποίηση συστήματος αυτόματης ανάλυσης εικόνας, με τεχνικές αναγνώρισης που χαρακτηρίζονται ως βασισμένες σε θεωρητικές μεθόδους απόφασης (decision-theoretic methods). Οι θεωρητικές μέθοδοι απόφασης βασίζονται στην αναπαράσταση προτύπων με τη μορφή διανυσμάτων χαρακτηριστικών παραμέτρων, και στη συνέχεια αναζήτηση κατάλληλων προσεγγίσεων για την ομαδοποίηση και ανάθεση των διανυσμάτων σε διαφορετικές κατηγορίες προτύπων. Βασικές τεχνικές αυτής μεθοδολογίας αποτελούν οι ταξινομητές ελάχιστης απόστασης και τα νευρωνικά δίκτυα, οι οποίες είναι και οι κύριες συνιστώσες στην παρούσα εργασία σε σχέση με τη σχεδίαση βέλτιστων ταξινομητών για την αυτόματη ανάλυση ιατρικής εικόνας.

#### 1.4 Στατιστική Αναγνώριση Προτύπων

Όπως αναφέρθηκε παραπάνω, η δυνατότητα εκτέλεσης λειτουργιών αναγνώρισης προτύπων σε κάποιο βαθμό είναι ζωτικής σημασίας για την κατασκευή συστημάτων αυτόματης ανάλυσης εικόνας. Για το ευρύτερο πρόβλημα της ανάλυσης εικόνας μέσω υπολογιστή, πρότυπο θεωρείται η ποσοτική αναπαράσταση ορισμένων συγκεκριμένων χαρακτηριστικών στις υπό μελέτη περιοχές της εκάστοτε εικόνας. Γενικότερα, ένα πρότυπο έχει τη μορφή διανύσματος με μία ή περισσότερες συνιστώσες που ονομάζονται χαρακτηριστικά (features) του προτύπου. Το πλήθος και η σημασιολογία κάθε συνιστώσας εξαρτάται από το εκάστοτε πρόβλημα και από την τεχνική που χρησιμοποιείται για τον υπολογισμό του κάθε ενός με βάση τα δεδομένα της αρχικής εικόνας στην υπό μελέτη περιοχή. Πρότυπα που εμφανίζουν «επαρκώς όμοια» χαρακτηριστικά ομαδοποιούνται στην ίδια κατηγορία, σχηματίζοντας έτσι συστάδες (clusters) προτύπων που καθορίζουν αντίστοιχες κλάσεις.

Οι διάφορες τεχνικές αναγνώρισης προτύπων χρησιμοποιούνται για την στατιστική συσχέτιση και σύγκριση προτύπων με τις διαθέσιμες κλάσεις, και την ανάθεσή τους σε μία από αυτές με βάση κάποιο χαρακτηριστικό βέλτιστης ταξινόμησης. Τυπικό παράδειγμα αποτελούν οι ταξινομητές ελάχιστης απόστασης, όπου για ένα άγνωστο, δηλαδή προς ταξινόμηση, πρότυπο υπολογίζεται η μέση απόσταση ή η απόσταση από τον μέσο εκπρόσωπο κάθε κλάσης και η τελική απόφαση ανάθεσής του γίνεται επιλέγοντας την κλάση από την οποία εμφανίζει την ελάχιστη απόσταση.

Η αποτελεσματικότητα σωστής απόφασης του ταξινομητή με βάση τα διαθέσιμα χαρακτηριστικά για κάθε πρότυπο ονομάζεται αλλιώς διαχωριστική ή διακριτική ικανότητα του ταξινομητή. Η διακριτική ικανότητα του ταξινομητή εξαρτάται τόσο από τη μεθοδολογία που εφαρμόζεται για την ανάθεση προτύπων σε προκαθορισμένες κατηγορίες, όσο και από τα χαρακτηριστικά που χρησιμοποιούνται για το διαχωρισμό των ίδιων των κατηγοριών μεταξύ τους. Το πρώτο στοιχείο αποτελεί εν γένει χαρακτηριστικό του ταξινομητή και καθορίζει τον τύπο του ταξινομητή, αν για παράδειγμα πρόκειται για ταξινομητή ελάχιστης απόστασης (γραμμικός), για νευρωνικό δίκτυο (μη γραμμικός), κτλ. Το δεύτερο στοιχείο αποτελεί ένα από τα στάδια μελέτης στη σχεδίαση του εκάστοτε

ταξινομητή, ανεξάρτητα από την δομή που χρησιμοποιείται στο εσωτερικό του, και είναι γνωστό ως πρόβλημα επιλογής χαρακτηριστικών παραμέτρων (feature selection) [03, 20].

Το πλήθος των χαρακτηριστικών παραμέτρων, που στην ουσία είναι το πλήθος των ενεργών συνιστωσών στο διάνυσμα των προτύπων, καθορίζει τη διάσταση  $D$  του ταξινομητή. Διανύσματα προτύπων μεγέθους 1 οδηγούν σε διαχωρισμό των σημείων μιας ευθείας σε επιμέρους τμήματα, κάθε ένα από τα οποία αντιστοιχεί σε μία κλάση. Παρόμοια, διανύσματα μεγέθους 2 παράγουν διαχωρισμό του επίπεδου χώρου σε επιμέρους περιοχές κλάσεων, και διανύσματα μεγέθους 3 παράγουν διαχωρισμό του τρισδιάστατου χώρου σε επιμέρους περιοχές. Αν και η απεικόνιση είναι δύσκολη για περισσότερες από 3 διαστάσεις, ταξινομητές με διάσταση  $N$  διαχωρίζουν τον υπερχώρο διάστασης  $N$  σε υποχώρους της ίδιας διάστασης, με βάση υπερεπίπεδα που καθορίζουν τα όρια μεταξύ των κλάσεων.

Αξίζει να σημειωθεί πως η χρήση ταξινομητών ολοένα μεγαλύτερης διάστασης, δηλαδή όλο και περισσότερων συνιστωσών στα διανύσματα των προτύπων, δεν οδηγεί εν γένει σε βελτίωση της απόδοσης του ταξινομητή. Πέρα από το πρόβλημα της αύξησης της πολυπλοκότητας, η διακριτική ικανότητα του ταξινομητή εξαρτάται, όπως αναφέρθηκε και προηγούμενα, από τη διαχωριστική ικανότητα που προσφέρουν τα επιμέρους χαρακτηριστικά των προτύπων, ανεξάρτητα από την εσωτερική δομή του ταξινομητή. Λίγα χαρακτηριστικά υψηλής διαχωριστικής ικανότητας είναι δυνατό να προσφέρουν στον ταξινομητή καλύτερη απόδοση σε σχέση με πολλά χαρακτηριστικά μέτριας διαχωριστικής ικανότητας, σε σχέση τόσο με την πολυπλοκότητα σε χώρο και χρόνο υπολογισμού, όσο και ως προς το ποσοστό επιτυχίας. Επιπλέον η επιλογή συγκεκριμένων χαρακτηριστικών παραμέτρων από όλες τις διαθέσιμες εξαρτάται άμεσα από το εκάστοτε πρόβλημα και τη μορφή των δεδομένων εισόδου [20]. Η ελάττωση των χαρακτηριστικών παραμέτρων είναι επιθυμητή ακόμα και με σχετικά μικρό κόστος όσο αφορά στο τελικό ποσοστό επιτυχίας, αφού πολλές φορές αυτός είναι ο μοναδικός τρόπος σχεδίασης ενός πρακτικά υλοποιήσιμου συστήματος. Το συγκεκριμένο ζήτημα αναφέρεται και ως πρόβλημα ελάττωσης των χαρακτηριστικών παραμέτρων (feature reduction) και είναι ζωτικής σημασίας για την κατασκευή πρακτικά χρήσιμων ταξινομητών σε πραγματικά προβλήματα [03].

Εφόσον τα χαρακτηριστικά που εμφανίζουν αρκετά καλή διαχωριστική ικανότητα είναι πλέον διαθέσιμα, επόμενο και τελικό στάδιο στην σχεδίαση του ταξινομητή αποτελεί η διαδικασία «εκπαίδευσης» της δομής που υλοποιεί τη διαδικασία ανάθεσης κλάσης σε πρότυπα που εισάγονται προς ταξινόμηση. Η ακριβής υλοποίηση της διαδικασίας εξαρτάται άμεσα από τη δομή που χρησιμοποιείται, αλλά σε κάθε περίπτωση με την ολοκλήρωση αυτού του σταδίου ο ταξινομητής έχει πλέον την τελική μορφή και διαμόρφωση, και είναι έτοιμος για χρήση. Μεθοδολογίες εκπαίδευσης γραμμικών και μη γραμμικών ταξινομητών, άμεσες και επαναληπτικές αντίστοιχα, θα εξεταστούν σε επόμενη ενότητα.

Στην παρούσα εργασία μελετώνται στατιστικά χαρακτηριστικά που βασίζονται σε ποσοτικοποίηση πληροφοριών υψής και περιγράφονται αναλυτικά στην αντίστοιχη ενότητα.

### 1.5 Θεωρητικές Μέθοδοι Απόφασης

Τα είδη των ταξινομητών που θα αναλυθούν στη συνέχεια ανήκουν στην κατηγορία των μεθόδων θεωρητικής απόφασης. Ανεξάρτητα από την εσωτερική δομή και τη λειτουργία τους, ταξινομητές αυτού του τύπου χρησιμοποιούν συναρτήσεις διάκρισης ή απόφασης (discriminant/decision functions) για τον καθορισμό των ορίων μεταξύ των κλάσεων. Όπως έχει ήδη αναφερθεί, σύνολα προτύπων με «επαρκώς όμοια» χαρακτηριστικά ομαδοποιούνται και σχηματίζουν κλάσεις, στις οποίες ανατίθενται τα προς ταξινόμηση διανύσματα με βάση κάποια βέλτιστη μεθοδολογία. Στην περίπτωση ταξινομητών που εφαρμόζουν μεθοδολογίες θεωρητικής απόφασης, το κριτήριο βέλτιστης ταξινόμησης υλοποιείται από κοινού από τις συναρτήσεις απόφασης. Κάθε συνάρτηση απόφασης αφορά την ανάθεση ή μη ανάθεση κάποιου προτύπου σε μια συγκεκριμένη κλάση. Υπολογίζοντας τις τιμές των όλων των συναρτήσεων απόφασης για τις αντίστοιχες κλάσεις και συγκρίνοντας στη συνέχεια τις τιμές αυτές, είναι δυνατή η «βέλτιστη» επιλογή κάποιας κλάσης ως τελική απόφαση του ταξινομητή.

Συνήθως χρησιμοποιείται κάποιο κριτήριο μέγιστης ή ελάχιστης τιμής, ενώ στις περισσότερες περιπτώσεις και ειδικότερα όταν μονάχα δύο κλάσεις είναι διαθέσιμες, οι συναρτήσεις απόφασης ενοποιούνται σε μία μοναδική συνάρτηση και η απόφαση βασίζεται σε κριτήρια ελέγχου περισσότερο του πρόσημου παρά της απόλυτης τιμής της συνάρτησης. Ουσιαστικά η συνάρτηση απόφασης εκτελεί μια απεικόνιση των προτύπων εισόδου σε μία από τις διαθέσιμες κλάσεις με τρόπο βέλτιστο ως προς το τελικό ποσοστό επιτυχίας. Ανάλογα με την υλοποίηση της συνάρτησης απόφασης και τον τρόπο αναπαράστασης των υπερεπιπέδων κατακερματισμού του χώρου των προτύπων εισόδου σε υποχώρους των κατηγοριών, οι ταξινομητές χαρακτηρίζονται ως γραμμικοί ή μη γραμμικοί. Οι δύο βασικοί εκπρόσωποι κάθε είδους, οι ταξινομητές ελάχιστης απόστασης και τα νευρωνικά δίκτυα, παρουσιάζονται αναλυτικά παρακάτω.

#### 1.5.1 Ταξινομητές Ελάχιστης Απόστασης (MDC)

Οι ταξινομητές ελάχιστης απόστασης αποτελούν ένα από τα πιο διαδεδομένα είδη ταξινομητών στο ευρύτερο πεδίο της αναγνώρισης προτύπων. Ο λόγος σχετίζεται περισσότερο με την ευρεία μελέτη του αντίστοιχου θεωρητικού υπόβαθρου και κυρίως με την απλότητα σε ότι αφορά την υλοποίησή τους σε υπολογιστή.

Ξεκινώντας από ένα δεδομένο σύνολο προτύπων και της αντίστοιχης πραγματικής κατηγορίας στην οποία ανήκει το καθένα από αυτά, το ζητούμενο της διαδικασίας εκπαίδευσης είναι η κατασκευή αντίστοιχων συναρτήσεων απόφασης για την βέλτιστη ταξινόμησή τους με αυτόματο τρόπο. Ο ταξινομητής που κατασκευάζεται τελικά μπορεί να εφαρμοστεί για οποιοδήποτε σύνολο προτύπων για το συγκεκριμένο πρόβλημα. Στην περίπτωση των ταξινομητών ελάχιστης απόστασης χρησιμοποιούνται συναρτήσεις απόφασης που βασίζονται στην επιλογή της ελάχιστης τιμής απόστασης.


Στην απλούστερη περίπτωση, το πρόβλημα περιλαμβάνει ταξινόμηση των προτύπων σε δύο μόνο κλάσεις, οπότε μπορεί να χρησιμοποιηθεί μία μοναδική συνάρτηση απόφασης που καθορίζει το σύνορο μεταξύ των δύο κλάσεων. Η συνάρτηση απόφασης υλοποιείται ως ένα σχήμα υπολογισμού της απόστασης του εκάστοτε προς ταξινόμηση προτύπου από κάθε διαθέσιμη κλάση. Ο υπολογισμός της απόστασης μπορεί να γίνει ως μέση απόσταση από όλα τα πρότυπα που ανήκουν στην συγκεκριμένη κλάση, ή εναλλακτικά από τον μέσο εκπρόσωπο κάθε κλάσης. Στην πρώτη περίπτωση δεν χρειάζεται κανένα στάδιο προεπεξεργασίας των αρχικών δεδομένων κατά τη φάση εκπαίδευσης, παρουσιάζει όμως σχετικά μεγάλο κόστος ως προς το πλήθος των απαιτούμενων υπολογισμών. Στη δεύτερη περίπτωση είναι αυτή που εφαρμόζεται πρακτικά στην πλειοψηφία των περιπτώσεων και περιλαμβάνει ένα στάδιο προεπεξεργασίας των αρχικών δεδομένων κατά τη φάση της εκπαίδευσης. Κατά το στάδιο αυτό, για το σύνολο των προτύπων κάθε κλάσης υπολογίζεται ο μέσος εκπρόσωπος της κλάσης, ως το διάνυσμα με συνιστώσες τη μέση τιμή κάθε επιμέρους χαρακτηριστικού. Η μεθοδολογία αυτή απαιτεί επιπλέον χώρο αποθήκευσης του μέσου εκπροσώπου κάθε κλάσης, αλλά απλοποιεί σε μεγάλο βαθμό τη διαδικασία απόφασης.

$$\bar{Z} = E[\vec{Z}] = \overline{E[Z_{ij}]} \quad [1.1]$$

**Εξίσωση 1.1:** Μέσο διάνυσμα = μέσες τιμές συνιστωσών

Χρησιμοποιώντας ως μέτρο απόφασης την Ευκλείδεια απόσταση του εκάστοτε προτύπου από τον μέσο εκπρόσωπο κάθε κλάσης, το σύνορο διαχωρισμού που προκύπτει για την περίπτωση δύο κλάσεων είναι η μεσοκάθετος μεταξύ των μέσων εκπροσώπων. Για διαστάσεις διανυσμάτων μεγαλύτερες του 2, η μεσοκάθετος είναι στην πραγματικότητα το υπερεπίπεδο που χωρίζει το χώρο σε δύο επιμέρους υποχώρους. Στην περίπτωση δύο κλάσεων, οι συναρτήσεις απόφασης για κάθε επιμέρους κλάση μπορούν να συνδυαστούν σε μία και μοναδική συνάρτηση, όπου πλέον ο έλεγχος δεν γίνεται με βάση την ελάχιστη απόσταση από κάθε μέσο εκπρόσωπο, αλλά απλά από το πρόσημο της τιμής που δίνει η εξίσωση της μεσοκαθέτου, δηλαδή αν το εκάστοτε πρότυπο εμφανίζεται αριστερά ή δεξιά του υπερεπιπέδου που καθορίζει το σύνορο διαχωρισμού των κλάσεων στο χώρο.

Το παρακάτω σχήμα παρουσιάζει ένα απλό παράδειγμα δύο κλάσεων προτύπων διάστασης 2, όπου φαίνεται η απεικόνιση των προτύπων κάθε κλάσης στο επίπεδο, καθώς και η μεσοκάθετος που ορίζεται μεταξύ των μέσων εκπροσώπων τους.



**Σχήμα 1.2:** Παράδειγμα γραμμικού ταξινομητή ελάχιστης απόστασης διάστασης 2

$$\| Z - \bar{Z}_1 \| = \| Z - \bar{Z}_2 \| \quad [1.2]$$

$$(\bar{Z}_1 - \bar{Z}_2)Z = \frac{1}{2}(\| \bar{Z}_1 \|^2 - \| \bar{Z}_2 \|^2) \quad [1.3]$$


$$g(U) = (\bar{Z}_1 - \bar{Z}_2)U - \frac{1}{2}(\| \bar{Z}_1 \|^2 - \| \bar{Z}_2 \|^2) \quad [1.4]$$

$$g(U) > 0 \Rightarrow \text{class}(Z_1)$$

$$g(U) < 0 \Rightarrow \text{class}(Z_2)$$

**Εξισώσεις 1.2-1.4:** Υπολογισμός εξίσωσης μεσοκαθέτου για διάσταση = 2





**Σχήμα 1.3:** Γραμμικός ταξινομητής διάστασης 2 για δύο κλάσεις


Στην περίπτωση ταξινόμησης των προτύπων σε τρεις κλάσεις, η μεθοδολογία παραμένει ίδια, με τη διαφορά ότι δεν είναι πλέον εφικτή η ενοποίηση όλων των συναρτήσεων απόφασης σε μία ενιαία απλή μορφή όπως στην περίπτωση των δύο κλάσεων. Εδώ πλέον απαιτείται ο υπολογισμός κάθε συνάρτησης ξεχωριστά, δηλαδή υπολογίζονται οι αποστάσεις του τρέχοντος διανύσματος από όλους τους μέσους εκπροσώπους των αντίστοιχων κλάσεων, και τελικά επιλογή της κλάσης για την οποία εμφανίζεται η ελάχιστη απόσταση.

$$g_k(U) = \bar{Z}_k U - \frac{1}{2} \|\bar{Z}_k\|^2 \quad [1.5]$$

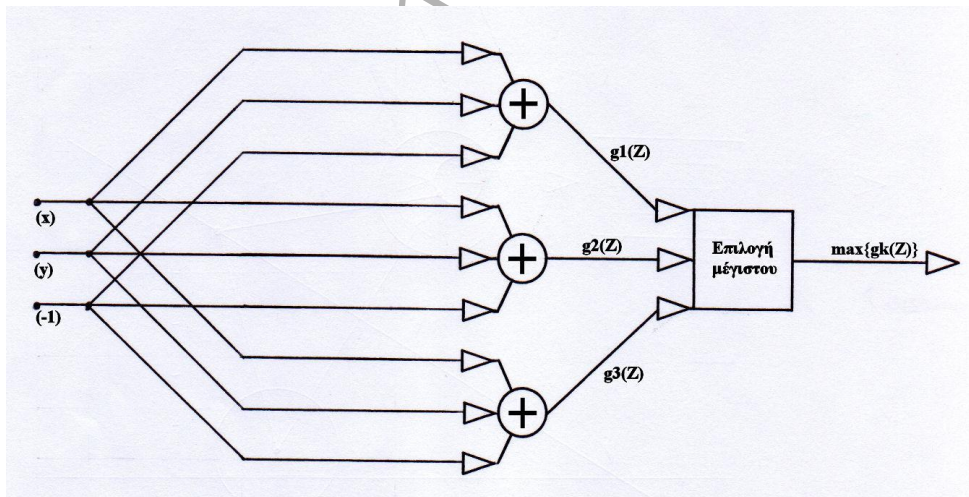
$$\min\{g_i(U)\} = g_k(U) \Rightarrow \text{class}(Z_k) \quad [1.6]$$

**Εξισώσεις 1.5-1.6:** Συναρτήσεις απόφασης και επιλογή κλάσεις για 3 κατηγορίες

Το παρακάτω σχήμα παρουσιάζει ένα απλό παράδειγμα τριών κλάσεων προτύπων διάστασης 2, όπου φαίνεται η απεικόνιση των προτύπων κάθε κλάσης στο επίπεδο. Στο σχήμα δεν εμφανίζονται πλέον μεσοκάθετοι αλλά μονάχα οι αποστάσεις ενός τυχαίου προτύπου από τις τρεις κλάσεις.



**Σχήμα 1.4:** Παράδειγμα γραμμικού ταξινομητή ελάχιστης απόστασης διάστασης 2



**Σχήμα 1.5:** Γραμμικός ταξινομητής διάστασης 2 για τρεις κλάσεις

Η μεθοδολογία γενικεύεται θεωρητικά για απεριόριστο πλήθος κλάσεων και διαστάσεων. Παρόλα αυτά, η αποτελεσματικότητα και η απόδοση ταξινομητών ελάχιστης απόστασης σε πρακτικές εφαρμογές παρουσιάζει ορισμένους σημαντικούς περιορισμούς που αφορούν κυρίως το πλήθος των κλάσεων που καλείται να υλοποιήσει η δομή του ταξινομητή. Αποδεικνύεται θεωρητικά ότι ταξινομητές ελάχιστης απόστασης εμφανίζουν υψηλή απόδοση σε περιπτώσεις όπου οι αποστάσεις μεταξύ των μέσων εκπροσώπων των κλάσεων είναι σχετικά μεγάλες σε σχέση με τη διασπορά των προτύπων της κλάσης γύρω τους [20]. Αντίθετα, σε περιπτώσεις όπου οι συστάδες των κλάσεων είναι πολύ κοντά ή ο πλήρης διαχωρισμός τους είναι αδύνατος με τη χρήση μίας και μόνο μεσοκαθέτου ευθείας, η απόδοση των ταξινομητών είναι μη ικανοποιητική. Επιπλέον, η υιοθέτηση επιμέρους μεσοκαθέτων ανά ζεύγη κλάσεων είναι δυνατό να οδηγήσει σε δημιουργία μη χαρακτηρισμένων περιοχών (ΜΧΠ), δηλαδή περιοχές του χώρου όπου δεν πραγματοποιείται θετική απόφαση για καμία από τις διαθέσιμες κλάσεις, στοιχείο ασφαλώς μη επιθυμητό για τη συμπεριφορά του ταξινομητή [10]. Τα μειονεκτήματα αυτά αποτελούν εν γένει χαρακτηριστικά του συγκεκριμένου τύπου ταξινομητών, καθώς και των περισσότερων γραμμικών ταξινομητών γενικότερα.

Γραμμικοί ταξινομητές που εμφανίζουν βέλτιστη απόδοση ταξινόμησης είναι δυνατό να κατασκευαστούν αν είναι εκ των προτέρων γνωστές οι κατανομές των πιθανοτήτων για κάθε κλάση, καθώς και *a priori* πληροφορία σχετικά με τη δομή του ίδιου του χώρου των προτύπων. Τέτοιοι ταξινομητές είναι οι Bayesian δομές με υπόθεση κανονικής (Gaussian) κατανομής για τα πρότυπα των κλάσεων. Ταξινομητές αυτής της μορφής χρησιμοποιούν πληροφορίες μέσης τιμής και συνδιασποράς των συνιστωσών των προτύπων κάθε κατηγορίας και ενσωματώνουν ακριβέστερη στατιστική αναπαράσταση του χώρου των κλάσεων, σε αντίθεση με τους κλασικούς ταξινομητές ελάχιστης απόστασης που χρησιμοποιούν μονάχα το μέσο εκπρόσωπο κάθε κλάσης [10, 20]. Παρόλα αυτά, η εκ των προτέρων γνώση της πραγματικής κατανομής πιθανοτήτων των προτύπων κάθε κλάσης, καθώς και των *a priori* πιθανοτήτων για τις κλάσεις είναι σπάνια εφικτή. Αυτό έχει ως αποτέλεσμα να υιοθετούνται προσεγγιστικές μέθοδοι στατιστικής εκτίμησης των άγνωστων παραμέτρων, οι οποίες είτε υποβιβάζουν την πραγματική απόδοση του ταξινομητή, είτε περιορίζουν την αξιοπιστία στα εξαγόμενα αποτελέσματα [10, 20].

Δύο ακόμα εξίσου αποδοτικές, αλλά και απαιτητικές ως προς την πολυπλοκότητα της διαδικασίας εκπαίδευσης, κατηγορίες γραμμικών ταξινομητών ελάχιστης απόστασης είναι η οικογένεια μεθόδων Ελάχιστου Μέσου Τετραγωνικού Σφάλματος (Least Mean Squares – LMS) και η οικογένεια μεθόδων Ελάχιστων Τετραγώνων (Least Squares – LS). Και οι δύο τεχνικές χρησιμοποιούν την ίδια βασική μεθοδολογία με τους ταξινομητές Bayes, η εκτίμηση όμως των κατανομών των πιθανοτήτων γίνεται δυναμικά με βάση τα διαθέσιμα σύνολα προτύπων που χρησιμοποιούνται κατά τη φάση της εκπαίδευσης [10, 26, 27]. Η διαφοροποίησή τους αφορά κυρίως στον τρόπο υπολογισμού του σφάλματος ταξινόμησης, όπως δηλώνει και το όνομα κάθε μιας μεθόδου. Οι άμεσες εκδόσεις απαιτούν την επίλυση γραμμικών συστημάτων εξισώσεων τάξης ίσης με το πλήθος των προτύπων στις κλάσεις, ενώ οι επαναληπτικές εκδόσεις εφαρμόζουν ευρετικά σχήματα σύγκλισης, παρόμοια με τους αλγόριθμους εκπαίδευσης σε αρχιτεκτονικές νευρωνικών δικτύων. Αποδοτικοί αλγόριθμοι, για την γρήγορη επίλυση των αντίστοιχων γραμμικών

συστημάτων εξισώσεων, έχουν προταθεί τόσο για τις άμεσες όσο και για τις έμμεσες εκδόσεις των αλγορίθμων, ενώ άλλες μέθοδοι, όπως η οικογένεια αναδρομικών μεθόδων ελαχίστων τετραγώνων (Recursive Least Squares – RLS), χρησιμοποιούν στατιστικές παραμέτρους ανώτερης τάξης [26, 27]. Παρόλα αυτά, η απόδοση των αντίστοιχων ταξινομητών στην καλύτερη περίπτωση προσεγγίζει αυτή των μη γραμμικών ταξινομητών νευρωνικών δικτύων, ανάλογα με την γραμμικότητα του εκάστοτε προβλήματος.

$$D_{eucl} = (\vec{x} - \vec{\mu}_i)^T (\vec{x} - \vec{\mu}_i) \quad [1.5]$$

**Εξίσωση 1.5:** Ευκλείδεια απόσταση

Εναλλακτικά, αντί της Ευκλείδειας απόστασης μπορούν να χρησιμοποιηθούν άλλες νόρμες απόστασης που να αξιοποιούν εν μέρει πληροφορία σχετικά με τη μορφή της κατανομής των προτύπων κάθε κλάσης στο χώρο. Κλασικό παράδειγμα αποτελεί η απόσταση Mahalanobis που ενσωματώνει στην εξίσωση του μητρώου συνδιασποράς των συνιστωσών των διανυσμάτων [10, 05].

$$D_{mah} = (\vec{x} - \vec{\mu}_i)^T \Sigma^{-1} (\vec{x} - \vec{\mu}_i) \quad [1.6]$$

**Εξίσωση 1.6:** Απόσταση Mahalanobis

Μια ακόμα απλούστερη υλοποίηση είναι μια παραλλαγή της κλασικής εξίσωσης της απόστασης Mahalanobis έτσι ώστε να χρησιμοποιούνται μονάχα τα διαγώνια στοιχεία του μητρώου συνδιασποράς, δηλαδή μόνο οι επιμέρους τιμές διασποράς για κάθε συνιστώσα σε συνδυασμό με τις μέσες τιμές.

$$D_{mah} = (\vec{x} - \vec{\mu}_i)^T \begin{bmatrix} \sigma_{11} & 0 \\ 0 & \sigma_{22} \end{bmatrix}^{-1} (\vec{x} - \vec{\mu}_i) \quad [1.7]$$

**Εξίσωση 1.7:** Απλοποιημένη μορφή απόστασης Mahalanobis

Η παραπάνω εξίσωση απόστασης διατηρεί την ίδια μορφή με την εξίσωση της Ευκλείδειας απόστασης, με την προσθήκη των επιμέρους διασπορών ως συντελεστές στους αντίστοιχους όρους του αθροίσματος. Ο υπολογισμός και η καταχώρηση των διασπορών θα πρέπει να γίνεται κατά τη φάση υπολογισμού των μέσων εκπροσώπων κάθε κλάσης, μαζί με τις μέσες τιμές. Η μορφή αυτή, αν και προσθέτει έναν ακόμη παράγοντα πολυπλοκότητας στην αναπαράσταση

των κλάσεων και στον υπολογισμό των επιμέρους αποστάσεων, παρουσιάζει σημαντικά πλεονεκτήματα έναντι της Ευκλείδειας απόστασης. Χωρίς να απαιτείται ο υπολογισμός ολόκληρου του μητρώου συνδιασποράς, η χρήση των επιμέρους διασπορών στο άθροισμα ενσωματώνει στον υπολογισμό του αθροίσματος πληροφορία σχετικά με την έκταση της συστοιχίας κάθε κλάσης, με αποτέλεσμα το διαχωριστικό σύνορο να μην είναι πλέον η μεσοκάθετος αλλά οποιαδήποτε καμπύλη δευτέρου βαθμού που περνά ανάμεσα στους μέσους εκπροσώπους σε αυθαίρετη απόσταση από τον καθένα. Αυτή η μορφή εξίσωσης απόστασης χρησιμοποιήθηκε για τη σχεδίαση και αξιολόγηση όλων των διαμορφώσεων του τυπικού ταξινομητή ελάχιστης απόστασης στην παρούσα εργασία.

### 1.5.2 Τεχνητά Νευρωνικά Δίκτυα (ΤΝΔ)

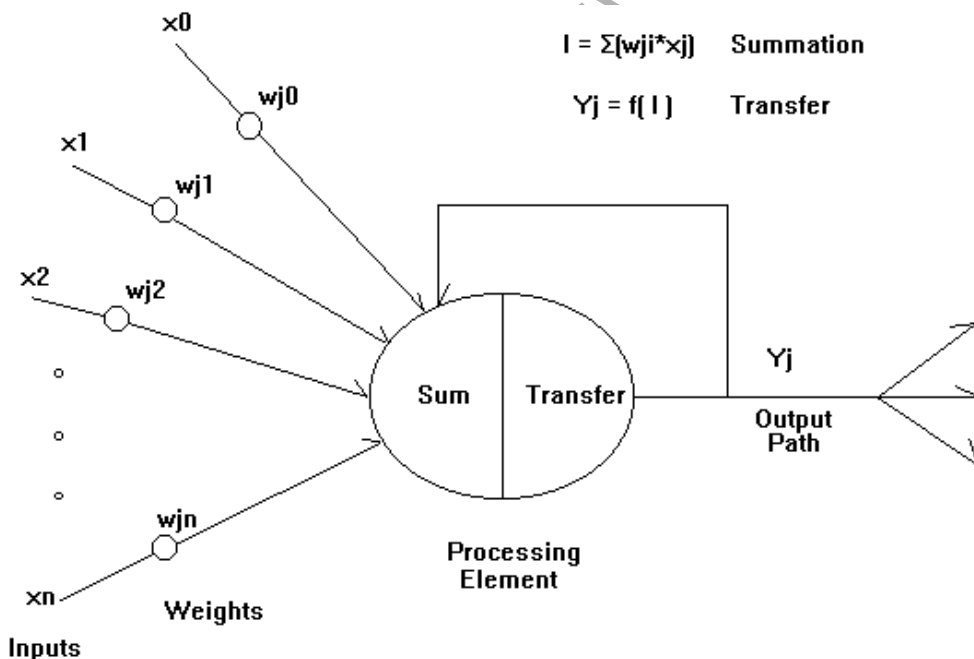
Οι μέθοδοι που παρουσιάστηκαν στις προηγούμενες ενότητες βασίζονται στη χρήση ενός συνόλου εκπαιδευτικών προτύπων για τον υπολογισμό συγκεκριμένων στατιστικών παραμέτρων, όπως η μέση τιμή και η διασπορά κάθε συνιστώσας στα αντίστοιχα διανύσματα κάθε κλάσης. Ο τυπικός ταξινομητής ελάχιστης απόστασης καθορίζεται πλήρως από τα διανύσματα των μέσων εκπροσώπων των κλάσεων (Ευκλείδεια απόσταση) ή και των επιμέρους διασπορών (απόσταση Mahalanobis). Αντίστοιχα, οι ταξινομητές Bayes για Gaussian κατανομές προτύπων καθορίζονται πλήρως από το μέσο διάνυσμα και το μητρώο συνδιασποράς για κάθε κλάση [20]. Τα πρότυπα που χρησιμοποιούνται για τον καθορισμό των παραμέτρων αυτών ονομάζονται εκπαιδευτικά πρότυπα και το αντίστοιχο σύνολο καλείται εκπαιδευτικό σύνολο.

Στην περίπτωση των γραμμικών ταξινομητών όπου ο καθορισμός των παραμέτρων του ταξινομητή γίνεται με άμεσες τεχνικές, η φάση της εκπαίδευσης είναι μια σχετικά απλή διαδικασία. Οι παράμετροι του ταξινομητή είναι τα πραγματικά στατιστικά χαρακτηριστικά που προκύπτουν από το σύνολο εκπαίδευσης, ενώ η τελική απόδοση του ταξινομητή εξαρτάται από το κατά πόσο οι στατιστικές αυτές παράμετροι επαρκούν για την καλή περιγραφή του χώρου των διανυσμάτων των προτύπων. Σε γραμμικά διαχωρίσιμες κλάσεις, η μέση τιμή από μόνη της ή σε συνδυασμό με τη διασπορά κάθε χαρακτηριστικού των προτύπων είναι αρκετές για την κατασκευή ενός ταξινομητή ελάχιστης απόστασης. Σε πιο πολύπλοκες περιπτώσεις, η τελική επιτυχία του ταξινομητή εξαρτάται από το βαθμό στον οποίο ισχύουν οι υποθέσεις γραμμικότητας για τον αντίστοιχο χώρο των διανυσμάτων.

Οι στατιστικές ιδιότητες, όμως, του χώρου των προτύπων σπάνια είναι γνωστές ή μπορούν να εκτιμηθούν με ακρίβεια. Πρακτικά, για την σχεδίαση αποδοτικών ταξινομητών θα πρέπει η διαδικασία εκπαίδευσης να ενσωματώνει την εκτίμηση των στατιστικών ιδιοτήτων του χώρου των προτύπων κατευθείαν στην ίδια την μέθοδο εκπαίδευσης. Η απαίτηση αυτή ουσιαστικά αίρει κάθε ανάγκη υπόθεσης γραμμικότητας για το χώρο των προτύπων, με ανάλογο όμως κόστος στην πολυπλοκότητα του αλγορίθμου εκπαίδευσης και του ίδιου του ταξινομητή.

Μία από τις πιο ευρεία διαδεδομένες και εφαρμοσμένες στην πράξη αρχιτεκτονικές παρόμοιων μη γραμμικών αρχιτεκτονικών αποτελούν τα Τεχνητά

Νευρωνικά Δίκτυα (ΤΝΔ) ή πιο απλά Νευρωνικά Δίκτυα. Οι πρώτες έρευνες σχετικά με τη λειτουργία και την πρακτική εφαρμογή σε ηλεκτρονικό υπολογιστή μεθόδων που προσομοιώνουν τη λειτουργία του νευρικού συστήματος και του εγκεφάλου ζωντανών οργανισμών ξεκινά, ουσιαστικά με την εργασία των McCulloch και Pitts το 1943, όπου προτάθηκε για πρώτη φορά η δομή του νευρώνα [14]. Η βασική δομή του νευρώνα περιελάμβανε ένα σύνολο παραμέτρων που χρησιμοποιούνταν για την υλοποίηση μιας δυαδικής συσκευής κατωφλίου. Λαμβάνοντας ως είσοδο ένα σύνολο ερεθισμάτων, υπολογίζεται το σταθμισμένο άθροισμα των εισόδων με τις αντίστοιχες παραμέτρους (βάρη) και η τελική έξοδος του νευρώνα είναι η τιμή +1 ή -1, ανάλογα με το όριο κατωφλίου που χρησιμοποιείται (συνήθως την αρχή των αξόνων). Η συνάρτηση αυτή ονομάζεται συνάρτηση ενεργοποίησης ή συνάρτηση μεταφοράς. Έκτοτε πολλές εναλλακτικές μορφές νευρώνων έχουν προταθεί, όπως η χρήση σιγμοειδούς συνάρτησης, υπερβολικών τριγωνομετρικών συναρτήσεων ή συναρτήσεων πιθανοτικών κατανομών στη θέση της απλής συνάρτησης κατωφλίου, όμως η βασική δομή των νευρώνων παραμένει η ίδια [12].



**Σχήμα 1.6:** Δομή και λειτουργία νευρώνα


Έχοντας σαν βάση τη δομή του νευρώνα, η πρώτη προσπάθεια συνδυασμού πολλαπλών νευρώνων για την κατασκευή νέων αρχιτεκτονικών ταξινομητών έγινε στα τέλη της δεκαετίας του '50 και στις αρχές της δεκαετίας του '60, με την πρόταση από τον Rosenblatt της δομής και του αντίστοιχου αλγορίθμου

Perceptron. Η νέα αυτή δομή επέτρεπε την χρήση πολλών νευρώνων κατωφλίου παράλληλα, με τον αλγόριθμο εκπαίδευσης να αναπροσαρμόζει τα βάρη των νευρώνων με επαναληπτικό τρόπο, έτσι ώστε τελικά το δίκτυο να είναι σε θέση να ταξινομεί σωστά τα πρότυπα ενός δεδομένου συνόλου εκπαίδευσης [14, 10]. Το πρώτο επίπεδο ονομάζεται επίπεδο εισόδου, το τελευταίο επίπεδο εξόδου και τα υπόλοιπα επίπεδα στο εσωτερικό του δικτύου ονομάζονται κρυμμένα ή κρυφά επίπεδα.

$$O_j = \sum_i x_i w_{ij} \quad , \quad y_j = f(O_j) \quad [1.8-1.9]$$

**Εξισώσεις 1.8-1.9:** Συνάρτηση αθροίσματος και μεταφοράς για νευρώνα perceptron

Τα δίκτυα perceptron χρησιμοποιήθηκαν με επιτυχία σε αρκετές εφαρμογές ταξινόμησης, όμως θεωρητικές και πειραματικές έρευνες κατέληξαν στο συμπέρασμα ότι παρουσιάζουν σημαντικά προβλήματα σε περιπτώσεις όπου οι κλάσεις δεν είναι γραμμικά διαχωρίσιμες. Για την αντιμετώπιση του συγκεκριμένου ζητήματος προτάθηκε η ιδέα της χρησιμοποίησης αλληπαλλήλων νευρωνικών επιπέδων perceptron. Η βασική ιδέα είναι η διασύνδεση πολλαπλών επιπέδων τύπου perceptron διαδοχικά, έτσι ώστε η έξοδος του ενός επιπέδου να αποτελεί είσοδο για το επόμενο επίπεδο. Η μορφή του δικτύου και ο ακριβής τρόπος διασύνδεσης των νευρώνων μεταξύ τους αποτελούν την τοπολογία του νευρωνικού δικτύου.

**Σχήμα 1.7:** Αρχιτεκτονική πολυεπίεδων δικτύων

Τοπολογίες πολλαπλών επιπέδων προσφέρουν την απαιτούμενη μη γραμμικότητα για την επίλυση πολύπλοκων προβλημάτων αναγνώρισης προτύπων, όμως δημιουργούν σημαντικές δυσκολίες στον καθορισμό της λειτουργίας της διαδικασίας εκπαίδευσης, αφού πλέον η αναπροσαρμογή των βαρών των νευρώνων δεν σχετίζεται άμεσα με το τελικό σφάλμα ταξινόμησης όπως στην περίπτωση του perceptron. Το γεγονός αυτό αποτέλεσε και τον ουσιαστικό λόγο για τον οποίο το πεδίο των νευρωνικών δικτύων εγκαταλείφθηκε για περίπου δύο δεκαετίες. Αρκετά αργότερα, το 1986, οι Rumelhart, Hinton και Williams κατάφεραν να διατυπώσουν έναν αποτελεσματικό αλγόριθμο εκπαίδευσης για δίκτυα πολλαπλών επιπέδων νευρώνων τύπου perceptron. Ο αλγόριθμος αυτός είναι σήμερα γνωστός ως Back-Propagation και αποτελεί ίσως την πιο διαδεδομένη μέθοδο εκπαίδευσης νευρωνικών δικτύων.

#### 1.5.2.1 Ο αλγόριθμος Back-Propagation

Τα πολυεπίεδα νευρωνικά δίκτυα αποτελούν σήμερα μια από τις πιο διαδεδομένες μορφές μη γραμμικών δομών με εφαρμογές σε ευρύτατο φάσμα εφαρμογών, με έμφαση στην αναγνώριση προτύπων και στην επεξεργασία σήματος. Η εκτεταμένη μελέτη των ιδιοτήτων και πρακτική χρήση τους σε πολλά διαφορετικά πεδία εφαρμογών οφείλονται κυρίως στην πληρότητα της




περιγραφής της διαδικασίας εκπαίδευσης, που υλοποιείται μέσω του αλγορίθμου Back-Propagation.

Η κλασική δομή πολυεπίπεδων δικτύων τύπου perceptron βασίζεται στην τυπική δομή νευρώνα, χρησιμοποιώντας ως συνάρτηση μεταφοράς τη λεγόμενη σιγμοειδή συνάρτηση.

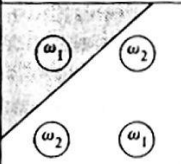
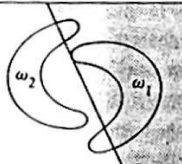
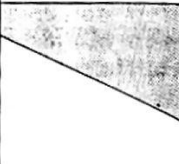
$$y = \text{sigmoid}(x) = \frac{1}{1 + e^{-x}} \quad [1.10]$$

**Εξίσωση 1.10:** Τυπική σιγμοειδής συνάρτηση



**Σχήμα 1.8:** Γραφική παράσταση σιγμοειδούς συνάρτησης

Η χρησιμοποίηση της σιγμοειδούς συνάρτησης σε συνδυασμό με την τοπολογία πολλαπλών νευρωνικών επιπέδων, καθιστούν την αρχιτεκτονική αυτή ισχυρότατο εργαλείο κατασκευής ταξινομητών για την επίλυση πολύπλοκων προβλημάτων αναγνώρισης προτύπων. Η δυνατότητα υλοποίησης κάποιας απεικόνισης εισόδου-εξόδου μέσω του νευρωνικού δικτύου εξαρτάται από τα δύο αυτά χαρακτηριστικά του [16]. Η μέγιστη πολυπλοκότητα της απεικόνισης αυτής σχετίζεται με τη λεγόμενη διάσταση Vapnik-Chervonenkis (VCDim), που ορίζει ουσιαστικά την τάξη μεγέθους όλων των πιθανών τρόπων γραμμικού διαχωρισμού του χώρου των προτύπων [17, 18]. Αν και ο ακριβής καθορισμός της VCDim μπορεί να γίνει στην πράξη μόνο για την περίπτωση του perceptron, αποδεικνύεται θεωρητικά ότι δίκτυα με συνολικά τρία νευρωνικά επίπεδα με νευρώνες που χρησιμοποιούν σιγμοειδή συνάρτηση ενεργοποίησης, είναι δυνατό να υλοποιήσουν οποιαδήποτε αυθαίρετη απεικόνιση εισόδου-εξόδου ως τομές υποχώρων [20, 17].

Δομή ΤΝΔ	Τύπος περιοχής απόφασης	Αναπαράσταση επίλυσης XOR	Κλάσεις με σύνθετες περιοχές απόφασης	Τύπος γενικευμένων περιοχών απόφασης
<b>1-επίπεδο</b> 	Απλό υπερεπίπεδο			
<b>2-επίπεδα</b> 	Ανοικτή ή κλειστή κυρτή περιοχή			
<b>3-επίπεδα</b> 	Οποιασδήποτε πολυπλοκότητας (ανάλογα με τους κρυμμένους νευρώνες)			

**Σχήμα 1.9:** Πολυπλοκότητα απεικόνισης σε σχέση με πολυπλοκότητα τοπολογίας

Το σημαντικότερο και πιο ενδιαφέρον ίσως στοιχείο της συγκεκριμένης αρχιτεκτονικής αποτελεί ο αλγόριθμος εκπαίδευσης. Ο αλγόριθμος Back-Propagation ανήκει στην κατηγορία των αλγορίθμων εκπαίδευσης με επίβλεψη, όπου απαιτείται η καθοδήγηση της εξόδου προς μια επιθυμητή τιμή, σε αντίθεση με αλγορίθμους εκπαίδευσης χωρίς επίβλεψη, όπου τα πρότυπα διαχωρίζονται με αυθαίρετο τρόπο σε συστάδες. Βασίζεται στον υπολογισμό του σφάλματος ταξινόμησης κάθε εκπαιδευτικού προτύπου στο τελευταίο νευρωνικό επίπεδο (έξοδος δικτύου) και στη συνέχεια μετάδοση του σφάλματος προς τα πίσω, δηλαδή στα προηγούμενα επίπεδα με κατάλληλο τρόπο, ώστε να είναι εφικτή τελικά η αναπροσαρμογή των βαρών κάθε νευρώνα του δικτύου με τρόπο ανάλογο με αυτόν του δικτύου perceptron. Η συγκεκριμένη μέθοδος αναφέρεται ως γενικευμένος κανόνας Δέλτα (Delta rule) για την εκμάθηση μέσω διάδοσης του σφάλματος προς τα πίσω [20, 12, 13].

Για κάθε εκπαιδευτικό πρότυπο είναι διαθέσιμα τόσο το διάνυσμα του προτύπου, που χρησιμοποιείται ως διάνυσμα εισόδου για το δίκτυο, όσο και η πραγματική κλάση στην οποία ανήκει, που έχει τη μορφή διανύσματος επιθυμητής εξόδου για το δίκτυο. Το τρέχον πρότυπο παρουσιάζεται στο δίκτυο και το διάνυσμα των συνιστωσών χρησιμοποιείται ως διάνυσμα εισόδου για το δίκτυο. Υπολογίζεται η έξοδος του πρώτου νευρωνικού επιπέδου, ακολούθως η έξοδος του δεύτερου νευρωνικού επιπέδου, και ούτω κάθε εξής. Τελικά στο τελευταίο επίπεδο λαμβάνεται η έξοδος του δικτύου για το τρέχον πρότυπο. Το σφάλμα ταξινόμησης στο επίπεδο εξόδου υπολογίζεται εύκολα ως η διαφορά της

επιθυμητής από την πραγματική έξοδο του δικτύου για το συγκεκριμένο πρότυπο, υπό τη μορφή του αθροίσματος των τετραγωνικών επιμέρους σφαλμάτων (Sum of Squares Error – SSE). Η αρχικοποίηση των βαρών γίνεται συνήθως αναθέτοντας σε αυτά μικρές τυχαίες τιμές με μέση τιμή ίση με μηδέν.

Για τον υπολογισμό της συνεισφοράς κάθε επιπέδου στο τελικό σφάλμα υπολογίζονται οι επιμέρους παράγωγοι της συνάρτησης σφάλματος για κάθε νευρώνα ξεχωριστά, σε σχέση με το διάνυσμα των βαρών του. Έτσι υπολογίζεται η συνεισφορά κάθε βάρους ξεχωριστά στο συνολικό σφάλμα που προκύπτει για τον νευρώνα. Χρησιμοποιώντας την ίδια τεχνική και με βάση τα όσα έχουν υπολογιστεί για το επίπεδο  $N$ , είναι δυνατό κατά τον ίδιο τρόπο να υπολογιστούν οι συνεισφορές των επιμέρους νευρώνων και κάθε βάρους ξεχωριστά στο σφάλμα για το επίπεδο  $N-1$ . Τελικά, προκύπτει ένα σύνολο εξισώσεων που δίνει τη δυνατότητα της «μετάδοσης» του σφάλματος από το επίπεδο εξόδου διαδοχικά σε όλα τα επίπεδα του νευρωνικού δικτύου [14, 12, 13, 25].

Έχοντας υπολογίσει τη συνεισφορά κάθε βάρους του δικτύου στο τελικό σφάλμα ταξινόμησης, είναι δυνατή η εφαρμογή κάποιου ευρετικού σχήματος για την αναπροσαρμογή των τιμών των βαρών. Στον αλγόριθμο Back-Propagation χρησιμοποιείται ένα σχήμα που μοιάζει αρκετά με τον κανόνα Δέλτα ελάχιστων μέσων τετραγωνικών σφαλμάτων (LMS delta rule) ή αλλιώς κανόνα Windrow-Hoff, που χρησιμοποιείται για δίκτυα τύπου perceptron [20, 17]. Ο κανόνας αναπροσαρμογής του Back-Propagation χρησιμοποιεί σταθμισμένο άθροισμα (αφαίρεση) του σφάλματος, σε σχέση με την εκάστοτε είσοδο του δικτύου, με την τρέχουσα τιμή του κάθε βάρους του δικτύου ξεχωριστά.

Υπολογισμός εξόδου:

$$a_i^{(1)}(t) = \sum_{j=1}^{N_0} w_{ij}^{(1)}(t) o_j^{(0)}(t) + \theta_i^{(1)} \quad , \quad o_i^{(1)} = f_h(a_i^{(1)})(t) \quad ,$$

$$1 \leq i \leq N_1 \quad [1.11]$$

$$a_i^{(2)}(t) = \sum_{j=1}^{N_1} w_{ij}^{(2)}(t) o_j^{(1)}(t) + \theta_i^{(2)} \quad , \quad o_i^{(2)} = f_h(a_i^{(2)})(t) \quad ,$$

$$1 \leq i \leq N_2 \quad [1.12]$$

.....

$$a_i^{(L)}(t) = \sum_{j=1}^{N_{L-1}} w_{ij}^{(L)}(t) o_j^{(L-1)}(t) + \theta_i^{(L)} \quad , \quad o_i^{(L)} = f_h(a_i^{(L)})(t) \quad ,$$

$$1 \leq i \leq N_L \quad [1.13]$$

Αναπροσαρμογή βαρών:

$$w_{ij}^{(l)}(t+1) = w_{ij}^{(l)}(t) + \varepsilon \delta_i^{(l)}(t) o_j^{(l-1)}(t) \quad [1.14]$$

όπου  $\delta_i^{(l)}(t)$  είναι το σήμα σφάλματος και προσδιορίζεται ως εξής:

$$\delta_i^{(L)}(t) = (t_i^m - o_i^{(L)}(t)) f_h'(a_i^{(L)}(t)) \quad [1.15]$$

$$\delta_i^{(l)}(t) = f_h'(a_i^{(l)}(t)) \sum_j \delta_j^{(l+1)}(t) w_{ij}^{(l+1)}(t) \quad [1.16]$$

$f_h$  : η μη-γραμμική συνάρτηση εξόδου (σιγμοειδής)

$o_i^{(l)}(t)$  :  $(l = 1, 2, \dots, L)$  αποτέλεσμα εξόδου της μονάδας  $i$  του στρώματος  $l$

$o_i^{(0)}(t) = x_i$  : τρέχον πρότυπο εισόδου

$a_i^{(l)}(t)$  : κατάσταση ενεργοποίησης της μονάδας  $i$  του στρώματος  $l$

$w_{ij}^{(l)}(t)$  : συντελεστής βάρους μεταξύ της μονάδας  $j$  του στρώματος  $l-1$  και της μονάδας  $i$  του στρώματος  $l$

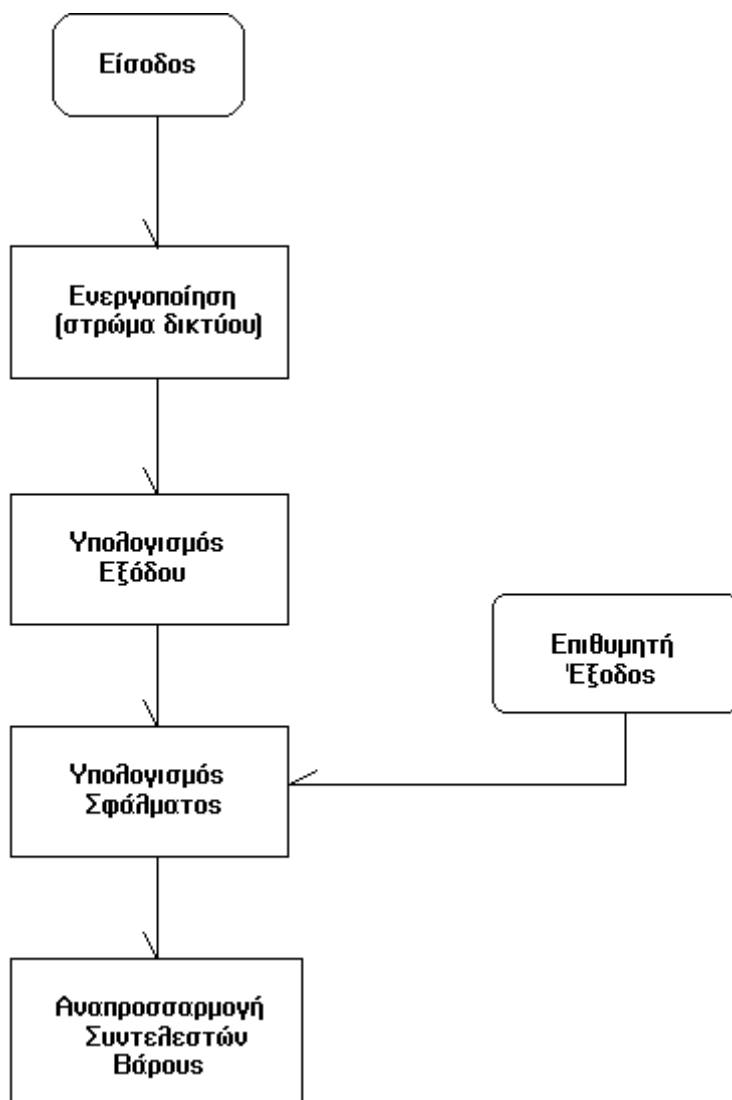
$\varepsilon$  : ρυθμός μάθησης,  $0 < \varepsilon < 1$

$t_i^{(m)}$  : επιθυμητή έξοδος της μονάδας  $i$  όταν το πρότυπο  $m$  παρουσιάζεται στο δίκτυο

#### Εξισώσεις 1.11-1.16: Σύνολο εξισώσεων για αλγόριθμο Back-Prop

Η μέθοδος εκπαίδευσης μέσω του αλγορίθμου Back-Propagation είναι επαναληπτική και ολοκληρώνεται όταν όλα τα πρότυπα εκπαίδευσης ταξινομούνται πλέον σωστά, με άλλα λόγια όταν το συνολικό σφάλμα

ταξινόμησης είναι αρκετά μικρό. Σε κάθε επανάληψη κάθε πρότυπο εκπαίδευσης παρουσιάζεται ξεχωριστά στο νευρωνικό δίκτυο και εκτελείται η διαδικασία αναπροσαρμογής των βαρών του σύμφωνα με το τρέχον σφάλμα ταξινόμησης στην έξοδο. Όταν όλα τα πρότυπα εκπαίδευσης έχουν παρουσιαστεί στο δίκτυο ολοκληρώνεται ο τρέχον κύκλος εκπαίδευσης (epoch) και η διαδικασία ξεκινά και πάλι από το πρώτο εκπαιδευτικό πρότυπο. Η σύγκλιση του δικτύου δεν είναι άμεση γιατί η αναπροσαρμογή των βαρών λαμβάνει υπόψη μονάχα μέρος της τρέχουσας τιμής σφάλματος, καθώς επίσης και λόγω του ότι η αναπροσαρμογή με βάση κάποιο συγκεκριμένο πρότυπο διαταράσσει τις επιπτώσεις της αναπροσαρμογής που έχουν γίνει μέχρι εκείνη τη χρονική στιγμή σύμφωνα με προηγούμενα εκπαιδευτικά πρότυπα. Αποδεικνύεται θεωρητικά ότι η σύγκλιση του αλγορίθμου εξασφαλίζεται, υπό προϋποθέσεις [17, 25].



**Σχήμα 1.10:** Μπλοκ διάγραμμα αλγορίθμου Back-Prop

#### 1.5.2.2 Προβλήματα και βελτιώσεις αλγορίθμου Back-Propagation

Το βασικό μειονέκτημα του αλγορίθμου είναι ο σχετικά αργός ρυθμός σύγκλισης, ανεξάρτητα από τη φύση του προβλήματος, στοιχείο που χαρακτηρίζει εν γένει όλες τις μεθόδους εκπαίδευσης που βασίζονται σε τεχνικές μέγιστης καθόδου (gradient descent) στην επιφάνεια της συνάρτησης σφάλματος [16]. Επιπλέον, επιφάνειες σφάλματος με απότομες διακυμάνσεις

μπορούν να οδηγήσουν σε εγκλωβισμό σε τοπικά ελάχιστα, κάτι που είναι γνωστό και ως «πάγωμα» της διαδικασίας εκπαίδευσης [17, 18]. Για τη βελτίωση της ταχύτητας και της ευστάθειας σύγκλισης του αλγορίθμου έχουν προταθεί παραλλαγές της βασικής μεθόδου σχετικά με τον κανόνα αναπροσαρμογής των βαρών, τον τρόπο εφαρμογής των επαναλήψεων κατά την εκπαιδευτική διαδικασία, το συντελεστή του ποσοστού αναπροσαρμογής των βαρών, καθώς ακόμα και σε σχέση με τη μορφή της συνάρτησης ενεργοποίησης των νευρώνων.

Για την αποφυγή τοπικών ελαχίστων και τη βελτίωση της ταχύτητας σύγκλισης σε ομαλές επιφάνειες, πολλές φορές εφαρμόζεται η προσθήκη ενός παράγοντα «ορμής» (momentum) στην αναπροσαρμογή των βαρών του δικτύου. Εκτός από τις τρέχουσες τιμές των βαρών, διατηρούνται και οι αμέσως προηγούμενες όπως διαμορφώθηκαν στον τελευταίο κύκλο εκπαίδευσης. Έτσι είναι δυνατή η διαφόρτιση και ο υπολογισμός της μεταβολής που προκύπτει σε σχέση με την τρέχουσα τιμή. Αν το ποσοστό μεταβολής που προκύπτει από την εξίσωση απότομης κατάβασης είναι πολύ μικρό, λόγω τοπικού ελαχίστου ή σχεδόν οριζόντιας επιφάνειας σφάλματος, ο συντελεστής ορμής μπορεί να οδηγήσει σε περαιτέρω βελτίωση της εξόδου του νευρώνα με γρηγορότερο ρυθμό. Επίσης ο συντελεστής ορμής επιταχύνει ακόμα περισσότερο τη σύγκλιση σε ομαλές επιφάνειες, αφού συνεχής μεταβολή των βαρών συνεχώς κατά την ίδια κατεύθυνση γίνεται με ολοένα αυξανόμενο ρυθμό [17].

Για την υλοποίηση των κύκλων εκπαίδευσης υπάρχουν δύο επιλογές. Στην πρώτη, η εκτέλεση των αναπροσαρμογών των βαρών του δικτύου γίνεται άμεσα κατά τον υπολογισμό του σφάλματος για το εκάστοτε πρότυπο εισόδου. Η μεταβολή γίνεται κατά την κατεύθυνση καθόδου που υποδεικνύει το διάνυσμα σφάλματος για το τρέχον πρότυπο και μόνο, και είναι γνωστή ως εκπαίδευση "on-line". Η επιλογή αυτή προσφέρει ευκολία στην υλοποίηση, όμως είναι δυνατό να δημιουργήσει προβλήματα στην ευστάθεια και την ταχύτητα σύγκλισης του αλγορίθμου, αφού η τεχνική αυτή μπορεί με κάθε νέα αναπροσαρμογή των βαρών για το τρέχον πρότυπο να αναιρούνται εν μέρει οι μεταβολές που εκτελέστηκαν για όλα τα προηγούμενα πρότυπα πριν από αυτό. Στη δεύτερη επιλογή, η εκτέλεση των αναπροσαρμογών των βαρών δεν γίνεται άμεσα αλλά καταχωρείται σε ενδιάμεσο χώρο αποθήκευσης. Με την ολοκλήρωση του τρέχοντος κύκλου εκπαίδευσης, όταν δηλαδή έχουν παρουσιαστεί όλα τα πρότυπα στο δίκτυο, υπολογίζεται η συνολική αθροιστική μεταβολή που προκύπτει συνδυάζοντας όλες τις επιμέρους, και η μεταβολή που εφαρμόζεται τελικά γίνεται κατά την κατεύθυνση καθόδου που υποδεικνύει το συνδυασμένο διάνυσμα σφάλματος. Η μέθοδος αυτή είναι γνωστή ως εκπαίδευση "off-line" και έχει αποδειχτεί πειραματικά ότι στα περισσότερα προβλήματα συνεισφέρει περισσότερο στην ευστάθεια παρά στην ταχύτητα σύγκλισης του αλγορίθμου [17, 16, 18].

Για την καλύτερη και ομαλότερη σύγκλιση του αλγορίθμου εκπαίδευσης, κατά την φάση αναπροσαρμογής των βαρών σύμφωνα με το σφάλμα εξόδου για το τρέχον πρότυπο, είναι σκόπιμο μονάχα ποσοστό της υπολογιζόμενης διαφοράς να εφαρμοστεί για τη μεταβολή της τρέχουσας τιμής κάθε βάρους. Το ποσοστό αυτό καθορίζεται από μία ειδική παράμετρο του αλγορίθμου εκπαίδευσης και ονομάζεται συντελεστής μάθησης ή ρυθμός μάθησης (learning rate). Τιμές κοντά στο 0 δίνουν αργή αλλά σταθερή σύγκλιση, ενώ τιμές κοντά

στο 1 επιταχύνουν τη σύγκλιση με πιθανό κόστος στην ευστάθεια. Με ανάλογο τρόπο καθορίζεται και ο συντελεστής ορμής (momentum coefficient) στην περίπτωση που χρησιμοποιούνται παρόμοιες τεχνικές στην εκπαίδευση. Συνήθως οι συντελεστές αυτοί είναι καθολικοί και ορίζονται στατικά για όλη τη διάρκεια της διαδικασίας εκπαίδευσης. Έχουν προταθεί παραλλαγές του τυπικού Back-Propagation αλγορίθμου που χρησιμοποιούν γραμμικά ή εκθετικά φθίνουσες συναρτήσεις αντί σταθερών τιμών, έτσι ώστε να περιορίζονται σταδιακά οι τροποποιήσεις στα βάρη του δικτύου καθώς προχωρά η εκπαίδευση, σύμφωνα με τη γενικότερη φιλοσοφία των μεθόδων simulated annealing. Επίσης υπάρχουν ειδικές τεχνικές που περιλαμβάνουν δομές για αποθήκευση και τροποποίηση συντελεστών μάθησης για κάθε βάρος ξεχωριστά (Delta-Bar-Delta Rule), έτσι ώστε οι αναπροσαρμογές να γίνονται κατά βέλτιστο τρόπο σε όλη τη διάρκεια της διαδικασίας εκπαίδευσης [17].

Τέλος, αντί της σιγμοειδούς ως συνάρτηση ενεργοποίησης των νευρώνων, έχουν προταθεί πολλές άλλες εναλλακτικές λύσεις, ανάλογα με το είδος του νευρωνικού δικτύου και του αλγορίθμου εκπαίδευσης που χρησιμοποιεί. Η υπερβολική εφραπτομένη έχει την ίδια μορφή και συμπεριφορά με τη σιγμοειδή συνάρτηση, όμως η εφαρμογή των αντίστοιχων κανόνων παραγωγίσιμης για την κατασκευή των τροποποιημένων εξισώσεων αναπροσαρμογής των βαρών, οδηγεί σε σχήματα με βελτιωμένη ταχύτητα σύγκλισης σε αρκετές περιπτώσεις, με αντίστοιχο φυσικά κόστος στον χρόνο υπολογισμού της [17].

#### 1.5.2.3 Τεχνικές σχεδίασης νευρωνικών δικτύων

Η πλήρης σχεδίαση ενός νευρωνικού δικτύου συνίσταται στον καθορισμό της τοπολογίας και στην διαδικασία εκπαίδευσης. Αν και ο αλγόριθμος εκπαίδευσης ασχολείται με όλες τις λεπτομέρειες της διαδικασίας σύγκλισης, δεν σχετίζεται με κανένα τρόπο με την τοπολογία, δηλαδή τη μορφή του δικτύου. Το πρόβλημα του καθορισμού της βέλτιστης τοπολογίας είναι ίσως το δυσκολότερο στον τομέα της σχεδίασης νευρωνικών ταξινομητών.

Γενικά, το νευρωνικό δίκτυο μπορεί να περιλαμβάνει αυθαίρετο αριθμό επιπέδων με αυθαίρετο πλήθος νευρώνων στο καθένα από αυτά. Η θεωρία αποδεικνύει ότι τρία το πολύ επίπεδο είναι αρκετά για την επίλυση οποιουδήποτε προβλήματος, όμως ο αριθμός των επιπέδων σχετίζεται άμεσα με το μέγεθος του κάθε ενός από αυτά. Για πολυεπίπεδα δίκτυα τύπου perceptron που χρησιμοποιούν αλγόριθμο εκπαίδευσης Back-Propagation, μελέτες σε επίπεδο περισσότερο πειραματικό παρά θεωρητικό, έχουν προτείνει διάφορες μεθοδολογίες για τον καθορισμό του βέλτιστου αριθμού επιπέδων και νευρώνων στο δίκτυο [16]. Το νευρωνικό δίκτυο μπορεί να θεωρηθεί ως ένας γενικής μορφής μη γραμμικός ταξινομητής ικανός να υλοποιήσει αυθαίρετες απεικονίσεις μεταξύ εισόδου εξόδου. Όπως κάθε παρόμοιο σύστημα, οι βαθμοί ελευθερίας καθορίζονται από το πλήθος των ελεύθερων παραμέτρων που πρόκειται να καθοριστούν μέσα από τη διαδικασία της εκπαίδευσης. Στην περίπτωση των γραμμικών συστημάτων ο καθορισμός των παραμέτρων γίνεται με μονοσήμαντο τρόπο μέσω κάποιας άμεσης ή έμμεσης μεθόδου ανάδειξης των εξαρτήσεων μεταξύ εισόδου και επιθυμητής εξόδου. Το ίδιο μπορεί θεωρητικά να εφαρμοστεί



και στην περίπτωση των μη γραμμικών συστημάτων, με την εφαρμογή περισσότερο πολύπλοκων μεθόδων για τον καθορισμό των παραμέτρων.

Παρόλα αυτά, η περίπτωση των μη γραμμικών συστημάτων είναι στην πραγματικότητα πολύ πιο σύνθετη από ότι αρχικά φαίνεται. Επειδή τα μη γραμμικά συστήματα είναι συχνά δύσκολο να επιλυθούν άμεσα, για τον καθορισμό των παραμέτρων χρησιμοποιούνται σχεδόν πάντοτε έμμεσες μέθοδοι και διάφορα επαναληπτικά σχήματα, όπως η μορφή του αλγόριθμου Back-Propagation. Επιπλέον, συνήθως εφαρμόζονται σε προβλήματα όπου, είτε λόγω πολυπλοκότητας, είτε λόγω υψηλού βαθμού μη γραμμικότητας, είναι δύσκολο να καθοριστούν σύνολα εκπαίδευσης που να καλύπτουν όλο το εύρος του χώρου των προτύπων. Έτσι ο αλγόριθμος εκπαίδευσης θα πρέπει, από τη μια πλευρά να εκτελεστεί με βάση ελλιπή πληροφορία σχετικά με το χώρο, ενώ παράλληλα απαιτείται η σχεδίαση ενός συστήματος με ικανοποιητική απόδοση για κάθε συνδυασμό εισόδου εξόδου. Ακόμα, είναι απαραίτητο ο ταξινομητής να λειτουργεί με υψηλό ποσοστό επιτυχίας και στην περίπτωση που τα δεδομένα εισόδου είναι ελλιπή ή περιέχουν θόρυβο. Τα χαρακτηριστικά αυτά καθορίζουν την ιδιότητα που ονομάζεται ικανότητα γενίκευσης του ταξινομητή και αποτελεί έναν από τους σημαντικότερους παράγοντες στη σχεδίασή του. Ο υψηλός βαθμός ικανότητας γενίκευσης και η ανθεκτικότητα σε θόρυβο ή ελλιπή δεδομένα, καθώς επίσης η προσαρμοστικότητα και ο υψηλός βαθμός παραλληλίας, είναι μερικά από τα σημαντικότερα στοιχεία επιτυχίας των νευρωνικών ταξινομητών σε μεγάλο εύρος εφαρμογών [17].

Για την επίτευξη υψηλής ικανότητας γενίκευσης του νευρωνικού δικτύου, θα πρέπει, εκτός από την πληρότητα του συνόλου εκπαιδευτικών προτύπων, η δομή και τοπολογία να επιτρέπει την κατασκευή μιας επαρκούς περιγραφής του χώρου μέσω των τιμών των βαρών του. Αν και θεωρητικά για τον καθορισμό της τιμής  $N$  ελεύθερων παραμέτρων απαιτούνται επίσης  $N$  πρότυπα εκπαίδευσης, παρόλα αυτά για την επίτευξη υψηλού βαθμού ικανότητας γενίκευσης απαιτούνται πολύ περισσότερα πρότυπα. Συχνά το απαιτούμενο μέγεθος του συνόλου εκπαίδευσης υπολογίζεται ως ακέραια πολλαπλάσια του συνολικού αριθμού των βαρών του δικτύου, συνήθως μεταξύ 3 και 10. Η ίδια τεχνική μπορεί να εφαρμοστεί και με αντίστροφη λογική, δηλαδή με βάση το μέγεθος του διαθέσιμου συνόλου εκπαίδευσης, να καθοριστεί το μέγιστο πλήθος συνολικά των βαρών του δικτύου, έτσι ώστε να επιτυγχάνεται αρκετά καλή ικανότητα γενίκευσης [25, 16].

Στην περίπτωση που το σύνολο των εκπαιδευτικών προτύπων δεν επαρκεί για την ικανοποιητική εκπαίδευση του δικτύου, είναι δυνατό να δημιουργηθούν προβλήματα στην συμπεριφορά του τελικού ταξινομητή. Αν και η εκπαίδευση μπορεί να ολοκληρωθεί με επιτυχία μετά από κάποιο αριθμό επαναλήψεων, η απόδοση του ταξινομητή για άγνωστα (πρωτοεμφανιζόμενα) πρότυπα μπορεί να είναι απογοητευτική λόγω της μη αντιπροσωπευτικής αναπαράστασης του χώρου από τη δομή και το σύνολο των βαρών. Το ίδιο συμβαίνει επίσης στην περίπτωση όπου η διαδικασία εκπαίδευσης συνεχίζεται πέρα από το όριο όπου έχει επιτευχθεί επαρκής αναπαράσταση του χώρου και από εκεί και πέρα ο ταξινομητής εκπαιδεύεται με βάση τα λεπτομερειακά χαρακτηριστικά των συγκεκριμένων προτύπων του συνόλου εκπαίδευσης, σε αντίστοιχο κόστος στην ικανότητα γενίκευσης και στην γενική απόδοση του ταξινομητή. Η κατάσταση

αυτή είναι σαφώς μη επιθυμητή και χαρακτηρίζεται ως υπερ-εκπαίδευση (over-training).

Για την αποφυγή φαινομένων υπερ-εκπαίδευσης, καθώς επίσης και την παρακολούθηση της ικανότητας γενίκευσης του νευρωνικού ταξινομητή, έχουν προταθεί διάφορες τεχνικές που αποτελούν ουσιαστικά παραλλαγές της γενικότερης μεθοδολογίας διαχωρισμού του διαθέσιμου συνόλου προτύπων σε σύνολα εκπαίδευσης και σύνολα αξιολόγησης. Κλασικά παραδείγματα των τεχνικών αυτών αποτελεί ο αλγόριθμος Leave-One-Out (LOO) που περιγράφεται αναλυτικά σε επόμενη ενότητα. Στην περίπτωση των νευρωνικών δικτύων ο σχετικά μεγάλος χρόνος σύγκλισης δεν επιτρέπει την εφαρμογή αναλυτικών μεθόδων όπως η μέθοδος LOO, μια και έτσι ο απαιτούμενος χρόνος για την ολοκλήρωση της διαδικασίας εκπαίδευσης θα πολλαπλασιαζόταν με τάξη μεγέθους ίση με το πλήθος των διαθέσιμων προτύπων. Αντί αυτού, μια άλλη εξίσου αποτελεσματική τεχνική χρησιμοποιείται ευρύτατα στην εκπαίδευση νευρωνικών δικτύων και είναι γνωστή ως Leave-Half-Out (LHO) ή Cross-Validation. Σύμφωνα με την τεχνική αυτή, το σύνολο των διαθέσιμων προτύπων διαμερίζεται με τυχαίο τρόπο σε δύο ίσα σύνολα. Το πρώτο ονομάζεται σύνολο εκπαίδευσης και χρησιμοποιείται για τη σχεδίαση του ταξινομητή και το δεύτερο ονομάζεται σύνολο αξιολόγησης και χρησιμοποιείται για τη μέτρηση της απόδοσης του ταξινομητή σε άγνωστα πρότυπα. Η βασική ιδέα είναι η διαδικασία εκπαίδευσης να ακολουθείται από μια φάση αξιολόγησης με άγνωστα πρότυπα, έτσι ώστε να μετρηθεί η ικανότητα γενίκευσης και η πραγματική απόδοση του ταξινομητή [25].

Εναλλακτικά, κάθε κύκλος εκπαίδευσης μπορεί να ακολουθείται από ένα κύκλο αξιολόγησης για την μέτρηση της τρέχουσας απόδοσης του ταξινομητή. Με τον τρόπο αυτό είναι εύκολος ο έλεγχος και η διακοπή της διαδικασίας εκπαίδευσης όταν έχει επιτευχθεί ο μέγιστος βαθμός γενίκευσης, και παράλληλα εξάλειψη του κινδύνου της υπερ-εκπαίδευσης του δικτύου. Ακόμα καλύτερα αποτελέσματα επιτυγχάνονται όταν υπάρχει φάση αξιολόγησης, τόσο κατά τη διάρκεια, όσο και μετά την ολοκλήρωση της διαδικασίας εκπαίδευσης. Συχνά για να περιοριστεί ο απαιτούμενος χρόνος ολοκλήρωσης της εκπαίδευσης, χρησιμοποιείται ένα μικρό σύνολο αξιολόγησης σε κάθε κύκλο εκπαίδευσης, το οποίο συχνά ονομάζεται σύνολο επικύρωσης, ενώ η τελική αξιολόγηση γίνεται με άλλο μεγαλύτερο σύνολο που δίνει μια καλή εκτίμηση για το βαθμό αξιοπιστίας στον ταξινομητή [15]. Τεχνικές αυτού του τύπου εφαρμόζονται κατά κόρο σε εφαρμογές όπου τα στατιστικά χαρακτηριστικά του χώρου των προτύπων είναι άγνωστα ή όταν τα διαθέσιμα σύνολα εκπαίδευσης είναι σχετικά περιορισμένα σε μέγεθος και ανεπαρκή για την πλήρη περιγραφή του.

Αξίζει να σημειωθεί πως ο συνδυασμός φάσεων τροποποίησης και αξιολόγησης του νευρωνικού δικτύου κατά τη διαδικασία εκπαίδευσης δίνει τη δυνατότητα συνεχούς παρακολούθησης της απόδοσης του ταξινομητή, καλύτερου ελέγχου της διαδικασίας και περισσότερο βέλτιστη επιλογή της τελικής διαμόρφωσης. Συχνά η διαδικασία εκπαίδευσης ενσωματώνει αυτόματους μηχανισμούς καταγραφής και διατήρησης της βέλτιστης διαμόρφωσης του δικτύου, καθώς διαμορφώνεται διαμέσου των εκπαιδευτικών κύκλων. Έτσι μετά την ολοκλήρωση της εκπαίδευσης είναι εύκολη η επιλογή της διαμόρφωσης που δίνει την βέλτιστη απόδοση. Αυτή η τεχνική χρησιμοποιήθηκε

για τη σχεδίαση και αξιολόγηση όλων των διαμορφώσεων των ταξινομητών νευρωνικών δικτύων στην παρούσα εργασία.

Αν και οι όλες οι παραπάνω τεχνικές είναι ιδιαίτερα χρήσιμες για τη βελτίωση της ποιότητας της διαδικασίας εκπαίδευσης, παρόλα αυτά παραμένει το πρόβλημα του καθορισμού της τοπολογίας του δικτύου. Για την αντιμετώπιση του συγκεκριμένου ζητήματος έχουν δημοσιευτεί αναρίθμητα άρθρα και εργασίες με σκοπό την διατύπωση κάποιας μεθοδολογίας αυτόματης επιλογής του πλήθους και του μεγέθους των νευρωνικών επιπέδων στο δίκτυο. Το στοιχείο που αξίζει να σημειωθεί εδώ είναι ότι, αν και ο συνολικός αριθμός βαρών στο δίκτυο σχετίζεται έμμεσα με το πλήθος των προτύπων εκπαίδευσης, η ακριβής διάταξη και διασύνδεση των νευρώνων στο δίκτυο αποτελούν επιπλέον ελεύθερες παραμέτρους για το σύστημα, που δεν σχετίζονται με κανένα τρόπο ούτε με το σύνολο εκπαίδευσης, ούτε με τη δομή και τη λειτουργία του αλγορίθμου εκπαίδευσης. Σε κάθε περίπτωση όμως η τοπολογία και η δομή του δικτύου επηρεάζει δραματικά την πολυπλοκότητα και το βαθμό σύγκλισης της διαδικασίας εκπαίδευσης.

Στις περισσότερες περιπτώσεις η επιλογή της τοπολογίας του δικτύου αποτελεί έναν από τους δυσκολότερους και ταυτόχρονα πιο κρίσιμους παράγοντες για την επιτυχία του νευρωνικού δικτύου. Για πολυεπίπεδα δίκτυα τύπου perceptron και αλγόριθμο εκπαίδευσης Back-Propagation έχουν διατυπωθεί κάποιοι εμπειρικοί κανόνες που συνδέουν το μέγεθος των ακραίων επιπέδων (εισόδου, εξόδου) με το μέγεθος των κρυμμένων επιπέδων. Το μέγεθος των ακραίων επιπέδων μπορεί να καθοριστεί εν μέρει από τη φύση του προβλήματος και συγκεκριμένα από τη διάσταση των διανυσμάτων εισόδου και εξόδου. Για δίκτυα με τρία συνολικά νευρωνικά επίπεδα, το μέγεθος του μοναδικού κρυμμένου επιπέδου συχνά καθορίζεται είτε ως η μέση τιμή των δύο μεγεθών, είτε ως η τετραγωνική ρίζα του συνολικού πλήθους των βαρών στο δίκτυο. Τα επίπεδα σχεδόν πάντα θεωρούνται πλήρως διασυνδεδεμένα, δηλαδή όλες οι εξοδοί του ενός επιπέδου οδηγούνται ως είσοδοι σε όλους τους νευρώνες του επόμενου επιπέδου. Η απενεργοποίηση κάποιας διασύνδεσης πραγματοποιείται απλά με το μηδενισμό της τιμής του αντίστοιχου βάρους.

Σε μια προσπάθεια αυτοματοποίησης της διαδικασίας καθορισμού της τοπολογίας του νευρωνικού δικτύου έχουν προταθεί διάφορες τεχνικές, οι οποίες μπορούν γενικά να κατηγοριοποιηθούν σε μεθόδους αύξησης και μεθόδους μείωσης της τοπολογίας. Στην πρώτη περίπτωση ο αλγόριθμος ξεκινά από μια ελάχιστη τοπολογία και προχωρά αυξάνοντας διαδοχικά την έκταση και την πολυπλοκότητά της. Αντίθετα, στη δεύτερη περίπτωση ο αλγόριθμος ξεκινά από μια μέγιστη τοπολογία και προχωρά μειώνοντας διαδοχικά την έκταση και την πολυπλοκότητά της. Η καταλληλότητα κάθε μιας από αυτές εξαρτάται από το εκάστοτε πρόβλημα και τις απαιτήσεις σε ότι αφορά την απόδοση του τελικού ταξινομητή.

Η αύξηση ή η μείωση της τοπολογίας του δικτύου μπορεί να γίνεται σε επίπεδο πλήθους βαρών (διασυνδέσεων), πλήθους νευρώνων ή πλήθους νευρωνικών επιπέδων. Η δυσκολία έγκειται κυρίως στο γεγονός ότι η επιμέρους εκτέλεση της διαδικασίας επιλογής τοπολογίας και της διαδικασίας εκπαίδευσης δημιουργεί πρακτικά μεγάλο κόστος ως προς το συνολικό χρόνο και την πολυπλοκότητα της σχεδίασης του ταξινομητή. Συχνά ο καθορισμός της


τοπολογίας συνδυάζεται με την εκπαίδευση του δικτύου για λόγους οικονομίας, κάτι που οδηγεί σε υποβέλτιστες λύσεις. Σε εφαρμογές όμως όπου δεν μπορεί να γίνει καλή αρχική εκτίμηση της τοπολογίας, οποιαδήποτε αυτόματη μέθοδος είναι ιδιαίτερα χρήσιμη.

Μια από τις πιο γνωστές μεθόδους αναζήτησης μιας ελάχιστης τοπολογίας είναι η επιλεκτική καταστροφή τμημάτων του δικτύου (pruning) [30]. Μετά την ολοκλήρωση της εκπαίδευσης, η μέθοδος αναζητά βάρη των οποίων οι τιμές είναι σχετικά κοντά στο μηδέν, κάτι που υποδεικνύει ότι οι συγκεκριμένες συνδέσεις είναι ασήμαντες για την απόδοση του δικτύου. Ανάλογα με την ανοχή σφάλματος στην έξοδο, καταστρέφονται επιλεκτικά με αυτό τον τρόπο διασυνδέσεις νευρώνων, δίνοντας τελικά μια απλούστερη δομή για την τοπολογία του δικτύου. Ακριβώς το αντίθετο μπορεί να εφαρμοστεί με αυξητικές μεθόδους, ξεκινώντας από μικρές τοπολογίες και προσθέτοντας συνεχώς βάρη ή ολόκληρους νευρώνες με σκοπό τη βελτίωση της απόδοσης του δικτύου. Οι πιο σύγχρονες τεχνικές χρησιμοποιούν γενετικούς αλγορίθμους για τη σταδιακή ανάπτυξη και βελτιστοποίηση της τοπολογίας [17]. Αν και συχνά αποδεικνύονται χρήσιμες σε πρακτική χρήση, παρόλα αυτά το βασικό μειονέκτημα των αυτοματοποιημένων μεθόδων είναι το γεγονός ότι δύσκολα αποσυνδέονται από τον ίδιο τον αλγόριθμο εκπαίδευσης και κατά συνέπεια η εφαρμογή τους σε ευρεία κλίμακα αρχιτεκτονικών νευρωνικών δικτύων παραμένει μέχρι σήμερα προβληματική.

## 1.6 Μεθοδολογία

Στις προηγούμενες ενότητες περιγράφηκε αναλυτικά η δομή και τα χαρακτηριστικά δύο από τις βασικότερες κατηγορίες ταξινομητών που χρησιμοποιούνται σε προβλήματα αναγνώρισης προτύπων. Στην παρούσα ενότητα θα περιγραφούν οι μέθοδοι και η διαδικασία που εφαρμόζεται για την πρακτική εφαρμογή τους στην περίπτωση ανάλυσης ιατρικής εικόνας.

Προτού είναι δυνατή η εφαρμογή του εκάστοτε αλγορίθμου εκπαίδευσης του ταξινομητή, είναι απαραίτητο τα αρχικά δεδομένα του προβλήματος, δηλαδή η ψηφιοποιημένη ιατρική εικόνα, να μετασχηματιστεί σε ένα σύνολο ποσοτικών χαρακτηριστικών με τη μορφή εκπαιδευτικών προτύπων [03]. Η διαδικασία αυτή είναι τυπική για όλα τα προβλήματα αναγνώρισης προτύπων και αποτελείται από τρία επιμέρους στάδια: την δημιουργία των χαρακτηριστικών, την επιλογή των πιο αποτελεσματικών ως προς τη διαχωριστική τους ικανότητα, και την ομαδοποίησή τους για την κατασκευή των εκπαιδευτικών συνόλων για τους αλγορίθμους εκπαίδευσης.



**Σχήμα 1.11:** Γενική μεθοδολογία σχεδίασης ταξινομητή

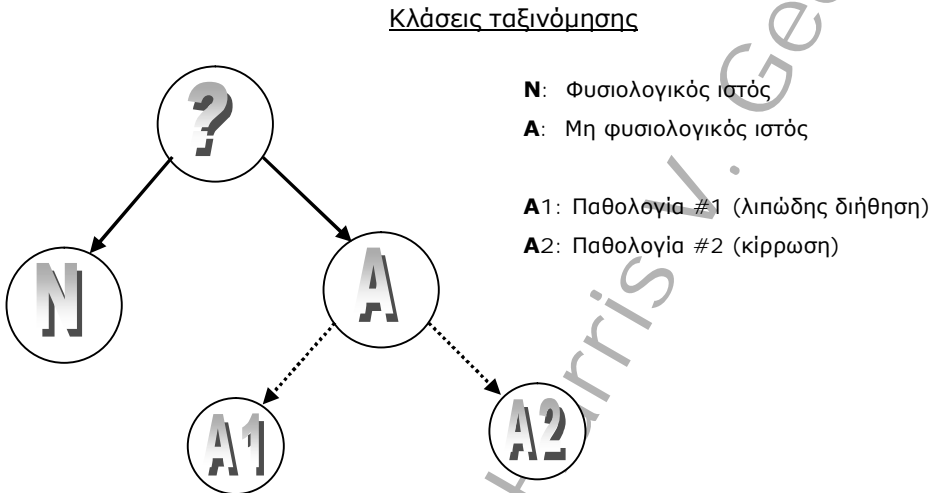
#### 1.6.1 Δημιουργία Χαρακτηριστικών (Feature Generation)

Ο όρος χαρακτηριστικό (feature) χρησιμοποιείται για να καθορίσει κάθε ποσοτική πληροφορία η οποία εξάγεται με τη μορφή αριθμητικής τιμής από τα δεδομένα της αρχικής εικόνας σε κάποια συγκεκριμένη περιοχή ενδιαφέροντος (region of interest – ROI). Η έκταση της υποπεριοχής εξαρτάται από τον τύπο και τις ιδιότητες της εικόνας και της παθολογίας που εξετάζεται. Σε κάθε περίπτωση, ο ακριβής καθορισμός των διαστάσεων ενδιαφέροντος θα πρέπει να είναι τέτοιος ώστε να μην αναδεικνύει μακροσκοπικά δομικά χαρακτηριστικά της ίδιας της εικόνας ως σύνολο, όπως για παράδειγμα η απεικόνιση οστών ή κεντρικών αρτηριών, που μπορεί να επηρεάσουν τη διαχωριστική ικανότητα των διαθέσιμων χαρακτηριστικών [02].

Στην περίπτωση της ανάλυσης υπερηχογραφικών εικόνων ήπατος, η περιοχή μελέτης είναι μικρές υποπεριοχές όπου εστιάζεται η εξέταση για πιθανή παθολογία του ιστού. Γενικά αναφέρεται σε τετραγωνικές εκτάσεις της ψηφιοποιημένης εικόνας με διαστάσεις από μερικά κλάσματα του χιλιοστού μέχρι μερικά χιλιοστά. Σε ιατρικές εφαρμογές για την ανάλυση παρόμοιων εικόνων, η περιοχή ενδιαφέροντος που χρησιμοποιείται στην πράξη είναι διαστάσεων από 0,2mm (5x5 pixels) ως 0,4mm (10x10 pixels) [05].

Στο υπό μελέτη πρόβλημα, αρχικά δεδομένα αποτελούν οι ψηφιοποιημένες υπερηχογραφικές τύπου B-scan εικόνες ανθρώπινου ήπατος, με διαστάσεις 256x256 pixels και βάθος απεικόνισης 256 επίπεδα τόνων του γκρι (256-grayscale). Οι παθολογίες που εξετάζονται, σε σχέση με φυσιολογικό ηπατικό ιστό, είναι η λιπώδης διήθηση και η κίρρωση. Η λιπώδης διήθηση προκαλεί μεγαλύτερο ίχνος αντανάκλασης του ηχητικού σήματος, με αποτέλεσμα να εμφανίζεται ως περιοχή με μεγαλύτερη φωτεινότητα στην υπερηχογραφική εικόνα σε σχέση με τον φυσιολογικό ιστό. Αντίθετα η κίρρωση αντιστοιχεί σε κατεστραμμένο ιστό που προκαλεί μικρότερη αντανάκλαση του ηχητικού σήματος, με αποτέλεσμα να εμφανίζεται ως περιοχή με μικρότερη φωτεινότητα

στην υπερηχογραφική εικόνα σε σχέση με τον φυσιολογικό ιστό. Οι δύο αυτές διαφοροποιήσεις είναι αρκετές για τη διαπίστωση παθογένειας, όσο αφορά στους δύο συγκεκριμένους τύπους, από έναν εξειδικευμένο ιατρό. Αυτός είναι και ο στόχος για το σύστημα αυτόματης διάγνωσης που υλοποιεί ο κάθε ταξινομητής που υλοποιείται μέσω υπολογιστή.



**Σχήμα 1.12:** Κατηγοριοποίηση παθολογιών

Για την εξαγωγή ποσοτικών δεδομένων για κάθε παρόμοια υπό μελέτη περιοχή ενδιαφέροντος (ROI) χρησιμοποιούνται συναρτήσεις εξαγωγής χαρακτηριστικών παραμέτρων που αναδεικνύουν συγκεκριμένες ιδιότητες των δεδομένων της εικόνας. Οι ιδιότητες αυτές θα πρέπει να είναι τέτοιες ώστε να αναδεικνύουν τις διαφοροποιήσεις μεταξύ φυσιολογικού και παθολογικού ιστού, όπως εμφανίζεται σε κάθε περίπτωση στην ψηφιοποιημένη εικόνα. Τέσσερις είναι οι βασικές κατηγορίες τεχνικών που εφαρμόζονται για το σκοπό αυτό [01].

Η πρώτη κατηγορία μεθόδων ασχολείται με την εξαγωγή χαρακτηριστικών παραμέτρων της κατανομής των τιμών των τόνων του γκρι, όπως εμφανίζεται στο ιστόγραμμα της περιοχής ενδιαφέροντος (ROI). Οι παράμετροι αυτές, γνωστές και ως στατιστικές πρώτης τάξης (1<sup>st</sup> order statistics) περιλαμβάνουν την μέση τιμή και τη διακύμανση του ιστογράμματος, καθώς επίσης την κλίση και την κύρτωση της κατανομής [01]. Η δεύτερη κατηγορία ασχολείται με την ποσοτική περιγραφή της υφής (texture) των δεδομένων της περιοχής ενδιαφέροντος, κυρίως σε σχέση με τη χωρική διακύμανση των τιμών του γκρι, και το σύνολο των παραμέτρων που παρέχει συχνά αναφέρεται ως στατιστικές δεύτερης τάξης (2<sup>nd</sup> order statistics). Η περιγραφή αυτή συνήθως επικεντρώνεται γύρω από ένα σύνολο συναρτήσεων που αναφέρονται σε ιδιότητες του αντίστοιχου μητρώου χωρικής εξάρτησης (spatial dependence

matrix – SDM) ή του μητρώου διαδοχικής εμφάνισης (run-length matrix – RLM) των τιμών του γκρι εντός της περιοχής ενδιαφέροντος. Μια σειρά τέτοιων συναρτήσεων έχουν προταθεί στη βιβλιογραφία με σκοπό την ανάδειξη χαρακτηριστικών που ταιριάζουν κάθε φορά στο εκάστοτε πρόβλημα ανάλυσης εικόνας [01, 02, 04, 05, 06, 07, 08]. Συναρτήσεις που βασίζονται στο μητρώο SDM αναφέρονται ως χαρακτηριστικά χωρικής συσχέτισης της κλίμακας αποχρώσεων του γκρι, ενώ συναρτήσεις που βασίζονται στο μητρώο RLM αναφέρονται ως χαρακτηριστικά χωρικής διακύμανσης της κλίμακας αποχρώσεων του γκρι. Τέλος, έχουν προταθεί τεχνικές που εφαρμόζονται άμεσα στο φάσμα ισχύος του δύο διαστάσεων σήματος της εικόνας.

Όπως είναι φυσικό, όλες οι παραπάνω μέθοδοι εξαρτώνται από το μέγεθος, τη μορφή και το σχήμα της περιοχής ενδιαφέροντος, καθώς επίσης και από το βάθος της κλίμακας τόνων του γκρι που χρησιμοποιείται στην ψηφιοποιημένη εικόνα. Πάντως είναι γενικά αποδεκτό πως τεχνικές που περιλαμβάνουν συναρτήσεις υφής (στατιστικές δεύτερης τάξης) παρέχουν περισσότερη πληροφορία σε σχέση με τεχνικές που αναφέρονται στο ιστόγραμμα (στατιστικές πρώτης τάξης), και είναι αυτές που δίνουν πολύ καλά αποτελέσματα σε προβλήματα ανάλυσης ιατρικής εικόνας [08].

Στο λογισμικό της παρούσας εργασίας χρησιμοποιήθηκαν χαρακτηριστικές παράμετροι πρώτης και δεύτερης τάξης για να διαπιστωθεί, εκτός της απόδοσης των δύο εφαρμοζόμενων ταξινομητών (ελάχιστης απόστασης και νευρωνικό δίκτυο), η σχετική διαχωριστική ικανότητα που προσφέρεται από κάθε μια ξεχωριστά και σε συνδυασμό. Οι παρακάτω εξισώσεις περιγράφουν αναλυτικά το σύνολο των συναρτήσεων που χρησιμοποιήθηκαν για την κατασκευή των χαρακτηριστικών παραμέτρων σε κάθε δείγμα (ROI) της ψηφιοποιημένης υπερηχογραφικής εικόνας. Το αρχικό σύνολο εκπαίδευσης που κατασκευάζεται κατά τη φάση της δημιουργίας χαρακτηριστικών περιλαμβάνει όλες τις τιμές των αντίστοιχων συναρτήσεων για κάθε δείγμα, ενώ το εκπαιδευτικό πρότυπο που σχηματίζεται καθορίζεται εκ των προτέρων ως φυσιολογικό (φυσιολογικού ιστού) ή παθογενές (παθογένειας τύπου λιπώδους διήθησης ή κίρρωσης).

1. Συνολική κατανομή κλίμακας αποχρώσεων (gray levels) [01] – στατιστικές παράμετροι 1ης τάξης: mean, variance, skewness, kurtosis:

$$g_{ave} = \frac{1}{N} \sum_{(i,j) \in R} g(i, j) \quad [1.17]$$

$$g_{var} = \frac{1}{N} \sum_{(i,j) \in R} [g(i, j) - g_{ave}]^2 \quad [1.18]$$

$$g_{skew} = \frac{\frac{1}{N} \sum_{(i,j) \in R} [g(i,j) - g_{ave}]^3}{\left[ \sqrt{\sum_{(i,j) \in R} [g(i,j)^2 - g_{ave}^2]} \right]^3} \quad [1.19]$$

$$g_{curt} = \frac{\frac{1}{N} \sum_{(i,j) \in R} [g(i,j) - g_{ave}]^4}{\left[ \sqrt{\sum_{(i,j) \in R} [g(i,j)^2 - g_{ave}^2]} \right]^4} \quad [1.20]$$

2. Χωρική συσχέτιση κλίμακας αποχρώσεων (gray levels) [04] – στατιστικές παράμετροι 2ης τάξης: angular second moment, contrast, correlation, sum of squares, inverse difference moment, sum average, sum variance, sum entropy, entropy, difference variance, difference entropy:

$$f_{asm} = \sum_{i=1}^{Ng} \sum_{j=1}^{Ng} p(i,j)^2 \quad [1.21]$$

$$f_{contrast} = \sum_{n=0}^{Ng-1} n^2 \left[ \sum_{i=1}^{Ng} \sum_{j=1}^{Ng} p(i,j) \right]_{|i-j|=n} \quad [1.22]$$

$$f_{corrl} = \frac{\left[ \sum_{i=1}^{Ng} \sum_{j=1}^{Ng} (ij) p(i,j) \right] - \mu_x \mu_y}{\sigma_x \sigma_y} \quad [1.23]$$

$$f_{sqsum} = \sum_i \sum_j (i - \mu)^2 p(i,j) \quad [1.24]$$

$$f_{idm} = \sum_i \sum_j \frac{1}{1 + (i - j)^2} p(i,j) \quad [1.25]$$



$$f_{sumavg} = \sum_{i=2}^{2Ng} i p_{x+y}(i) \quad [1.26]$$

$$f_{sumvar} = \sum_{i=2}^{2Ng} (i - f_{sumavg})^2 p_{x+y}(i) \quad [1.27]$$

$$f_{sument} = - \sum_{i=2}^{2Ng} p_{x+y}(i) \log(p_{x+y}(i)) \quad [1.28]$$

$$f_{ent} = - \sum_i \sum_j p(i, j) \log(p(i, j)) \quad [1.29]$$

$$f_{diffvar} = \sum_{i=0}^{Ng-1} (i - f_{sumavg})^2 p_{x-y}(i) \quad [1.30]$$

$$f_{diffent} = - \sum_{i=0}^{Ng-1} p_{x-y}(i) \log(p_{x-y}(i)) \quad [1.31]$$

3. Χωρική διακύμανση κλίμακας αποχρώσεων (gray levels) [06] – (α) υπολογισμός run-lengths, (β) στατιστικά χαρακτηριστικά: short runs emphasis, long runs emphasis, gray level non-uniformity, run length non-uniformity, run percentage:

$$f_{sre} = \frac{\sum_{i=1}^{Ng} \sum_{j=1}^{Nr} \frac{r(i, j)}{j^2}}{\sum_{i=1}^{Ng} \sum_{j=1}^{Nr} r(i, j)} \quad [1.32]$$

$$f_{lre} = \frac{\sum_{i=1}^{Ng} \sum_{j=1}^{Nr} j^2 r(i, j)}{\sum_{i=1}^{Ng} \sum_{j=1}^{Nr} r(i, j)} \quad [1.33]$$

$$f_{gnu} = \frac{\sum_{i=1}^{Ng} \left( \sum_{j=1}^{Nr} r(i, j) \right)^2}{\sum_{i=1}^{Ng} \sum_{j=1}^{Nr} r(i, j)} \quad [1.34]$$

$$f_{gnu} = \sum_{j=1}^{N_g} \left( \sum_{i=1}^{N_r} r(i, j) \right)^2 / \sum_{i=1}^{N_g} \sum_{j=1}^{N_r} r(i, j) \quad [1.35]$$

$$f_{rpc} = \sum_{i=1}^{N_g} \sum_{j=1}^{N_r} r(i, j) / (N_g N_r) \quad [1.36]$$

Όπου:

$N_g$  = κλίμακα αποχρώσεων γκρι

$N_r$  = εύρος τιμών για run lengths (max)

$g(i, j)$  = τρέχουσα τιμή απόχρωσης

$p(i, j)$  = τιμή στο μητρώο χωρικής συσχέτισης αποχρώσεων γκρι (SDM:  $\{N_g \times N_g\}$ )

$r(i, j)$  = τιμή στο μητρώο χωρικής διακύμανσης αποχρώσεων γκρι (RLM:  $\{N_g \times N_r\}$ )

$$p_x(i) = \sum_{j=1}^{N_g} p(i, j) \quad p_y(j) = \sum_{i=1}^{N_g} p(i, j)$$

$$p_{x+y}(k) = \sum_{i=1}^{N_g} \sum_{j=1}^{N_g} p(i, j) \quad , i+j=k, k=2,3,\dots,2N_g$$

$$p_{x-y}(k) = \sum_{i=1}^{N_g} \sum_{j=1}^{N_g} p(i, j) \quad , |i-j|=k, k=0,1,\dots,N_g-1$$

**Εξισώσεις 1.17-1.36:** Στατιστικές 1<sup>ης</sup> τάξης (1.17-1.20) και στατιστικές συναρτήσεις SDM (1.21-1.31), RLM (1.32-1.36) χαρακτηριστικών παραμέτρων

#### 1.6.2 Επιλογή Χαρακτηριστικών – Feature Reduction

Η χρησιμοποίηση όλων των διαθέσιμων χαρακτηριστικών για την εκπαίδευση των ταξινομητών προκαλεί τεράστιες απαιτήσεις σε χρόνο επεξεργασίας και είναι συχνά ανέφικτη λόγω του μεγάλου πλήθους των διαθέσιμων συναρτήσεων εξαγωγής τους. Αν και ο υπολογισμός τους γίνεται μία φορά κατά την κατασκευή του αρχικού συνόλου εκπαίδευσης, η διερεύνηση συνδυασμών τους για την εκπαίδευση όσο το δυνατό αποτελεσματικότερων ταξινομητών είναι

ουσιαστικά ανέφικτη ακόμα και για μικρό πλήθος συνιστώσων. Για το λόγο αυτό είναι απαραίτητη η επιλογή των πιο αποτελεσματικών και απορριψη των υπόλοιπων, πριν την ομαδοποίησή τους για το σχηματισμό εκπαιδευτικών συνόλων για διάφορες διαμορφώσεις ταξινομητών.

Επειδή το κόστος αναλυτικής διερεύνησης της αποδοτικότητάς τους μέσω σχεδίασης αντίστοιχων ταξινομητών για κάθε ένα από αυτά ξεχωριστά είναι μεγάλο λόγω του πλήθους τους, διάφορες τυπικές τεχνικές ελέγχου εφαρμόζονται για τη διερεύνηση της στατιστικής τους εξάρτησης σε σχέση με την διαχωριστική τους ικανότητα ως προς τις κλάσεις ταξινόμησης. Δύο τεχνικές που εφαρμόζονται ευρύτατα στην πράξη είναι το T-test και το F-test, όπου εξετάζεται ξεχωριστά η στατιστική εξάρτηση των τιμών κάθε χαρακτηριστικού των προτύπων εκπαίδευσης με την αντίστοιχη κλάση ταξινόμησης [32]. Σύμφωνα με κάποιο επίπεδο σημαντικότητας στις αντίστοιχες στατιστικές κατανομές και βαθμούς ελευθερίας που ορίζονται από το πλήθος των διαθέσιμων εκπαιδευτικών προτύπων, ορίζεται ένα κάτω όριο σχετικά με την στατιστική τιμή σε κάθε δοκιμή. Έτσι, χαρακτηριστικά τα οποία εμφανίζουν υψηλή εξάρτηση με τις κλάσεις ταξινόμησης θεωρούνται ως σημαντικά και διατηρούνται, ενώ χαρακτηριστικά τα οποία εμφανίζουν χαμηλή εξάρτηση με τις κλάσεις ταξινόμησης θεωρούνται ως μη σημαντικά και απορρίπτονται [05, 07, 10, 32].

$$t_{\pi} = \frac{|\bar{x}_1 - \bar{x}_2|}{\sigma} \sqrt{\frac{v_1 v_2}{v_1 + v_2}}, \quad \sigma = \frac{\sigma_1^2 (v_1 - 1) + \sigma_2^2 (v_2 - 1)}{v_1 + v_2 - 2}$$

[1.37-1.38]

$$D_f = v_1 + v_2 - 2$$

$$t_n > f_t(a, D_f) \Rightarrow \text{significant (non-random) statistical difference}$$

### Εξισώσεις 1.37-1.38: Εξισώσεις και έλεγχοι T-test

Τα πρότυπα στο νέο σύνολο εκπαίδευσης περιλαμβάνουν μονάχα τις συνιστώσες των χαρακτηριστικών που προσφέρουν υψηλή κατά το δυνατό διαχωριστική ικανότητα στον ταξινομητή, ανεξάρτητα από την μεθοδολογία και τη δομή που πρόκειται να χρησιμοποιηθεί για την υλοποίησή του σε επόμενα στάδια. Φυσικά, η διαχωριστική ικανότητα εξαρτάται άμεσα από τις ιδιότητες που αναδεικνύονται από τις αντίστοιχες συναρτήσεις υπολογισμού των χαρακτηριστικών και της αποτελεσματικότητάς τους στην εκάστοτε εφαρμογή. Η διαχωριστική ικανότητα συνδυασμών χαρακτηριστικών είναι δυνατό να διερευνηθεί μέσω τεχνικών πολυδιάστατης στατιστικής ανάλυσης, το κόστος όμως εφαρμογής τους είναι τις περισσότερες φορές συγκρίσιμο με αυτό της σχεδίασης και αξιολόγησης ολόκληρου του ταξινομητή με τη συγκεκριμένη διαμόρφωση και κατά συνέπεια σπάνια χρησιμοποιούνται στην πράξη [05].

### 1.6.3 Ομαδοποίηση Χαρακτηριστικών – Feature Selection

Έχοντας καταλήξει σε ένα σύνολο χαρακτηριστικών με σχετικά καλή διαχωριστική ικανότητα, το επόμενο και τελευταίο στάδιο επεξεργασίας, πριν την ίδια τη διαδικασία εκπαίδευσης των ταξινομητών, αποτελεί η φάση της ομαδοποίησής τους σε υποσύνολα, για την κατασκευή αντίστοιχων διαμορφώσεων εκπαίδευσης.

Για την επιλογή βέλτιστης διαμόρφωσης για τον ταξινομητή είναι απαραίτητη η διερεύνηση όλων των πιθανών συνδυασμών χαρακτηριστικών, δηλαδή στη σχεδίαση και εκπαίδευση του ταξινομητή με βάση όλα τα πιθανά υποσύνολα εκπαίδευσης, όσο αφορά στη διάσταση των διανυσμάτων εισόδου των προτύπων και τα συγκεκριμένα χαρακτηριστικά που περιλαμβάνουν. Θεωρητικά μια τέτοια προσέγγιση δίνει πιθανούς συνδυασμούς χαρακτηριστικών της τάξης του  $O(N!)$ , όπου  $N$  είναι το διαθέσιμο πλήθος χαρακτηριστικών που επιλέχθηκαν κατά την προηγούμενη φάση. Όμως, ακόμα σε περιπτώσεις όπου λίγα χαρακτηριστικά είναι διαθέσιμα, το πλήθος όλων των πιθανών συνδυασμών είναι συχνά απαγορευτικό για την αναλυτική σύγκριση μέσω εκπαίδευσης και αξιολόγησης κάθε αντίστοιχου ταξινομητή. Σε παρόμοιες περιπτώσεις τα διαθέσιμα χαρακτηριστικά ομαδοποιούνται με βάση κάποια ελάχιστα και μέγιστα όρια για τη διάσταση του διανύσματος εισόδου, ανάλογα με την πολυπλοκότητα του προβλήματος και τη δομή του ταξινομητή. Έτσι, για διαμορφώσεις βασισμένες σε συνδυασμούς  $K$  χαρακτηριστικών από τα  $N$  διαθέσιμα, τα αντίστοιχα εκπαιδευτικά σύνολα που θα πρέπει να κατασκευαστούν είναι της τάξης  $O(N^K)$ .

Για την αξιολόγηση της αποτελεσματικότητας κάθε πιθανής διαμόρφωσης εκτελείται αναλυτικά η διαδικασία εκπαίδευσης του ταξινομητή με το αντίστοιχο σύνολο εκπαίδευσης. Το εκάστοτε σύνολο εκπαίδευσης περιλαμβάνει όλα τα πρότυπα από το σύνολο που κατασκευάστηκε μετά την επιλογή αποτελεσματικών χαρακτηριστικών που έγινε κατά την προηγούμενη φάση, έχοντας όμως διανύσματα εισόδου διάστασης  $d$  με:  $K_{\min} \leq d \leq K_{\max}$  και συνιστώσες συνδυασμούς των διαθέσιμων χαρακτηριστικών. Για κάθε διάσταση πολλές διαμορφώσεις είναι διαθέσιμες και κάθε μία αξιολογείται ξεχωριστά για να διαπιστωθεί η αποτελεσματικότητα του αντίστοιχου συνδυασμού χαρακτηριστικών. Σε προβλήματα ανάλυσης υπερηχογραφικής εικόνας για διάγνωση λιπώδους διήθησης και κίρρωσης ήπατος, έχει παρατηρηθεί πειραματικά πως σε κάθε περίπτωση τέσσερα χαρακτηριστικά υψής είναι αρκετά για την σχεδίαση γραμμικών ταξινομητών ελάχιστης απόστασης [05].

Η διαδικασία αξιολόγησης του ταξινομητή πραγματοποιείται με τεχνικές και μεθόδους που ταιριάζουν στη δομή και την πολυπλοκότητά του. Η βασική μεθοδολογία συνίσταται στο διαδοχικό διαχωρισμό του εκάστοτε συνόλου εκπαίδευσης σε υποσύνολα, από τα οποία άλλα χρησιμοποιούνται για την εκπαίδευση και άλλα για την αξιολόγηση του ταξινομητή. Τεχνικές αυτής της μορφής αναφέρονται ως  $k$ -fold cross validation και χρησιμοποιούνται ευρύτατα, τόσο για γραμμικές, όσο και για μη γραμμικές δομές ταξινομητών [33].

Στην περίπτωση που η δομή του ταξινομητή είναι σχετικά απλή και η εκπαίδευσή του δεν είναι ιδιαίτερα απαιτητική σε χώρο και χρόνο, μπορεί να εφαρμοστεί μια ειδική παραλλαγή της μεθόδου που διερευνά αναλυτικά όλα τα

Ν υποσύνολα με μέγεθος N-1 πρότυπα του συνόλου εκπαίδευσης, η οποία είναι γνωστή ως μέθοδος Leave-One-Out (LOO). Σύμφωνα με την τεχνική αυτή, σε κάθε σύνολο εκπαίδευσης επιλέγεται ένα πρότυπο που δεν λαμβάνεται υπόψη κατά τη φάση της σχεδίασης του ταξινομητή. Αφού η σχεδίαση ολοκληρωθεί χρησιμοποιώντας τα υπόλοιπα διανύσματα εκπαίδευσης, το «άγνωστο» πρότυπο παρουσιάζεται στον ταξινομητή. Αν η ταξινόμησή του γίνεται στη σωστή κατηγορία τότε υπολογίζεται ως επιτυχία, διαφορετικά ως αποτυχία. Η διαδικασία αυτή επαναλαμβάνεται για κάθε ένα από τα διανύσματα στο αρχικό σύνολο εκπαίδευσης, δίνοντας τελικά τόσες περιπτώσεις ταξινόμησης όσα και τα διανύσματα στο αρχικό σύνολο εκπαίδευσης. Η τελική απόδοση του ταξινομητή υπολογίζεται με βάση το ποσοστό των σωστών αποτελεσμάτων επί του συνολικού πλήθους των διανυσμάτων. Η συγκεκριμένη μέθοδος είναι ιδανική για γραμμικούς ταξινομητές, όπως ο MDC, όπου η σχεδίασή τους γίνεται με άμεσες και σχετικά όχι χρονοβόρες τεχνικές.

Σε περίπτωση που η δομή του ταξινομητή παρουσιάζει μεγάλη πολυπλοκότητα και για την εκπαίδευση χρησιμοποιούνται αλγόριθμοι που εφαρμόζουν επαναληπτικά σχήματα, η επιλογή της μεθόδου Leave-One-Out δεν είναι κατάλληλη, αφού και προκαλεί πολλαπλασιασμό του απαιτούμενου χρόνου ολοκλήρωσης της διαδικασίας εκπαίδευσης. Για δομές νευρωνικών δικτύων συχνά εφαρμόζονται τεχνικές Cross-validation με τη μορφή κάποιας παραλλαγής της μεθόδου Leave-Half-Out (LHO), όπως αναλύθηκε σε προηγούμενη ενότητα.

Ανεξάρτητα από τη δομή του ταξινομητή, η τελική αξιολόγηση, που γίνεται εφαρμόζοντας κάποια από τις δύο μεθόδους (LOO ή LHO), βασίζεται σε πίνακες αλήθειας που παρουσιάζουν τα αθροιστικά αποτελέσματα του κάθε ταξινομητή ξεχωριστά. Για δύο κλάσεις ταξινόμησης οι πίνακες αλήθειας έχουν τη μορφή μητρώου με διαστάσεις 2x2, όπου οι γραμμές αντιστοιχούν στις δύο κλάσεις ταξινόμησης που είναι γνωστές εκ των προτέρων για όλα τα πρότυπα εκπαίδευσης, ενώ οι στήλες στις δύο κλάσεις που δίνει ως αποτέλεσμα για κάθε πρότυπο ο ταξινομητής (classifier truth table). Σωστά αποτελέσματα αντιστοιχούν σε στοιχεία στη διαγώνιο του μητρώου, δηλαδή πρότυπα τα οποία είναι φυσιολογικά και ταξινομούνται ως φυσιολογικά (θέση: [1,1]), ή πρότυπα τα οποία είναι παθολογικά και ταξινομούνται ως παθολογικά (θέση: [2,2]). Αντίθετα, λανθασμένα αποτελέσματα αντιστοιχούν σε στοιχεία στη εκτός της διαγώνιου του μητρώου, δηλαδή πρότυπα τα οποία είναι φυσιολογικά και ταξινομούνται ως παθολογικά (θέση: [1,2]), ή πρότυπα τα οποία είναι παθολογικά και ταξινομούνται ως φυσιολογικά (θέση: [2,1]).

	Class-N(MDC)	Class-A(MDC)
Class-N(TRUE)	40	17
Class-A(TRUE)	13	30

$$\text{Correct\%} = \sum_{(i)} [c(i,i)] / \sum_{(i,j)} [c(i,j)] = 70\%$$

**Σχήμα 1.13:** Παράδειγμα πίνακα αλήθειας

Το συνολικό ποσοστό επιτυχίας του ταξινομητή αναφέρεται στο άθροισμα των σωστών αποτελεσμάτων, δηλαδή το άθροισμα των διαγώνιων στοιχείων, σε σχέση με το σύνολο των ταξινομήσεων, δηλαδή το άθροισμα όλων των στοιχείων του πίνακα αλήθειας. Η τελική αξιολόγηση του ταξινομητή βασίζεται συνήθως στο συνολικό ποσοστό επιτυχίας, αν και σε πολλές ιατρικές εφαρμογές οι περιπτώσεις εσφαλμένης ταξινόμησης είναι εξίσου σημαντική, κυρίως αναφορικά με πρότυπα παθολογικά που αναγνωρίζονται από το σύστημα ως φυσιολογικά (μη ανίχνευση παθογένειας) [17, 11].

Copyright (c) 2012, Harris V. Georgiou

## Μέρος – 2

### Περιγραφή Λογισμικού

#### 2.1 Ταξινομητές – Υλοποίηση

Για την ανάπτυξη και αξιολόγηση του συστήματος αυτόματης ανάλυσης υπερηχογραφικής εικόνας ήπατος, εφαρμόστηκαν δύο είδη ταξινομητών. Από την κατηγορία των γραμμικών ταξινομητών χρησιμοποιήθηκε ταξινομητής ελάχιστης απόστασης, ενώ από την κατηγορία των μη γραμμικών ταξινομητών χρησιμοποιήθηκε νευρωνικό δίκτυο τύπου πολυεπίπεδου perceptron (Multi-Layered Perceptron – MLP). Παρόλο που η δομή, η εκπαίδευση και η λειτουργία των ταξινομητών διαφέρουν πολύ μεταξύ τους, ο τρόπος εφαρμογής τους για την επίλυση τους συγκεκριμένου προβλήματος, δηλαδή του χαρακτηρισμού δειγμάτων ιστού στην εικόνα, είναι ουσιαστικά ο ίδιος.

Η επιλογή των δύο αυτών ταξινομητών έγινε με βάση τα αποτελέσματα σχετικών ερευνών που έχουν γίνει στο συγκεκριμένο πεδίο ανάλυσης ιατρικών εικόνων, καθώς και την αντίστοιχη καταγεγραμμένη εμπειρία σε εφαρμογές ανάλυσης εικόνας σε άλλα επιστημονικά πεδία, όπως τα Γεωγραφικά Συστήματα Πληροφοριών (Geographical Information Systems – GIS), η Οπτική Αναγνώριση Χαρακτήρων (Optical Character Recognition – OCR), κ.ά. [04, 06, 09, 20].

Παραλλαγές γραμμικών ταξινομητών ελάχιστης απόστασης έχουν εφαρμοστεί στην πράξη με αρκετή επιτυχία σε συστήματα GIS για το χαρακτηρισμό του τύπου του εδάφους μιας περιοχής με βάση αεροφωτογραφία ή δορυφορική απεικόνιση. Η ανάλυση ακολουθεί τις ίδιες αρχές με αυτές της ανάλυσης ιατρικής υπερηχογραφικής εικόνας, μια που και στις δύο περιπτώσεις το μεγαλύτερο ποσοστό πληροφορίας που εξάγεται από την ψηφιοποιημένη εικόνα βασίζεται σε χαρακτηριστικά της υφής σε διάφορες περιοχές ενδιαφέροντος. Μελέτες αξιολόγησης ταξινομητών αυτού του είδους σε ιατρικές εφαρμογές ανάλυσης εικόνας έχουν δείξει σε πειραματικό επίπεδο, τόσο τη δυσκολία κατασκευής αποτελεσματικών γραμμικών ταξινομητών αυτού του είδους, όσο και τη δυσκολία επιλογής χαρακτηριστικών με βέλτιστη διαχωριστική ικανότητα.

Η χρησιμοποίηση νευρωνικών δικτύων σε ιατρικές εφαρμογές ανάλυσης εικόνας είναι πολύ πιο περιορισμένος σε σχέση με γραμμικούς ταξινομητές, κυρίως λόγω της πολυπλοκότητας της δομής τους και του αλγορίθμου εκπαίδευσης. Παρόλα αυτά, νευρωνικοί ταξινομητές εμφανίζουν σημαντικά μεγαλύτερη απόδοση ως προς το τελικό ποσοστό επιτυχίας. Η περισσότερη διαδεδομένη αρχιτεκτονική νευρωνικών δικτύων στο συγκεκριμένο πεδίο



έρευνας είναι η MLP, ως καθολικό σύστημα προσέγγισης συναρτήσεων απεικόνισης μεταξύ των συνόλων εισόδου και εξόδου [20].

Λεπτομέρειες της δομής και της λειτουργίας του κάθε ταξινομητή, όπως χρησιμοποιήθηκε για την εξαγωγή των αποτελεσμάτων της παρούσας εργασίας, παρουσιάζονται παρακάτω. Αναλυτικές λεπτομέρειες υλοποίησης για τα αντίστοιχα προγράμματα που χρησιμοποιήθηκαν αναφέρονται σε επόμενη ενότητα, καθώς και στο αντίστοιχο παράρτημα τεκμηρίωσης του λογισμικού της εργασίας.

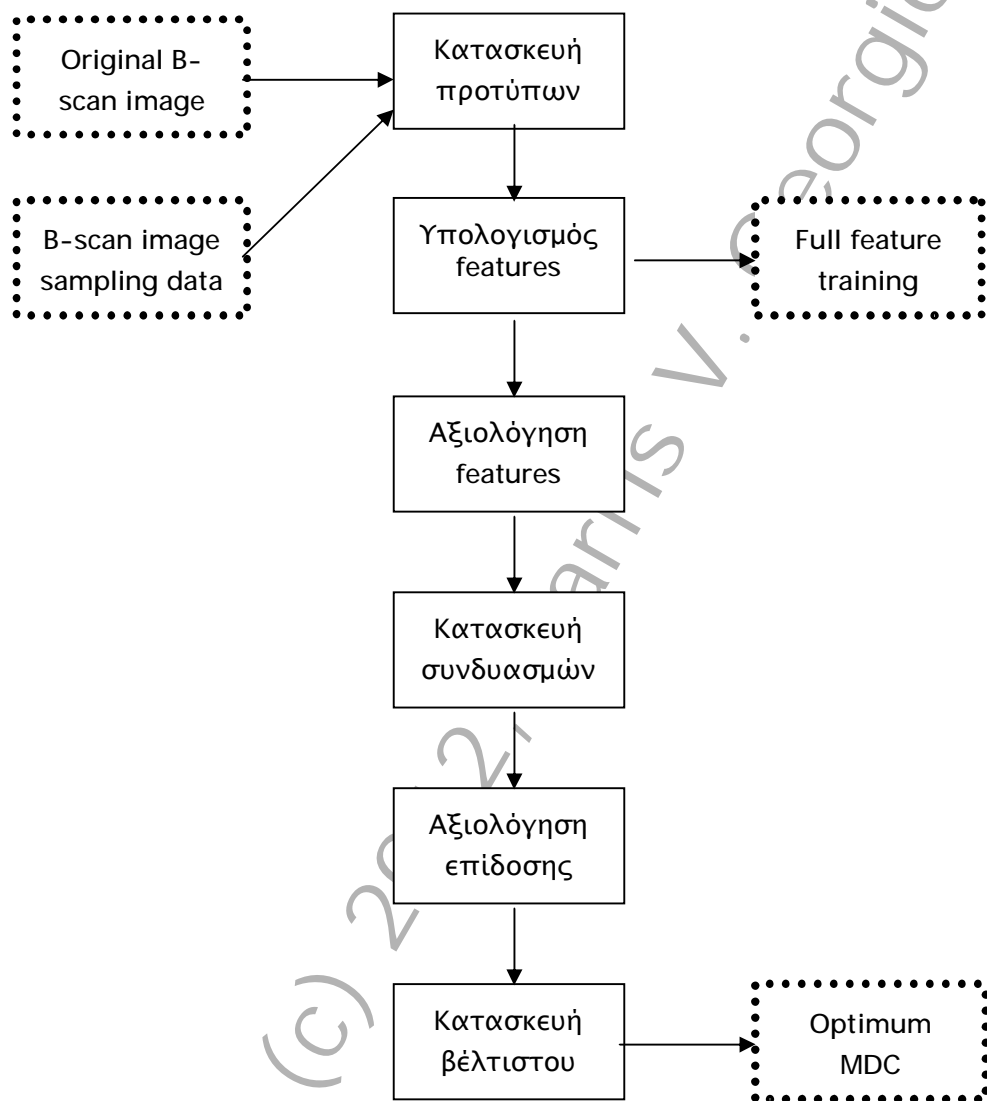
### 2.1.1 Ταξινομητής Ελάχιστης Απόστασης (MDC)

Ο ταξινομητής ελάχιστης απόστασης που χρησιμοποιήθηκε βασίζεται στον κλασικό ταξινομητή ελάχιστης απόστασης που περιγράφηκε αναλυτικά σε προηγούμενη ενότητα. Ως νόρμα απόστασης χρησιμοποιήθηκε μια παραλλαγή της πλήρους Mahalanobis νόρμας, λαμβάνοντας υπόψη μονάχα τις επιμέρους τιμές διασποράς για κάθε συνιστώσα. Η αντίστοιχη δομή που απαιτείται για την πλήρη περιγραφή κάποιας κλάσης είναι τα διανύσματα μέσης τιμής και διασπορών για τον μέσο εκπρόσωπο της κλάσης αυτής.

Η διαδικασία κατασκευής του ταξινομητή διακρίνεται στα εξής επιμέρους στάδια:

1. Κατασκευή των προτύπων του αρχικού συνόλου εκπαίδευσης
2. Εξαγωγή των χαρακτηριστικών παραμέτρων για κάθε πρότυπο
3. Αξιολόγηση διακριτικής ικανότητας κάθε χαρακτηριστικού και επιλογή
4. Κατασκευή πιθανών διαμορφώσεων για τη σχεδίαση του ταξινομητή
5. Αξιολόγηση πιθανών διαμορφώσεων για τη σχεδίαση του ταξινομητή
6. Επιλογή και τελική αξιολόγηση βέλτιστης διαμόρφωσης για τον ταξινομητή

Το πρώτο στάδιο αναφέρεται και ως στάδιο προεπεξεργασίας των αρχικών δεδομένων. Περιλαμβάνει τη δειγματοληψία της αρχικής ψηφιοποιημένης εικόνας στις περιοχές που αναφέρονται στο σύνολο των περιοχών ενδιαφέροντος, κανονικοποίηση των δεδομένων, εφαρμογή όλων των διαθέσιμων συναρτήσεων χαρακτηριστικών και τέλος αποθήκευση των διανυσμάτων ως πρότυπα εκπαίδευσης για τον ταξινομητή. Για την κανονικοποίηση χρησιμοποιείται το σχήμα μέσης τιμής και διακύμανσης, καθώς έχει αποδειχθεί περισσότερο αποτελεσματικό ως προς τη διατήρηση της πληροφορίας σε σχέση με άλλα σχήματα όπως αυτό της μέγιστης και ελάχιστης τιμής [09]. Όλο το πρώτο και δεύτερο στάδιο υλοποιείται από το αντίστοιχο πρόγραμμα δειγματοληψίας και κατασκευής χαρακτηριστικών παραμέτρων, το οποίο περιλαμβάνεται στο πακέτο του λογισμικού της εργασίας (SIFX).



**Σχήμα 2.1:** Μπλοκ διάγραμμα σταδίων επεξεργασίας για τον MDC

Το τρίτο στάδιο επεξεργασίας αναφέρεται στην ποσοτική αξιολόγηση της διακριτικής ικανότητας που προσφέρεται από το κάθε χαρακτηριστικό ξεχωριστά. Η επιλογή γίνεται με βάση τα αποτελέσματα μιας στατιστικής μεθόδου δοκιμής της μορφής T-test. Συνήθως σαν επίπεδο σημαντικότητας σε παρόμοιες στατιστικές μεθόδους δοκιμής χρησιμοποιείται η τιμή 1% ( $\alpha=0,01$ ) ή

ακόμα λιγότερο [05]. Ως αποτέλεσμα της επεξεργασίας κατασκευάζεται ένα νέο εκπαιδευτικό σύνολο, του οποίου τα διανύσματα εισόδου των προτύπων περιλαμβάνουν μονάχα τις συνιστώσες που αντιστοιχούν σε χαρακτηριστικά που επιλέχθηκαν ως αποτελεσματικά για το διαχωρισμό των κλάσεων.

Sorted feature selection:

feature 03	-> tval=4.2732	-> +[Selected]
feature 15	-> tval=2.8149	-> +[Selected]
feature 10	-> tval=2.7438	-> +[Selected]
feature 14	-> tval=2.7385	-> +[Selected]
feature 06	-> tval=2.3835	-> +[Selected]
feature 04	-> tval=2.3318	-> [Rejected]
feature 12	-> tval=2.2839	-> [Rejected]
feature 02	-> tval=1.8961	-> [Rejected]
feature 13	-> tval=1.4402	-> [Rejected]
feature 08	-> tval=1.3874	-> [Rejected]
feature 05	-> tval=1.2815	-> [Rejected]
feature 01	-> tval=0.8490	-> [Rejected]
feature 09	-> tval=0.7559	-> [Rejected]
feature 07	-> tval=0.6724	-> [Rejected]
feature 11	-> tval=0.0221	-> [Rejected]

T-Test Results: selected 5 out of 20 features (limit=2.352)

## Σχήμα 2.2: Παράδειγμα output για feature selection στο T-test

Το τέταρτο στάδιο περιλαμβάνει το συνδυασμό των χαρακτηριστικών για την κατασκευή αντιστοιχών διαμορφώσεων για τη σχεδίαση του ταξινομητή. Ο συνδυασμός των επιμέρους χαρακτηριστικών γίνεται χρησιμοποιώντας όσα έχουν επιλεγεί κατά το προηγούμενο στάδιο ανά 2, ανά 3 και ανά 4. Για κάθε διάσταση προκύπτουν πολλοί συνδυασμοί χαρακτηριστικών και όλοι οι συνδυασμοί για όλες τις διαστάσεις αποτελούν τις πιθανές διαμορφώσεις του ταξινομητή. Για κάθε διαμόρφωση αντιστοιχεί σύνολο εκπαίδευσης με όλα τα διαθέσιμα πρότυπα, όπως κατασκευάστηκαν στο δεύτερο στάδιο επεξεργασίας, έχοντας όμως διανύσματα εισόδου μόνο τις συνιστώσες που υποδεικνύονται από την εκάστοτε διαμόρφωση.

Κατά το πέμπτο στάδιο επεξεργασίας εκτελείται η αξιολόγηση του ταξινομητή για κάθε πιθανή διαμόρφωση που υπολογίστηκε στο προηγούμενο στάδιο. Η αξιολόγηση γίνεται εκτελώντας τη διαδικασία εκπαίδευσης ξεχωριστά για κάθε διαμόρφωση και επιλογή, τελικά, αυτής που δίνει τα καλύτερα

αποτελέσματα ως προς το τελικό ποσοστό επιτυχίας. Επειδή η δομή του ταξινομητή ελάχιστης απόστασης εμφανίζει μικρή πολυπλοκότητα, για την αξιολόγηση του ταξινομητή εφαρμόζεται η πλήρης μέθοδος Leave-One-Out, όπως περιγράφηκε σε προηγούμενη ενότητα. Για την αποφυγή επιπλέον κόστους αντιγραφής και αποθήκευσης μεγάλου όγκου δεδομένων, τόσο κατά την κατασκευή των συνόλων εκπαίδευσης κάθε διαμόρφωσης, όσο και κατά την εκτέλεση της μεθόδου LOO χρησιμοποιούνται δεδομένα από κοινού από το αρχικό σύνολο εκπαίδευσης, με κατάλληλο τρόπο ώστε να προσομοιώνονται τα περιεχόμενα του τρέχοντος ενεργού συνόλου προτύπων σε κάθε φάση της διαδικασίας εκπαίδευσης.

### OPTIMUM MDC:

Class-0 configuration:

MDCinfo:

```
tag = { 3 6 10 14 }
center = [ 0.0029 27.72 22774.7 -3247.86 ]
stddev = [ 0.00384838 22.6513 7575.01 6399.36 ]
```

Class-1 configuration:

MDCinfo:

```
tag = { 3 6 10 14 }
center = [ 0.00688 19.04 18956.6 -568.13 ]
stddev = [ 0.0059553 20.008 8193.41 5193.38 ]
```

CPMinfo:

```
      cN      cA
+-----+
pN: | 30 | 20 |
+-----+
pA | 10 | 90 |
+-----+
succ = 80.0%
```

**Σχήμα 2.3:** Παράδειγμα output για optimum MDC

Στο τελευταίο στάδιο επεξεργασίας γίνεται η επιλογή και η τελική αξιολόγηση της βέλτιστης διαμόρφωσης του ταξινομητή. Η επιλογή γίνεται με βάση το τελικό ποσοστό επιτυχίας, και μάλιστα με τέτοιο τρόπο ώστε σε περίπτωση διαμορφώσεων με το ίδιο ποσοστό επιτυχίας να επιλέγεται αυτή με τη μικρότερη πολυπλοκότητα, δηλαδή με τη μικρότερη διάσταση ως προς τα

διανύσματα διαμόρφωσης του ταξινομητή. Η τελική αξιολόγηση της βέλτιστης διαμόρφωσης γίνεται χρησιμοποιώντας ολόκληρο το σύνολο εκπαίδευσης, δηλαδή χωρίς την εφαρμογή της μεθόδου LOO. Η τελική διαμόρφωση του ταξινομητή, καθώς και το αντίστοιχο σύνολο εκπαίδευσης αποθηκεύονται σε μορφή αρχείων για τη δυνατότητα επισκόπησης και περαιτέρω επεξεργασίας.

OPTIMUM MDC Configuration file:

```
4
3 0.002900 0.000015
6 27.720000 513.081600
10 22774.740000 57380738.472400
14 -3247.860000 40951805.320400
4
3 0.006880 0.000035
6 19.040000 400.318400
10 18956.610000 67131898.817900
14 -568.130000 26971160.533100
150
30      20
10      90
```

**Σχήμα 2.4:** Παράδειγμα output για optimum MDC configuration file

Τα στάδια επεξεργασίας από 3 ως και 6 αποτελούν τον κορμό της διαδικασίας εκπαίδευσης του ταξινομητή ελάχιστης απόστασης και υλοποιούνται από το αντίστοιχο πρόγραμμα σχεδίασης και κατασκευής του ταξινομητή MDC, το οποίο περιλαμβάνεται στο πακέτο του λογισμικού της εργασίας (FCD).

### 2.1.2 Ταξινομητής Νευρωνικού Δικτύου (NNC)

Ο ταξινομητής νευρωνικού δικτύου που χρησιμοποιήθηκε βασίζεται στην κλασική αρχιτεκτονική MLP που περιγράφηκε αναλυτικά σε προηγούμενη ενότητα. Ως αλγόριθμος εκπαίδευσης εφαρμόστηκε μια παραλλαγή του βασικού Back-Propagation, συμπεριλαμβάνοντας τεχνικές συντελεστή ορμής (momentum), on-line εκπαίδευση και cross-validation με σύνολα επικύρωσης σε όλη τη διάρκεια της.

Η διαδικασία κατασκευής του ταξινομητή διακρίνεται στα εξής επιμέρους στάδια:

1. Κατασκευή των προτύπων του αρχικού συνόλου εκπαίδευσης
2. Εξαγωγή των χαρακτηριστικών παραμέτρων για κάθε πρότυπο
3. Αξιολόγηση διακριτικής ικανότητας κάθε χαρακτηριστικού και επιλογή
4. Κατασκευή πιθανών διαμορφώσεων για τη σχεδίαση του ταξινομητή
5. Αξιολόγηση πιθανών διαμορφώσεων για τη σχεδίαση του ταξινομητή
6. Επιλογή και τελική αξιολόγηση βέλτιστης διαμόρφωσης για τον ταξινομητή

Τα πρώτα δύο στάδια αναφέρονται στην προεπεξεργασία των αρχικών δεδομένων της ψηφιοποιημένης εικόνας και εκτελούνται μία φορά από κοινού, τόσο για τον ταξινομητή ελάχιστης απόστασης, όσο και για τον νευρωνικό ταξινομητή. Επειδή η εφαρμογή υλοποίησης του νευρωνικού ταξινομητή έχει κατασκευαστεί ως γενικής χρήσης, δεν ενσωματώνει μεθοδολογία στατιστικής δοκιμής των χαρακτηριστικών των προτύπων εισόδου όπως το αντίστοιχο πρόγραμμα για τον γραμμικό ταξινομητή. Αντί αυτού, χρησιμοποιεί εν μέρει τα αποτελέσματα του αντίστοιχου σταδίου επεξεργασίας του γραμμικού ταξινομητή για την μορφοποίηση συνόλων εκπαίδευσης του νευρωνικού ταξινομητή.

Το τέταρτο στάδιο επεξεργασίας αναφέρεται στην επιλογή, τόσο των επιμέρους συνόλων εκπαίδευσης για κάθε διαμόρφωση, όσο και της ίδιας της τοπολογίας του νευρωνικού δικτύου. Λόγω της πολυπλοκότητας της δομής του ταξινομητή και του αλγορίθμου εκπαίδευσης, δεν είναι δυνατή η εφαρμογή αναλυτικών μεθόδων όπως έγινε στην περίπτωση του γραμμικού ταξινομητή, συνεπώς η όλη διαδικασία βασίζεται σε μεθόδους δοκιμής και αξιολόγησης, όπως άλλωστε στις περισσότερες περιπτώσεις εφαρμογής νευρωνικών δικτύων για την επίλυση κάποιου προβλήματος αναγνώρισης προτύπων. Στην περίπτωση νευρωνικών ταξινομητών για ανάλυση ιατρικής εικόνας έχουν προταθεί διάφορες μορφολογίες για την τοπολογία του δικτύου, κυρίως σε ότι αφορά τα εσωτερικά επίπεδα νευρώνων. Συγκεκριμένα, έχουν προταθεί τοπολογίες με ένα κρυμμένο επίπεδο του οποίου το μέγεθος καθορίζεται ως το μέσο μέγεθος μεταξύ επιπέδων εισόδου και εξόδου [20]. Επιπλέον, όπως έχει ήδη αναφερθεί σε προηγούμενη ενότητα, το συνολικό πλήθος των βαρών στο δίκτυο περιορίζεται και από το διαθέσιμο πλήθος των προτύπων εκπαίδευσης, σύμφωνα με τον επιθυμητό βαθμό ικανότητας γενίκευσης που απαιτείται για τον ταξινομητή.

Τα τελευταία δύο επίπεδα αποτελούν ουσιαστικά τον κορμό της διαδικασίας εκπαίδευσης του νευρωνικού ταξινομητή και υλοποιούνται ενοποιημένα στον αλγόριθμο του προγράμματος εκπαίδευσης. Το πέμπτο στάδιο αναφέρεται στην κυρίως φάση εκπαίδευσης χρησιμοποιώντας το σύνολο εκπαίδευσης και το σύνολο επικύρωσης (on-line), ενώ το έκτο στάδιο περιλαμβάνει την μέτρηση της τελικής απόδοσης του νευρωνικού ταξινομητή με βάση το σύνολο αξιολόγησης. Το πρόγραμμα εκπαίδευσης που χρησιμοποιείται για τη σχεδίαση και εκπαίδευση του νευρωνικού ταξινομητή αποτελεί εφαρμογή γενικής χρήσης για την εκπαίδευση νευρωνικών δικτύων τύπου MLP και περιλαμβάνεται στο πακέτο του λογισμικού της εργασίας (BPM).

```
#i ter=999 of 1000, recogn=1120 of 1125, trainerr=0.061, validated= 96.46%
Saving current network in file (bpm_net.txt)...
#i ter=1000 of 1000, recogn=1120 of 1125, trainerr=0.061, validated=
96.46%
```

Finished training. Start testing.....

#paterns tested	#paterns recongi sed	#fai lures
2250	2212	38
Percentages:	98.311%	1.689%

Learning coeffi ci ent: 0.150

Momentum coeffi ci ent: 0.050

```

      cN   cA
+-----+
pN: | 723 | 27 |
+-----+
pA  |  11 | 1489 |
+-----+
succ = 98.3%
```

**Σχήμα 2.5:** Παράδειγμα output για νευρωνικό δίκτυο

## 2.2 Τεκμηρίωση Λογισμικού

Στην παρούσα ενότητα αναφέρονται λεπτομέρειες σχετικά με την δομή και τον τρόπο λειτουργίας των προγραμμάτων του πακέτου λογισμικού, που χρησιμοποιήθηκαν για την σχεδίαση, κατασκευή και εκπαίδευση των ταξινομητών ελάχιστης απόστασης και νευρωνικού δικτύου. Περισσότερες πληροφορίες σχετικά με τη δομή του κώδικα υλοποίησής τους παρουσιάζονται στο αντίστοιχο παράρτημα.

### 2.2.1 SIFX: Sample Image Feature Extractor

#### 2.2.1.1 Εισαγωγή

Το πρόγραμμα SIFX αποτελεί το εργαλείο προεπεξεργασίας της αρχικής ψηφιοποιημένης υπερηχογραφικής εικόνας και της εξαγωγής των δεδομένων προς ανάλυση από τα προγράμματα σχεδίασης ταξινομητή. Με βάση κάποια αρχική ψηφιακή εικόνα και ένα σύνολο περιοχών δειγματοληψίας, χρησιμοποιεί ένα σύνολο συναρτήσεων για την ποσοτικοποίηση των πληροφοριών υψής σε κάθε μια περιοχή και την μετέπειτα χρησιμοποίησή τους για τη σχεδίαση του ταξινομητή. Η εφαρμογή είναι ανεπτυγμένη με τέτοιο τρόπο ώστε η χρησιμότητα και η πρακτική εφαρμογή της να μπορεί να επεκταθεί εύκολα, εκτός από υπερηχογραφικές, και σε άλλου τύπου εικόνες.

#### 2.2.1.2 Λειτουργία

Δύο εκδόσεις της εφαρμογής είναι διαθέσιμες. Η πρώτη λειτουργεί σε περιβάλλον κελύφους συστήματος (MS-DOS shell) και η διεπαφή με το χρήστη είναι κονσόλα τερματικού σταθμού, δηλαδή βασισμένη σε χαρακτήρες. Η δεύτερη περιλαμβάνει γραφικό περιβάλλον για την αλληλεπίδραση με το χρήστη και την απεικόνιση των αποτελεσμάτων. Ο λόγος για την ύπαρξη των δύο εκδόσεων είναι ότι, ενώ η εφαρμογή με το γραφικό περιβάλλον είναι χρήσιμη για την εύκολη επισκόπηση των ενδιάμεσων σταδίων επεξεργασίας και των τελικών αποτελεσμάτων, λόγω του γραφικού περιβάλλοντος είναι εν γένει ως ένα βαθμό πιο αργή σε απόλυτη ταχύτητα επεξεργασίας.

Οι δύο εκδόσεις είναι σε κάθε περίπτωση απόλυτα συμβατές και ο χρήστης μπορεί να επιλέξει ποια από τις δύο επιθυμεί να χρησιμοποιήσει, χωρίς καμία απολύτως διαφοροποίηση στα τελικά αποτελέσματα. Οποιαδήποτε αναφορά σε θέματα αρχιτεκτονικής και υλοποίησης αφορά και τις δύο εκδόσεις του προγράμματος.

#### 2.2.1.3 Έκδοση κονσόλας

Η έκδοση κονσόλας (sifx.exe) μπορεί να χρησιμοποιηθεί για την γρήγορη εξαγωγή των αποτελεσμάτων της προεπεξεργασίας της εικόνας εισόδου. Το



πρόγραμμα ζητά από το χρήστη το όνομα του αρχείου εικόνας τύπου bitmap (.bmp) προς επεξεργασία, την τρέχουσα κλίμακα τόνων απεικόνισης (greyscale), το αρχείο κειμένου με τις περιοχές έρευνας, τις διαστάσεις του παραθύρου δειγματοληψίας, καθώς και δύο συντελεστές θορύβου για την κατασκευή των προσομοιωμένων δεδομένων. Σαν έξοδο παράγει δύο αρχεία κειμένου με τα πρότυπα διανύσματα που θα χρησιμοποιηθούν στη συνέχεια για τη σχεδίαση των ταξινομητών. Ο χρήστης μπορεί να χρησιμοποιήσει κάποιο αρχείο αυτόματης εισόδου των ζητούμενων από το πρόγραμμα παραμέτρων (response file), όμοιο με αυτό που χρησιμοποιείται από την έκδοση γραφικού περιβάλλοντος.



```

Γραμμή εντολών MS-DOS
Image normalized OK
Give samples pt file: us1.dat.txt
Creating: 250x[5x5] image samples
Give output patterns filename: us1_pat.txt
Give noise bias (0.0 ... +1.0): 0.0
Give noise level (0.0 ... +1.0): 0.1
Enter type(s) of simulated data to create:
(U=NONE, 1=ASP, 2=ASM, 3=BOTH): 3

Creating training patterns:
.....
.....
.....
Constructing patterns file... done.
Reading initial patterns file...
patterns read: count=750 , features=20
done.
Writing normalized patterns file... done.
Constructing normalized patterns file... done.
Writing AUX-0 data file ('fcd-all.dat')... done.
Cleaning up... All done!

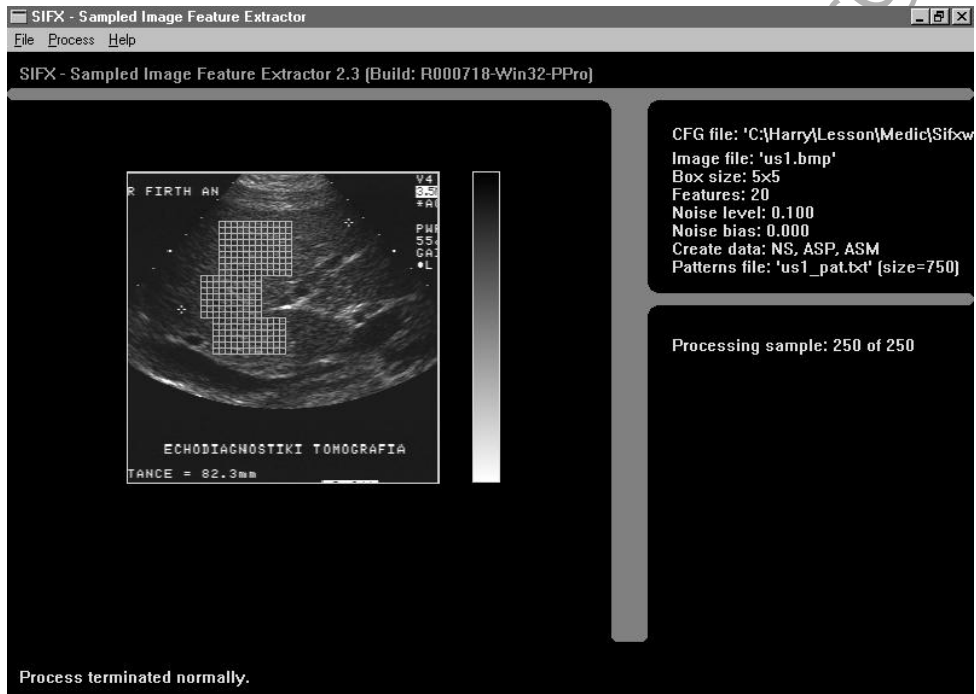
C:\Harry\Lesson\Medic\sifx>
    
```

**Σχήμα 2.6:** SIFX – Εικόνα προγράμματος κονσόλας

#### 2.2.1.4 Έκδοση γραφικού περιβάλλοντος

Η έκδοση γραφικού περιβάλλοντος (sifxw.exe) μπορεί να χρησιμοποιηθεί για την εύκολη επισκόπηση των αποτελεσμάτων της προεπεξεργασίας. Η ψηφιοποιημένη εικόνα εμφανίζεται στο παράθυρο της εφαρμογής και κατά τον υπολογισμό των συναρτήσεων υψής οι περιοχές δειγματοληψίας σημειώνονται επάνω στην εικόνα. Το πρόγραμμα περιμένει από το χρήστη τα επιλέξει κάποιο αρχείο εισόδου, το οποίο χρησιμοποιείται για τη διαμόρφωση του περιβάλλοντος και έχει ακριβώς την ίδια μορφή με το αντίστοιχο αρχείο αυτόματης εισόδου που χρησιμοποιείται στην έκδοση κονσόλας. Από το αρχείο διαμόρφωσης καθορίζονται όλες οι απαραίτητες παράμετροι, δηλαδή το όνομα του αρχείου εικόνας τύπου bitmap (.bmp) προς επεξεργασία, η τρέχουσα κλίμακα τόνων απεικόνισης (greyscale), το αρχείο κειμένου με τις περιοχές έρευνας, οι διαστάσεις του παραθύρου δειγματοληψίας, καθώς και οι δύο συντελεστές θορύβου για την κατασκευή των προσομοιωμένων δεδομένων. Σαν έξοδο

παράγει δύο αρχεία κειμένου με τα πρότυπα διανύσματα που θα χρησιμοποιηθούν στη συνέχεια για τη σχεδίαση των ταξινομητών.



Σχήμα 2.7: SIFXW - Εικόνα προγράμματος GUI

#### 2.2.1.5 Αρχιτεκτονική και δομή

Το πρόγραμμα της εφαρμογής λειτουργεί σε δύο φάσεις. Κατά την πρώτη φάση διαβάζονται οι παράμετροι λειτουργίας και διαμορφώνεται το περιβάλλον επεξεργασίας, ενώ κατά τη δεύτερη φάση εκτελείται το κυρίως μέρος της επεξεργασίας.

Αρχικά διαβάζεται το αρχείο bitmap της ψηφιοποιημένης εικόνας σε περιοχή της κύριας μνήμης και στη συνέχεια εκτελείται κανονικοποίηση των τιμών κάθε pixel με βάση την επιλεγείσα κλίμακα τόνων του γκρι (greyscale), η οποία μπορεί να πάρει τιμές από 2 (black-white) ως 256 (καμία κανονικοποίηση). Η κανονικοποίηση των δεδομένων της αρχικής εικόνας είναι απαραίτητη, όχι μόνο για την αύξηση της ευκρίνειας και κατά συνέπεια της διακριτικής ικανότητας, αλλά και για την επιτάχυνση των υπολογισμών, αφού το εύρος της κλίμακας των τόνων του γκρι επηρεάζει άμεσα τις διαστάσεις πινάκων που χρησιμοποιούνται από συναρτήσεις υφής δευτέρας τάξης. Η μορφή των αρχείων bitmap που είναι συμβατά με την εφαρμογή είναι το τυπικό bitmap format (OS/2 sub-version) με 256 greyscale περιεχόμενο και μέγεθος 256x256 pixels.

Στη συνέχεια τα κανονικοποιημένα δεδομένα της εικόνας μπορούν να χρησιμοποιηθούν για τη δειγματοληψία στις δοθείσες περιοχές έρευνας και την εφαρμογή σε κάθε μία από αυτές όλων των διαθέσιμων συναρτήσεων υψής. Στην παρούσα υλοποίηση έχουν συμπεριληφθεί 20 συναρτήσεις υψής που περιλαμβάνουν στατιστικές ποσότητες πρώτης τάξης (first order statistics, FOS = 4), στατιστικές χωρικής εξάρτησης (spatial dependence statistics, SDS = 11), καθώς και στατιστικές βασισμένες σε run-lengths (run-length statistics, RLS = 5). Ο υπολογισμός των FOS γίνεται άμεσα στα κανονικοποιημένα δεδομένα της εικόνας, ενώ για τον υπολογισμό των SDS και RLS απαιτείται προηγουμένως η κατασκευή αντίστοιχων πινάκων (SDM, RLM) για κάθε περιοχή δείγματος, οι διαστάσεις των οποίων εξαρτώνται από τις διαστάσεις του παραθύρου δειγματοληψίας και από την τρέχουσα κλίμακα τόνων του γκρι.

Η διαδικασία υπολογισμού των συναρτήσεων υψής εφαρμόζεται τόσο στα αρχικά δεδομένα κάθε δείγματος, όσο και στα προσομοιωμένα παθολογικά δείγματα. Για την κατασκευή των προσομοιωμένων παθολογικών δειγμάτων χρησιμοποιούνται τα δεδομένα της κανονικοποιημένης εικόνας, που αντιπροσωπεύει φυσιολογικό ιστό (φυσιολογικό: N), στα οποία προστίθεται ή αφαιρείται κάποιο ποσοστό από κάθε τιμή ρixel σε μορφή ομοιόμορφου θορύβου. Με τον τρόπο αυτό κατασκευάζονται προσομοιωμένα δείγματα τύπου παθολογίας λιπώδους διήθησης (παθολογία: A1) και παθολογίας κίρρωσης (παθολογία: A2) αντίστοιχα. Το ποσοστό που προστίθεται ή αφαιρείται κάθε φορά υπολογίζεται τυχαία για κάθε ρixel και ο χρήστης μπορεί να καθορίσει το εύρος (noise level) και το απόλυτο ποσοστό διαχωρισμού (noise bias), αν πρόκειται και έγχρωμο θόρυβο. Επίσης υπάρχει δυνατότητα επιλογής υπολογισμού μονάχα μιας από τις δύο παθολογικές κατηγορίες. Η φυσιολογική περίπτωση αποτελεί την πρώτη κατηγορία δειγμάτων, ενώ οι δύο παθολογικές περιπτώσεις θεωρούνται ενιαία ως η δεύτερη κατηγορία.

Οι τιμές των όλων των συναρτήσεων υψής για τα φυσιολογικά (N) και τα παθολογικά (A1, A2) δείγματα, μαζί με την ένδειξη της κατηγορίας στην οποία ανήκει το συγκεκριμένο δείγμα, αποθηκεύονται σε μορφή διανυσμάτων που στη συνέχεια θα χρησιμοποιηθούν από τα προγράμματα σχεδίασης ταξινομητή. Ως έξοδο το πρόγραμμα παράγει δύο αρχεία κειμένου με τα πρότυπα διανύσματα σε δύο διαφορετικές μορφές, συμβατές με τα αντίστοιχα προγράμματα σχεδίασης των ταξινομητών (FCD, BPM).

## 2.2.2 FCD: Feature Classifier Designer

### 2.2.2.1 Εισαγωγή

Το πρόγραμμα FCD αποτελεί το βασικό εργαλείο σχεδίασης και κατασκευής γραμμικών ταξινομητών ελάχιστης απόστασης (Minimum Distance Classifier – MDC). Με βάση κάποιο σύνολο προτύπων διανυσμάτων δύο κατηγοριών, κατασκευάζει τον ταξινομητή βέλτιστης διαχωριστικής ικανότητας με βάση την (ελάχιστη) απόσταση του άγνωστου προτύπου από τα αντιπροσωπευτικά διανύσματα των δύο κατηγοριών. Η εφαρμογή είναι ανεπτυγμένη με τέτοιο τρόπο ώστε η χρησιμότητα και η πρακτική εφαρμογή της να μπορεί να επεκταθεί εύκολα σε κάθε είδους εφαρμογή που απαιτεί τη σχεδίαση γραμμικών ταξινομητών ελάχιστης απόστασης (MDC) με βάση κάποια πρότυπα διανύσματα.

### 2.2.2.2 Λειτουργία

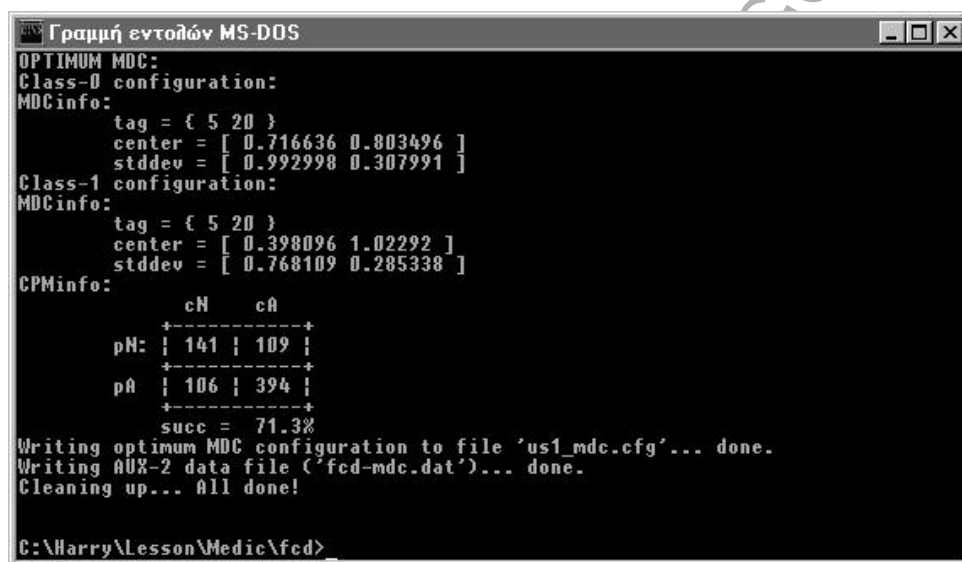
Δύο εκδόσεις της εφαρμογής είναι διαθέσιμες. Η πρώτη λειτουργεί σε περιβάλλον κελύφους συστήματος (MS-DOS shell) και η διεπαφή με το χρήστη είναι κονσόλα τερματικού σταθμού, δηλαδή βασισμένη σε χαρακτήρες. Η δεύτερη περιλαμβάνει γραφικό περιβάλλον για την αλληλεπίδραση με το χρήστη και την απεικόνιση των αποτελεσμάτων. Ο λόγος για την ύπαρξη των δύο εκδόσεων είναι ότι, ενώ η εφαρμογή με το γραφικό περιβάλλον είναι χρήσιμη για την εύκολη επισκόπηση των ενδιάμεσων σταδίων επεξεργασίας και των τελικών αποτελεσμάτων, λόγω του γραφικού περιβάλλοντος είναι εν γένει ως ένα βαθμό πιο αργή σε απόλυτη ταχύτητα επεξεργασίας.

Οι δύο εκδόσεις είναι σε κάθε περίπτωση απόλυτα συμβατές και ο χρήστης μπορεί να επιλέξει ποια από τις δύο επιθυμεί να χρησιμοποιήσει, χωρίς καμία απολύτως διαφοροποίηση στα τελικά αποτελέσματα. Οποιαδήποτε αναφορά σε θέματα αρχιτεκτονικής και υλοποίησης αφορά και τις δύο εκδόσεις του προγράμματος.

### 2.2.2.3 Έκδοση κονσόλας

Η έκδοση κονσόλας (fcd.exe) μπορεί να χρησιμοποιηθεί για την γρήγορη εξαγωγή των αποτελεσμάτων της επιλογής του βέλτιστου γραμμικού ταξινομητή. Το πρόγραμμα ζητά από το χρήστη το όνομα του αρχείου με τα πρότυπα διανύσματα που πρόκειται να χρησιμοποιηθούν για τη σχεδίαση του ταξινομητή, το όριο σημαντικότητας στο T-test των επιμέρους τιμών (συνιστώσες) των διανυσμάτων, καθώς και το ελάχιστο πλήθος συνιστωσών που θα πρέπει να ληφθούν υπόψη στον ταξινομητή. Ο χρήστης επιλέγει επίσης τη συνάρτηση απόστασης που θα χρησιμοποιηθεί (Euclidean, Mahalanobis), καθώς και το όνομα του αρχείου εξόδου όπου θα αποθηκευτεί η βέλτιστη διαμόρφωση του ταξινομητή. Σαν έξοδο παράγει δύο αρχεία κειμένου με τα πρότυπα διανύσματα που θα χρησιμοποιηθούν στη συνέχεια για τη σχεδίαση των

ταξινομητών (BPM format), το ένα με όσες συνιστώσες επιλέχθηκαν από το T-test και το άλλο με όσες χρησιμοποιεί ο βέλτιστος MDC ταξινομητής. Τέλος, αποθηκεύει τη διαμόρφωση (συνιστώσες, μέσοι εκπρόσωποι, απόδοση) της βέλτιστης διαμόρφωσης επίσης σε αρχείο κειμένου. Ο χρήστης μπορεί να χρησιμοποιήσει κάποιο αρχείο αυτόματης εισόδου των ζητούμενων από το πρόγραμμα παραμέτρων (response file), όμοιο με αυτό που χρησιμοποιείται από την έκδοση γραφικού περιβάλλοντος.



```

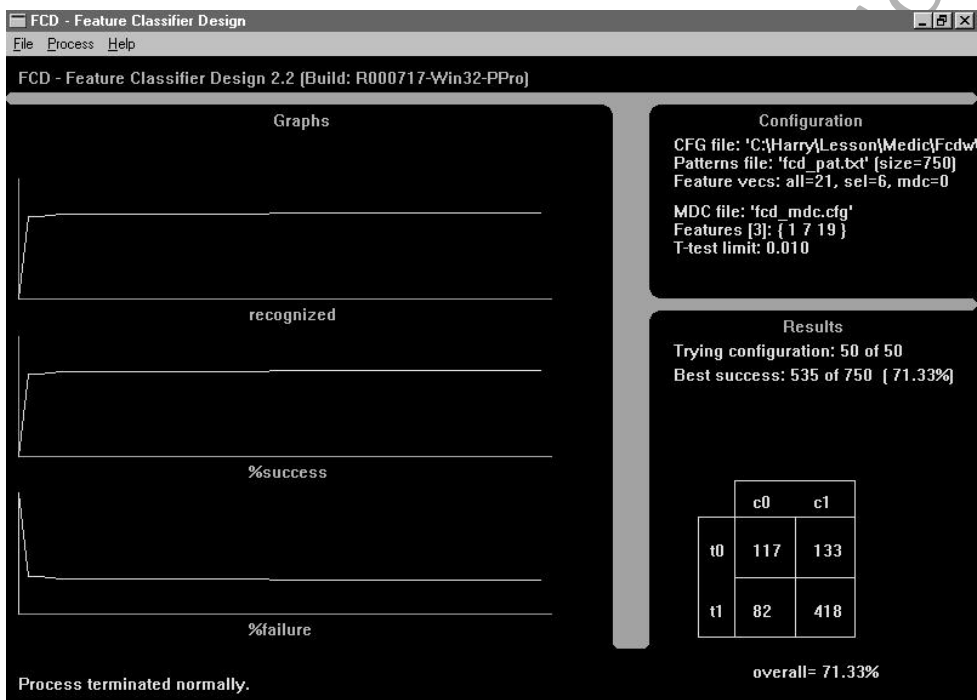
Γραμμή εντολών MS-DOS
OPTIMUM MDC:
Class-0 configuration:
MDCinfo:
    tag = { 5 20 }
    center = [ 0.716636 0.803496 ]
    stddev = [ 0.992998 0.307991 ]
Class-1 configuration:
MDCinfo:
    tag = { 5 20 }
    center = [ 0.398096 1.02292 ]
    stddev = [ 0.768109 0.285338 ]
CPMinfo:
      cN    cA
+-----+
pH: | 141 | 109 |
+-----+
pA: | 106 | 394 |
+-----+
succ = 71.3%
Writing optimum MDC configuration to file 'us1_mdc.cfg'... done.
Writing AUX-2 data file ('fcd-mdc.dat')... done.
Cleaning up... All done!

C:\Harry\Lesson\Medic\fcd>
    
```

Σχήμα 2.8: FCD - Εικόνα προγράμματος κονσόλας

#### 2.2.2.4 Έκδοση γραφικού περιβάλλοντος

Η έκδοση γραφικού περιβάλλοντος (fcdw.exe) μπορεί να χρησιμοποιηθεί για την εύκολη επισκόπηση των αποτελεσμάτων της επεξεργασίας. Στο παράθυρο της εφαρμογής εμφανίζονται τρία διαγράμματα που παρουσιάζουν την τρέχουσα απόδοση του ταξινομητή. Το πρόγραμμα περιμένει από το χρήστη τα επιλέξει κάποιο αρχείο εισόδου, το οποίο χρησιμοποιείται για τη διαμόρφωση του περιβάλλοντος και έχει ακριβώς την ίδια μορφή με το αντίστοιχο αρχείο αυτόματης εισόδου που χρησιμοποιείται στην έκδοση κονσόλας. Από το αρχείο διαμόρφωσης καθορίζονται όλες οι απαραίτητες παράμετροι, δηλαδή το όνομα του αρχείου προτύπων διανυσμάτων, το όριο σημαντικότητας στο T-test, η συνάρτηση απόστασης και το αρχείο αποθήκευσης της βέλτιστης διαμόρφωσης. Σαν έξοδο παράγει δύο αρχεία κειμένου με τα πρότυπα διανύσματα που θα χρησιμοποιηθούν στη συνέχεια για τη σχεδίαση των ταξινομητών (BPM format), το ένα με όσες συνιστώσες επιλέχθηκαν από το T-test και το άλλο με όσες χρησιμοποιεί ο βέλτιστος MDC ταξινομητής. Τέλος, αποθηκεύει τη διαμόρφωση (συνιστώσες, μέσοι εκπρόσωποι, απόδοση) της βέλτιστης διαμόρφωσης επίσης σε αρχείο κειμένου.



**Σχήμα 2.9:** FCDW - Εικόνα προγράμματος GUI

#### 2.2.2.5 Αρχιτεκτονική και δομή

Το πρόγραμμα της εφαρμογής λειτουργεί σε τρεις φάσεις. Κατά την πρώτη φάση διαβάζονται οι παράμετροι λειτουργίας και διαμορφώνεται το περιβάλλον επεξεργασίας, κατά τη δεύτερη φάση εκτελείται ένα τυπικό T-test για κάθε συνιστώσα των διανυσμάτων εισόδου και επιλογή όσων εμφανίζουν ικανοποιητική διαχωριστική ικανότητα, ενώ κατά την τρίτη φάση εκτελείται το κυρίως μέρος της επεξεργασίας.

Αρχικά διαβάζεται το αρχείο των πρότυπων διανυσμάτων, όπως κατασκευάστηκε από το αντίστοιχο πρόγραμμα υπολογισμού των συναρτήσεων υψής (sifx). Οι τιμές των συναρτήσεων υψής αποτελούν τις συνιστώσες σε κάθε διάνυσμα εισόδου, ενώ η αντίστοιχη κατηγορία στην οποία ανήκει αποτελεί την επιθυμητή έξοδο για τον ταξινομητή. Πριν την κατασκευή των μετασχηματισμένων συνόλων εκπαίδευσης για την σχεδίαση αντίστοιχων ταξινομητών, είναι απαραίτητη η μείωση των ενεργών συνιστωσών στα διανύσματα εισόδου. Με βάση κάποιο συγκεκριμένο όριο σημαντικότητας που ορίζει ο χρήστης, ένα τυπικό T-test καθορίζει τις πιο αποτελεσματικές συνιστώσες ως προς τη διαχωριστική ικανότητα σε σχέση με τις κατηγορίες.

Η διαδικασία σχεδίασης χρησιμοποιεί συνδυασμούς συνιστωσών των διανυσμάτων εισόδου για την κατασκευή μετασχηματισμών του αρχικού συνόλου εκπαίδευσης, σύμφωνα με συγκεκριμένους περιορισμούς χώρου και χρόνου επεξεργασίας. Επειδή απαιτείται η διερεύνηση όλων των πιθανών συνδυασμών συνιστωσών, το μέγιστο πλήθος (διάσταση) των μετασχηματισμένων διανυσμάτων εκπαίδευσης δεν ξεπερνά το 4, ενώ για την επίτευξη υψηλού ποσοστού επιτυχίας συνήθως απορρίπτονται ταξινομητές με διάσταση διανυσμάτων ίση με 1. Με βάση τα όρια αυτά κατασκευάζονται όλοι οι πιθανοί συνδυασμοί συνιστωσών διανυσμάτων και τα αντίστοιχα μετασχηματισμένα σύνολα αποτελούν τα πρότυπα εκπαίδευσης για γραμμικούς ταξινομητές με αντίστοιχη διαμόρφωση.

Η διαδικασία σχεδίασης του βέλτιστου ταξινομητή στην πραγματικότητα περιλαμβάνει την σχεδίαση του ίδιου ταξινομητή για κάθε πιθανή διαμόρφωση, σύμφωνα με τα μετασχηματισμένα σύνολα εκπαίδευσης που κατασκευάστηκαν στο προηγούμενο στάδιο. Έτσι, ξεκινώντας για παράδειγμα από την πρώτη διαμόρφωση με 2 συνιστώσες σε κάθε διάνυσμα (διάσταση = 2), υπολογίζεται η απόδοση του ταξινομητή. Κάθε νέα διαμόρφωση υπολογίζεται όπως και πριν, συγκρίνοντας την απόδοσή της με αυτή της τρέχουσας βέλτιστης και σε περίπτωση που η νέα διαμόρφωση είναι αποδοτικότερη υιοθετείται ως βέλτιστη. Η διαδικασία επαναλαμβάνεται για όλες τις διαθέσιμες διαμορφώσεις και τελικά επιλέγεται ως βέλτιστη αυτή που εμφανίζει την μεγαλύτερη απόδοση. Επιπλέον, για να εξασφαλιστεί η επιλογή όσο το δυνατό μικρότερης διάστασης, η διερεύνηση ξεκινά από τις διαμορφώσεις με τη μικρότερη διάσταση και προχωρά προς διαμορφώσεις με μεγαλύτερες διαστάσεις. Για τον υπολογισμό της απόδοσης κάθε διαμόρφωσης κατά τη σχεδίαση του ταξινομητή, χρησιμοποιείται η τεχνική Leave-One-Out (LOO).

## 2.2.3 BPM: Neural Network Classifier Design

### 2.2.3.1 Εισαγωγή

Το πρόγραμμα BPM αποτελεί το βασικό εργαλείο σχεδίασης και κατασκευής ταξινομητών βασισμένων σε Τεχνητά Νευρωνικά Δίκτυα (ΤΝΔ). Με βάση κάποιο σύνολο προτύπων διανυσμάτων, κατασκευάζει την βέλτιστη διαμόρφωση μιας δεδομένης τοπολογίας νευρωνικού (μη γραμμικού) ταξινομητή για την κατηγοριοποίηση του άγνωστου προτύπου σε μια από τις διαθέσιμες κατηγορίες. Η εφαρμογή είναι ανεπτυγμένη με τέτοιο τρόπο ώστε η χρησιμότητα και η πρακτική εφαρμογή της να μπορεί να επεκταθεί εύκολα σε κάθε είδους εφαρμογή που απαιτεί τη σχεδίαση νευρωνικών ταξινομητών με βάση κάποια πρότυπα διανύσματα.

### 2.2.3.2 Λειτουργία

Δύο εκδόσεις της εφαρμογής είναι διαθέσιμες. Η πρώτη λειτουργεί σε περιβάλλον κελύφους συστήματος (MS-DOS shell) και η διεπαφή με το χρήστη είναι κονσόλα τερματικού σταθμού, δηλαδή βασισμένη σε χαρακτήρες. Η δεύτερη περιλαμβάνει γραφικό περιβάλλον για την αλληλεπίδραση με το χρήστη και την απεικόνιση των αποτελεσμάτων. Ο λόγος για την ύπαρξη των δύο εκδόσεων είναι ότι, ενώ η εφαρμογή με το γραφικό περιβάλλον είναι χρήσιμη για την εύκολη επισκόπηση των ενδιάμεσων σταδίων επεξεργασίας και των τελικών αποτελεσμάτων, λόγω του γραφικού περιβάλλοντος είναι εν γένει ως ένα βαθμό πιο αργή σε απόλυτη ταχύτητα επεξεργασίας.

Οι δύο εκδόσεις είναι σε κάθε περίπτωση απόλυτα συμβατές και ο χρήστης μπορεί να επιλέξει ποια από τις δύο επιθυμεί να χρησιμοποιήσει, χωρίς καμία απολύτως διαφοροποίηση στα τελικά αποτελέσματα. Οποιαδήποτε αναφορά σε θέματα αρχιτεκτονικής και υλοποίησης αφορά και τις δύο εκδόσεις του προγράμματος.

### 2.2.3.3 Έκδοση κονσόλας

Η έκδοση κονσόλας (bpm.exe) μπορεί να χρησιμοποιηθεί για την γρήγορη εξαγωγή των αποτελεσμάτων της επιλογής του βέλτιστου νευρωνικού ταξινομητή. Το πρόγραμμα ζητά από το χρήστη το όνομα του αρχείου με τα πρότυπα διανύσματα που πρόκειται να χρησιμοποιηθούν για την εκπαίδευση (training set), την επικύρωση (validation set) και την αξιολόγηση (test set) του νευρωνικού δικτύου. Ο χρήστης επίσης καθορίζει την τοπολογία του δικτύου κατά την αρχικοποίηση (επίπεδα και πλήθος νευρώνων σε καθένα από αυτά), καθώς επίσης τους δύο συντελεστές μάθησης ( $\lambda$ ,  $\mu$ ), το μέγιστο πλήθος επαναλήψεων στη φάση εκπαίδευσης και το όριο προώρου τερματισμού στο σύνολο επικύρωσης. Ο χρήστης μπορεί να χρησιμοποιήσει κάποιο αρχείο αυτόματης εισόδου των ζητούμενων από το πρόγραμμα παραμέτρων (response file), όμοιο με αυτό που χρησιμοποιείται από την έκδοση γραφικού περιβάλλοντος. Σε τακτά χρονικά διαστήματα κατά τη διάρκεια, καθώς και μετά την ολοκλήρωση της διαδικασίας εκπαίδευσης, ολόκληρη η τοπολογία και η τρέχουσα διαμόρφωση του δικτύου αποθηκεύεται σε αρχείο κειμένου.



```

Γραμμή εντολών MS-DOS
#iter=535 of 1000 , recogn= 252 of 253, trainerr=0.014097 , validated= 97.44%
#iter=536 of 1000 , recogn= 252 of 253, trainerr=0.014082 , validated= 97.45%
#iter=537 of 1000 , recogn= 252 of 253, trainerr=0.014066 , validated= 97.45%
#iter=538 of 1000 , recogn= 253 of 253, trainerr=0.014051 , validated= 97.46%

Finished training. Start testing.....

+-----+-----+-----+
| #patterns tested      #patterns recongised      #failures      |
+-----+-----+-----+
|              5005              4765              240      |
+-----+-----+-----+
| Percentages:              95.205%              4.795%      |
+-----+-----+-----+
| Learning coefficient: 0.150      Momentum coefficient: 0.050      |
+-----+-----+-----+

Saving optimal network into file...
Saving current network in file (bpm_net.txt)...
Closing patterns files...
De-allocating network structure...

Process terminated successfully. Exit to system.
C:\Harry\Lesson\Medic\Ann32\Develop\Bpm40>

```

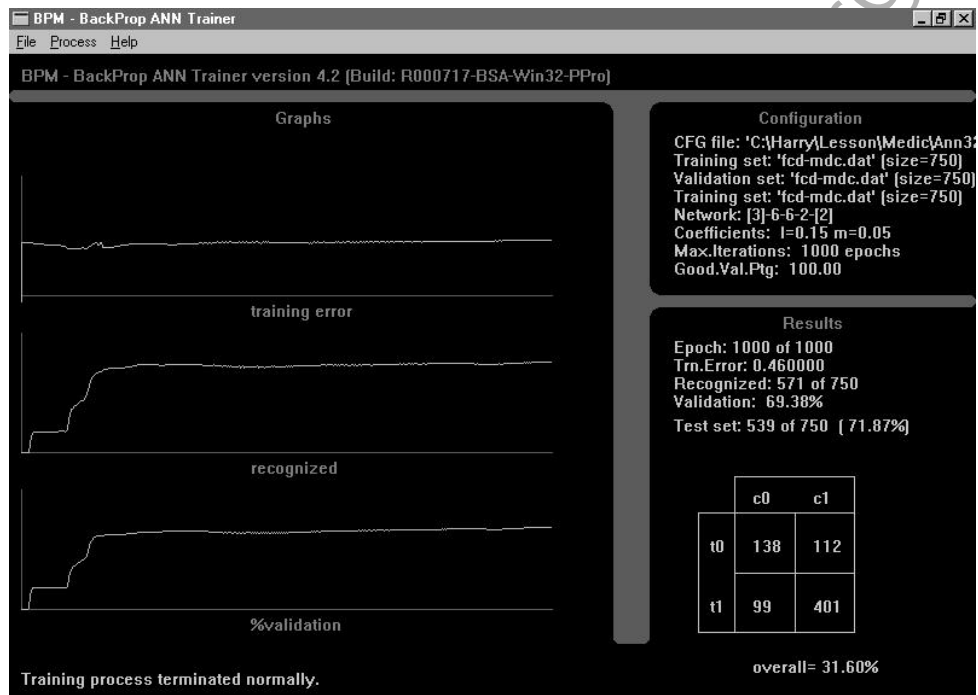
Σχήμα 2.10: BPM - Εικόνα προγράμματος κονσόλας

#### 2.2.3.4 Έκδοση γραφικού περιβάλλοντος

Η έκδοση γραφικού περιβάλλοντος (bpmw.exe) μπορεί να χρησιμοποιηθεί για την εύκολη επισκόπηση των αποτελεσμάτων της επεξεργασίας. Στο παράθυρο της εφαρμογής εμφανίζονται τρία διαγράμματα που παρουσιάζουν την τρέχουσα απόδοση του ταξινομητή. Το πρόγραμμα περιμένει από το χρήστη τα επiléξει κάποιο αρχείο εισόδου, το οποίο χρησιμοποιείται για τη διαμόρφωση του περιβάλλοντος και έχει ακριβώς την ίδια μορφή με το αντίστοιχο αρχείο αυτόματης εισόδου που χρησιμοποιείται στην έκδοση κονσόλας. Από το αρχείο διαμόρφωσης καθορίζονται όλες οι απαραίτητες παράμετροι, δηλαδή τα αρχεία προτύπων εκπαίδευσης, επικύρωσης και αξιολόγησης, η τοπολογία του δικτύου, οι συντελεστές μάθησης και οι συνθήκες τερματισμού. Όπως και στην έκδοση κονσόλας, ολόκληρη η τοπολογία και η τρέχουσα διαμόρφωση του δικτύου αποθηκεύεται σε αρχείο κειμένου.

Ο χρόνος ολοκλήρωσης του κάθε κύκλου εκπαίδευσης παρουσιάζει δραματικές διαφοροποιήσεις ανάλογα με την εκάστοτε διαμόρφωση του συστήματος και εξαρτάται από την τρέχουσα τοπολογία του δικτύου, καθώς και το μέγεθος των συνόλων εκπαίδευσης και επικύρωσης. Επειδή είναι πιθανό ο κάθε κύκλος εκπαίδευσης να ολοκληρώνεται γρηγορότερα από το χρόνο που απαιτείται για την ανανέωση των περιεχομένων του παραθύρου της εφαρμογής, αυτό θα έχει σαν αποτέλεσμα την καθυστέρηση της όλης φάσης εκπαίδευσης. Για το λόγο αυτό, υπάρχει δυνατότητα ρύθμισης του πλήθους των κύκλων που μεσολαβούν μεταξύ της ενημέρωσης του παραθύρου της εφαρμογής (αν κάτι τέτοιο κρίνεται απαραίτητο) μέσω του αρχείου διαμόρφωσης (bpmw.ini), έτσι ώστε ο απαιτούμενος χρόνος ανανέωσης του παραθύρου της εφαρμογής να αποτελεί πολύ μικρό ποσοστό σε σχέση με το συνολικό χρόνο επεξεργασίας. Η

εξ' ορισμού ρύθμιση είναι 1, δηλαδή ενημέρωση του παραθύρου (γραφήματα) με την ολοκλήρωση κάθε κύκλου εκπαίδευσης.



**Σχήμα 2.11:** BPMW - Εικόνα προγράμματος GUI

#### 2.2.3.5 Αρχιτεκτονική και δομή

Το πρόγραμμα της εφαρμογής λειτουργεί σε τρεις φάσεις. Κατά την πρώτη φάση διαβάζονται οι παράμετροι λειτουργίας και διαμορφώνεται το περιβάλλον επεξεργασίας, κατά τη δεύτερη φάση εκτελείται η εκπαίδευση (σύγκλιση) του συστήματος, ενώ κατά την τρίτη φάση εκτελείται η αξιολόγηση του τελικού ταξινομητή με βάση την απόδοση στο σύνολο προτύπων αξιολόγησης.

Σε πρώτη φάση καθορίζονται τα αρχεία εκπαίδευσης (training set), επικύρωσης (validation set) και αξιολόγησης (testing set). Τα δύο πρώτα χρησιμοποιούνται από κοινού στη φάση της εκπαίδευσης, ενώ το τρίτο στη φάση της αξιολόγησης της απόδοσης του τελικού ταξινομητή.

Η τοπολογία του δικτύου βασίζεται στο πρότυπο του πολυεπίπεδου Perceptron (MLP) και ο αλγόριθμος εκπαίδευσης που χρησιμοποιείται είναι ο κλασικός αλγόριθμος Back-Propagation. Η τοπολογία κατασκευάζεται δυναμικά κατά την αρχικοποίηση, υλοποιώντας πλήρως διασυνδεδεμένα επίπεδα νευρώνων.

Η εκπαίδευση του δικτύου γίνεται με την εφαρμογή του αλγορίθμου Back-Propagation με momentum για επιτάχυνση της σύγκλισης. Κατά τη φάση της εκπαίδευσης τα εκπαιδευτικά πρότυπα εφαρμόζονται στο δίκτυο και τροποποιούν κατάλληλα τα βάρη των νευρώνων ώστε να υπάρξει σύγκλιση, δηλαδή σωστή ταξινόμησή τους από το σύστημα. Επειδή μια πολύ σημαντική ιδιότητα στους νευρωνικούς ταξινομητές είναι η ικανότητα γενίκευσης (σωστή συμπεριφορά για άγνωστα πρότυπα), για να εξασφαλιστεί η σωστή, αλλά όχι υπερβολική (over-training), σύγκλιση κατά τη φάση εκπαίδευσης, το σύνολο επικύρωσης χρησιμοποιείται για το συνεχή έλεγχο της απόδοσης με άγνωστα πρότυπα. Σε κάθε μεταβολή των βαρών με την εφαρμογή εκπαιδευτικών προτύπων στο δίκτυο, ελέγχεται παράλληλα η απόδοση του δικτύου στο σύνολο επικύρωσης, το οποίο περιλαμβάνει πρότυπα ξένα ως προς το σύνολο που χρησιμοποιείται για την εκπαίδευση του δικτύου. Συνήθως τα διαθέσιμα πρότυπα εισόδου διαχωρίζονται με τυχαίο τρόπο σε δύο ίσα σύνολα, το ένα εκ των οποίων χρησιμοποιείται ως σύνολο εκπαίδευσης και το άλλο ως σύνολο επικύρωσης. Η τεχνική αυτή είναι γνωστή ως μέθοδος Leave-Half-Out (LHO) και εφαρμόζεται σε περιπτώσεις όπου η τεχνική Leave-One-Out είναι ασύμφορη λόγω μεγάλου κόστους σε χρόνο, όπως στην περίπτωση της εκπαίδευσης των νευρωνικών δικτύων MLP (BackProp). Με τη χρήση του συνόλου επικύρωσης κατά τη διαδικασία εκπαίδευσης, η εφαρμογή είναι σε θέση να διατηρεί αντίγραφο από τη διαμόρφωση με τη μεγαλύτερη απόδοση στο σύνολο επικύρωσης (καλύτερη γενίκευση), το οποίο τελικά παράγεται ως έξοδος κατά την ολοκλήρωση της εκπαίδευσης. Με τον τρόπο αυτό η διαδικασία εκπαίδευσης προχωρά σύμφωνα με τα καθιερωμένα, αλλά μονάχα οι μεταβολές που οδηγούν σε θετικά αποτελέσματα (μείωση απόλυτου σφάλματος) υιοθετούνται σε κάθε εκπαιδευτικό κύκλο.

Οι συνθήκες τερματισμού της φάσης εκπαίδευσης είναι τρεις. Στην πρώτη περίπτωση η εκπαίδευση σταματά όταν όλα τα πρότυπα εκπαίδευσης αναγνωρίζονται σωστά. Στη δεύτερη περίπτωση το ποσοστό επιτυχίας στο σύνολο επικύρωσης έχει ξεπεράσει το προκαθορισμένο από το χρήστη όριο (για παράδειγμα 95%). Η επιλογή αυτή είναι χρήσιμη όταν απαιτείται μεγάλη ικανότητα γενίκευσης ή όταν το κόστος πλήρους σύγκλισης είναι μεγάλο, πιθανότατα όταν τα σύνολα προτύπων είναι πολύ μεγάλα σε πλήθος προτύπων. Στην τρίτη περίπτωση ο τρέχον αριθμός εκπαιδευτικού κύκλου έχει ξεπεράσει το ανώτατο όριο εκπαιδευτικών κύκλων που έχει οριστεί από τον χρήστη. Η επιλογή αυτή είναι χρήσιμη όταν απαιτείται η ολοκλήρωση της διαδικασίας μέσα σε καθορισμένο χρονικό περιθώριο, ή για την πρόωρη διακοπή της εκπαίδευσης χωρίς πλήρη σύγκλιση.

Μετά την ολοκλήρωση της φάσης εκπαίδευσης (με οποιοδήποτε τρόπο), ακολουθεί η φάση της αξιολόγησης του τελικού ταξινομητή. Για το σκοπό αυτό χρησιμοποιείται το σύνολο αξιολόγησης, το οποίο, επειδή παρουσιάζεται μία φορά στο δίκτυο, μπορεί να είναι πολύ μεγαλύτερο σε μέγεθος και εντελώς ξένο από τα δύο άλλα σύνολα που χρησιμοποιήθηκαν κατά την εκπαίδευση. Αν το σύνολο αξιολόγησης είναι αρκετά αντιπροσωπευτικό του χώρου των διανυσμάτων εισόδου, τότε κατά τη φάση αυτή μπορούν να εξαχθούν ουσιαστικά συμπεράσματα σχετικά με τη γενικότερη απόδοση του τελικού ταξινομητή.

Για την επιτάχυνση της επεξεργασίας σε κάθε φάση, τα πρότυπα των τριών συνόλων μεταφέρονται εξ' ολοκλήρου στην κύρια μνήμη σε κατάλληλα διαμορφωμένες περιοχές ενδιάμεσης αποθήκευσης. Η συνάρτηση μεταφοράς που χρησιμοποιείται στους νευρώνες του δικτύου είναι η κλασική σιγμοειδής.

#### 2.2.4 MLP: Neural Network Executor

##### 2.2.4.1 Εισαγωγή

Το πρόγραμμα MLP αποτελεί το βοηθητικό εργαλείο για την αξιολόγηση και πρακτική χρήση νευρωνικών δικτύων που έχουν προηγουμένως σχεδιαστεί και εκπαιδευτεί από το αντίστοιχο πρόγραμμα του πακέτου (BPM). Η εφαρμογή είναι ανεπτυγμένη με τέτοιο τρόπο ώστε η χρησιμότητα και η πρακτική εφαρμογή της να μπορεί να επεκταθεί εύκολα σε κάθε είδους εφαρμογή που χρησιμοποιεί δομές νευρωνικών ταξινομητών με βάση κάποια πρότυπα διανύσματα.

##### 2.2.4.2 Λειτουργία

Η εφαρμογή διατίθεται σε μία έκδοση, αυτή της κονσόλας. Η έκδοση κονσόλα (mlp.exe) λειτουργεί σε περιβάλλον κελύφους συστήματος (MS-DOS shell) και η διεπαφή με το χρήστη είναι κονσόλα τερματικού σταθμού, δηλαδή βασισμένη σε χαρακτήρες. Μπορεί να χρησιμοποιηθεί για την αξιολόγηση ενός ήδη εκπαιδευμένου δικτύου σε σχέση με πολλά διαφορετικά σύνολα αξιολόγησης, χωρίς να είναι απαραίτητη η εκτέλεση ολόκληρης της διαδικασίας εκπαίδευσης και αξιολόγησης μέσω του αντίστοιχου προγράμματος (brpm.exe).

Το πρόγραμμα ζητά από το χρήστη το όνομα του αρχείου διαμόρφωσης του δικτύου που περιλαμβάνει την τοπολογία και τις τελικές παραμέτρους (βάρη), όπως καθορίστηκαν μετά την ολοκλήρωση της διαδικασίας εκπαίδευσης. Ο χρήστης στη συνέχεια καθορίζει την συνάρτηση μεταφοράς και τον τρόπο υπολογισμού των εξόδων του δικτύου. Για τη συνάρτηση μεταφοράς υπάρχουν δύο επιλογές, η τυπική σιγμοειδής και η υπερβολική εφραπτομένη, όμως σε κάθε περίπτωση η συνάρτηση μεταφοράς πρέπει να είναι η ίδια με αυτή που χρησιμοποιήθηκε κατά την φάση εκπαίδευσης. Για τον υπολογισμό της εξόδου, υπάρχει η επιλογή για υπολογισμό της απόλυτης (κανονικής) ή κβαντισμένης τιμής. Ο χρήστης επιπλέον επιλέγει το αρχείο εισόδου που περιέχει το σύνολο των προτύπων αξιολόγησης, καθώς και το μέγεθος (πλήθος διανυσμάτων). Τέλος, για την εκτέλεση του προγράμματος υπάρχουν δύο καταστάσεις. Η μία χρησιμοποιείται στην περίπτωση που το σύνολο εισόδου περιλαμβάνει ζεύγη διανυσμάτων εισόδου και επιθυμητής εξόδου, όπως αυτά που χρησιμοποιούνται για την εκπαίδευση του δικτύου, και επιλέγεται στην περίπτωση που ο χρήστης επιθυμεί την αξιολόγηση του ταξινομητή με βάση κάποιο σύνολο εκπαίδευσης. Η δεύτερη χρησιμοποιείται στην περίπτωση που το σύνολο εισόδου περιλαμβάνει μόνο διανύσματα εισόδου και ο χρήστης επιθυμεί να λάβει την έξοδο του ταξινομητή για τα άγνωστα αυτά διανύσματα. Στην πρώτη περίπτωση, με την ολοκλήρωση της εκτέλεσης δίνονται στατιστικές πληροφορίες σχετικά με το

ποσοστό επιτυχίας του ταξινομητή, ενώ στη δεύτερη μονάχα οι κατηγορίες οι οποίες επιλέχθηκαν για κάθε άγνωστο διάνυσμα εισόδου.

```

Γραμμή εντολών MS-DOS
( 1):0.752 ( 2):0.248
.....
..... Prediction pattern #5004 of 5005 .....
Network output (sorted):
( 1):0.997 ( 2):0.003
.....
..... Prediction pattern #5005 of 5005 .....
Network output (sorted):
( 1):0.843 ( 2):0.157
.....
Execution process completed!
Mode: PREDICTION
Patterns evaluated: 5005

Sigmoid: Standard
Output: Absolute

Closing all files... done!
De-allocating memory... done!

C:\Harry\Lesson\Medic\bin>
    
```

**Σχήμα 2.12:** MLP - Εικόνα προγράμματος κονσόλας

## 2.2.5 SHUFFLE: Patterns Set Randomizer

### 2.2.5.1 Εισαγωγή

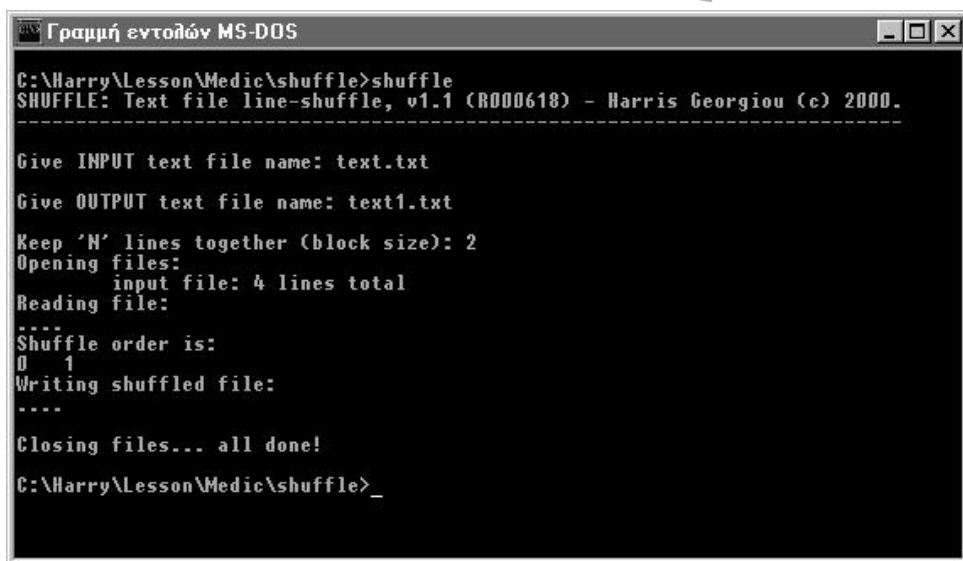
Το πρόγραμμα SHUFFLE αποτελεί το βοηθητικό εργαλείο για την προετοιμασία των αρχείων των προτύπων εκπαίδευσης, πριν τη χρησιμοποίησή τους από την αντίστοιχη εφαρμογή σχεδίασης και εκπαίδευσης του νευρωνικού δικτύου. Η προεπεξεργασία των συνόλων εκπαίδευσης δεν είναι υποχρεωτική, αλλά σε μερικές περιπτώσεις προτείνεται για την καλύτερη σύγκλιση κατά της φάση της εκπαίδευσης. Η εφαρμογή είναι ανεπτυγμένη με τέτοιο τρόπο ώστε η χρησιμότητα και η πρακτική εφαρμογή της να μπορεί να επεκταθεί εύκολα σε αρχεία κειμένου με πρότυπα εισόδου-εξόδου μορφής μίας, δύο ή περισσότερων γραμμών.

### 2.2.5.2 Λειτουργία

Η εφαρμογή διατίθεται σε μία έκδοση, αυτή της κονσόλας. Η έκδοση κονσόλας (shuffle.exe) λειτουργεί σε περιβάλλον κελύφους συστήματος (MS-DOS shell) και η διεπαφή με το χρήστη είναι κονσόλα τερματικού σταθμού, δηλαδή βασισμένη σε χαρακτήρες. Μπορεί να χρησιμοποιηθεί για την

αναδιάταξη με τυχαίο τρόπο των προτύπων εισόδου-εξόδου πριν τη χρησιμοποίησή τους από κάποιο πρόγραμμα σχεδίασης γραμμικού ή μη γραμμικού ταξινομητή.

Το πρόγραμμα ζητά από το χρήστη το όνομα του αρχείου εισόδου με τα εκπαιδευτικά πρότυπα, το όνομα του αρχείου προορισμού με το νέο σύνολο προτύπων, καθώς και το πλήθος των γραμμών κειμένου που αποτελούν το εκάστοτε πρότυπο. Το πρόγραμμα σχεδίασης του γραμμικού ταξινομητή (FCD) χρησιμοποιεί αρχεία εισόδου με ένα πρότυπο ανά γραμμή κειμένου, ενώ το πρόγραμμα του νευρωνικού ταξινομητή (BPM) χρησιμοποιεί αρχεία εισόδου με ένα πρότυπο ανά δύο γραμμές κειμένου. Με τον τρόπο αυτό η τυχαία αναδιάταξη προτύπων γίνεται κατά τρόπο τέτοιο ώστε να μην επηρεάζονται οι εξαρτήσεις μεταξύ διαδοχικών διανυσμάτων στο αρχείο εισόδου.



```
Γραμμή εντολών MS-DOS

C:\Harry\Lesson\Medic\shuffle>shuffle
SHUFFLE: Text file line-shuffle, v1.1 (R000618) - Harris Georgiou (c) 2000.
-----
Give INPUT text file name: text.txt
Give OUTPUT text file name: text1.txt
Keep 'N' lines together (block size): 2
Opening files:
    input file: 4 lines total
Reading file:
****
Shuffle order is:
0 1
Writing shuffled file:
****
Closing files... all done!
C:\Harry\Lesson\Medic\shuffle>_
```

**Σχήμα 2.13:** SHUFFLE - Εικόνα προγράμματος κονσόλας

Copyright (c) 2012, Harris V. Georgiou

## **Μέρος – 3**

### **Παρουσίαση & Σχολιασμός Αποτελεσμάτων**

#### **3.1 Παρουσίαση & Αξιολόγηση Αποτελεσμάτων**

##### **3.1.1 Διατύπωση Στόχων**

Βασικός στόχος της παρούσας εργασίας στο σύνολό της αποτελεί η μελέτη εφικτότητας σχετικά με την εφαρμογή αρχιτεκτονικών αναγνώρισης προτύπων για την κατασκευή συστήματος αυτόματης ανάλυσης και χαρακτηρισμού παθολογίας σε υπερηχογραφικές εικόνες ανθρώπινου ήπατος. Η μελέτη εφικτότητας βασίστηκε σε δύο κατηγορίες ταξινομητών, τον γραμμικό ταξινομητή ελάχιστης απόστασης και τον μη γραμμικό ταξινομητή νευρωνικού δικτύου τύπου MLP για την αξιολόγηση της αυτόματης κατηγοριοποίησης των δειγμάτων ιστού από τα δεδομένα της ψηφιοποιημένης εικόνας.

Η μελέτη υλοποίησης και πρακτικής εφαρμογής των δύο ταξινομητών έγινε από κοινού, αφ' ενός για τη δυνατότητα συγκριτικής αξιολόγησής τους στο συγκεκριμένο πρόβλημα, και αφ' ετέρου για την καλύτερη εξέταση των ιδιαίτερων ιδιοτήτων που διέπουν το συγκεκριμένο πρόβλημα. Συγκεκριμένα, οι βασικοί στόχοι που τέθηκαν από την αρχή της μελέτης είναι οι παρακάτω:

- Μελέτη εφικτότητας: δυνατότητα κατασκευής ταξινομητών με πρακτική χρησιμότητα
- Συγκριτική απόδοση γραμμικών και μη γραμμικών μεθόδων για τους ταξινομητές
- Αναγνώριση, αν υπάρχει, συγκεκριμένου συνόλου χαρακτηριστικών παραμέτρων ταξινόμησης

Το πρώτο ζήτημα αναφέρεται στην γενικότερη μελέτη εφικτότητας για ένα σύστημα ανάλυσης και αυτόματου χαρακτηρισμού παθολογίας για το συγκεκριμένο πρόβλημα. Το πεδίο έρευνας αφορά κυρίως χαρακτηριστικά υψής σε δεδομένα της ψηφιοποιημένης εικόνας και περιλαμβάνει 20 χαρακτηριστικές παραμέτρους ποσοτικής περιγραφής της μέσω αντίστοιχων συναρτήσεων εξαγωγής χαρακτηριστικών υψής, όπως περιγράφηκαν στο θεωρητικό μέρος της εργασίας. Παρόλο που τα χαρακτηριστικά υψής θεωρούνται πολύ αποτελεσματικά σε προβλήματα χαρακτηρισμού παθολογίας σε υπερηχογραφικές εικόνες ήπατος, είναι λίγες οι μελέτες που εξετάζουν το ζήτημα διεξοδικά και σε σχέση με την πραγματική απόδοση ταξινομητών, και



επιπλέον οι περισσότερες από αυτές αναφέρονται μόνο σε παραλλαγές του κλασικού ταξινομητή ελάχιστης απόστασης [05].

Το δεύτερο ζήτημα αναφέρεται ακριβώς στην πρακτική εφαρμογή και στην αξιολόγηση της απόδοσης των δύο ταξινομητών, τόσο ξεχωριστά όσο και σε σύγκριση μεταξύ τους. Σε αυτό το στάδιο μελέτης μπορεί να διαπιστωθεί εν μέρει η πολυπλοκότητα του προβλήματος και η χρησιμότητα μη γραμμικών τεχνικών όπως τα νευρωνικά δίκτυα για την κατασκευή του ταξινομητή.

Το τρίτο και τελευταίο ζήτημα είναι η διερεύνηση της δυνατότητας καθορισμού ενός σταθερού υποσυνόλου χαρακτηριστικών παραμέτρων που να εμφανίζει σταθερά ικανοποιητική απόδοση ως προς τη διαχωριστική ικανότητα που προσφέρει. Η διερεύνηση γίνεται σε σχέση με το εκάστοτε σύνολο χαρακτηριστικών που επιλέγεται κατά το στάδιο της εφαρμογής στατιστικών μεθόδων δοκιμής (T-test), καθώς επίσης και την σχετική απόδοση όμοιων ταξινομητών με διαφορετικά σύνολα εκπαίδευσης ως προς τη διάσταση και ως προς τα επιμέρους χαρακτηριστικά που περιλαμβάνουν.

### 3.1.2 Μεθοδολογία, Οργάνωση & Εξαγωγή Αποτελεσμάτων

Η διαδικασία οργάνωσης και εξαγωγής των αποτελεσμάτων αποτελείται από τέσσερις επιμέρους φάσεις μελέτης:

- Φάση Α: συγκριτική απόδοση MDC και NNC σε διαφορετικά επίπεδα διαχωρισμού και σύνολα εκπαίδευσης.
- Φάση Β: συγκριτική απόδοση NNC σε διαφορετικά επίπεδα διαχωρισμού με εφαρμογή της μεθόδου LHO.
- Φάση Γ: συγκριτική απόδοση NNC για 1 και 2 κρυμμένα επίπεδα νευρώνων με μεταβλητό μέγεθος, χρησιμοποιώντας το πλήρες MDC-optimum σύνολο εκπαίδευσης.
- Φάση Δ: συγκριτική απόδοση NNC για 1 και 2 κρυμμένα επίπεδα νευρώνων με μεταβλητό μέγεθος, με εφαρμογή της μεθόδου LHO στο πλήρες T-test selected σύνολο εκπαίδευσης.

Κάθε μια από τις παραπάνω φάσεις μελέτης στοχεύει στην ανάδειξη συγκεκριμένων παραμέτρων του προβλήματος, ανάλογα με τα σύνολα εκπαίδευσης, τη δομή του ταξινομητή και τους αλγορίθμους που εφαρμόζονται.

Η πρώτη φάση έχει σαν κύριο στόχο την κατασκευή των δύο ταξινομητών σε περιορισμένο πεδίο εφαρμογής ως προς το σύνολο εκπαίδευσης, με σκοπό από την μια πλευρά την αξιολόγηση του γραμμικού ταξινομητή ελάχιστης απόστασης ως βασικό επίπεδο αναφοράς και από την άλλη τη συγκριτική απόδοση του νευρωνικού ταξινομητή ως προς το τελικό ποσοστό επιτυχίας. Το επίπεδο διαχωρισμού αναφέρεται στις παραμέτρους που καθορίζουν τη διαφοροποίηση που προκύπτει στα προσομοιωμένα πρότυπα παθολογίας σε σχέση με τα φυσιολογικά, κατά την κατασκευή των συνόλων εκπαίδευσης για τους δύο ταξινομητές. Όσο ελαττώνεται το επίπεδο διαχωρισμού, τόσο αυξάνει η πολυπλοκότητα του προβλήματος της σωστής ταξινόμησης των προτύπων.

Η δεύτερη φάση αναφέρεται στην εφαρμογή αποκλειστικά του νευρωνικού ταξινομητή σε διαφορετικά επίπεδα διαχωρισμού και εκπαιδευτικά σύνολα, με σκοπό την καλύτερη αξιολόγηση της απόδοσης σε ευρύτερο πεδίο εφαρμογής του σε σχέση με την πρώτη φάση. Ταξινομητές βασισμένοι σε νευρωνικά δίκτυα φαίνεται να υπερτερούν σε σημαντικό βαθμό ως προς την απόδοση σε σχέση με αντίστοιχους ταξινομητές ελάχιστης απόστασης, κάτι που επιβεβαιώνεται από τα πρώτα αποτελέσματα της πρώτης φάσης της μελέτης. Επιπλέον, η εφαρμογή της μεθόδου Leave-Half-Out (LHO) δίνει μια πληρέστερη εικόνα ως προς την ικανότητα γενίκευσης παρόμοιων ταξινομητών για το συγκεκριμένο πρόβλημα.

Η τρίτη φάση αφορά στην εκτίμηση των γενικών ορίων μιας βέλτιστης τοπολογίας για το δίκτυο, χρησιμοποιώντας ως σύνολο εκπαίδευσης το ίδιο σύνολο που επιλέχθηκε κατά την κατασκευή του αντίστοιχου βέλτιστου ταξινομητή ελάχιστης απόστασης. Όπως και κατά την πρώτη φάση, είναι δυνατή η άμεση σύγκριση της απόδοσης των δύο ταξινομητών, αλλά κυρίως είναι εφικτός ο καθορισμός μιας (υπο-)βέλτιστης τοπολογίας για το νευρωνικό δίκτυο, πάντοτε με βάση μη αυτόματες μεθόδους δοκιμής και αξιολόγησης.

Η τέταρτη και τελευταία φάση περιλαμβάνει ουσιαστικά την ίδια διαδικασία έρευνας όπως και στο τρίτο στάδιο, χρησιμοποιώντας όμως ένα γενικότερο σύνολο εκπαίδευσης και εφαρμόζοντας τη μέθοδο LHO. Το γενικότερο σύνολο εκπαίδευσης περιλαμβάνει όλες τις χαρακτηριστικές παραμέτρους που αξιολογήθηκαν ως σημαντικές κατά το στάδιο των στατιστικών μεθόδων δοκιμής (T-test) και τα αντίστοιχα αποτελέσματα δίνουν μια πληρέστερη εικόνα ως προς την ποσότητα της επιπλέον πληροφορίας διαχωρισμού που προσφέρουν στην κατασκευή του νευρωνικού ταξινομητή. Η εφαρμογή της μεθόδου LHO χρησιμοποιείται και πάλι, όπως στη δεύτερη φάση, για μια πληρέστερη εικόνα ως προς την ικανότητα γενίκευσης παρόμοιων ταξινομητών για το συγκεκριμένο πρόβλημα.

Τα αναλυτικά αποτελέσματα παρουσιάζονται στις επόμενες ενότητες κατά σειρά διαδοχής ως προς τις αντίστοιχες φάσεις μελέτης στις οποίες αναφέρονται. Τα αποτελέσματα δίνουνται κυρίως συγκεντρωτικά σε μορφή συγκριτικών διαγραμμάτων, τόσο ως προς τις φάσεις μελέτης, όσο και ως προς τους επιμέρους ταξινομητές, καθώς το εκτεταμένο πλήθος των διαμορφώσεων δεν επιτρέπει την παρουσίαση των αποτελεσμάτων για κάθε διαμόρφωση ξεχωριστά.

### 3.1.3 Πληροφορίες Διαμόρφωσης & Παραμέτρων Εκπαίδευσης

Η κατασκευή των συνόλων εκπαίδευσης έγινε από κοινού και για τους δύο ταξινομητές, χρησιμοποιώντας αντίστοιχη μορφοποίηση των δεδομένων στα αντίστοιχα αρχεία εισόδου των προγραμμάτων κατασκευής τους. Τα πρότυπα εκπαίδευσης σε κάθε περίπτωση έχουν τη μορφή διανυσμάτων εισόδου με διάσταση και περιεχόμενα που καθορίζεται από την εκάστοτε διαμόρφωση. Συγκριτικά αποτελέσματα μεταξύ ταξινομητών ελάχιστης απόστασης και νευρωνικών ταξινομητών αναφέρονται στην ίδια διαμόρφωση ως προς το σύνολο των προτύπων εισόδου. Γενικά, από τα 20 χαρακτηριστικά που αποτελούν το πλήρες σύνολο των συνιστωσών που υπολογίζονται από τις αντίστοιχες συναρτήσεις, χρησιμοποιήθηκαν διαστάσεις μεταξύ 2 και 9, ανάλογα με την επιλογή που έγινε κατά το στάδιο στατιστικής δοκιμής (T-test). Η έξοδος

και στις δύο περιπτώσεις είναι διανύσματα που περιλαμβάνουν ενδείξεις σχετικά με την επιλεγμένη από τον κάθε ταξινομητή κλάση ταξινόμησης, ενώ η εκπαίδευση γίνεται χρησιμοποιώντας αντίστοιχη πληροφορία που περιλαμβάνεται στο σύνολο εκπαίδευσης.

Για την κατασκευή των προτύπων εκπαίδευσης χρησιμοποιήθηκαν δύο διαφορετικές διαμορφώσεις. Η πρώτη βασίζεται σε μεμονωμένη ψηφιοποιημένη υπερηχογραφική εικόνα και χρησιμοποιείται σε διαμορφώσεις όπου η μελέτη επικεντρώνεται περισσότερο στο απόλυτο επίπεδο επιτυχίας παρά στην ικανότητα γενίκευσης. Περιλαμβάνει 250 δείγματα της εικόνας σε αντίστοιχες περιοχές ενδιαφέροντος μεγέθους 5x5, εφαρμόζοντας προσομοίωση παθολογίας και των δύο τύπων, με προσθετικό (λιπώδης διήθηση) και αφαιρετικό (κίρρωση) επίπεδο διαχωρισμού. Τα 750 πρότυπα που κατασκευάζονται συνολικά αποτελούν το σύνολο εκπαίδευσης (set-A). Η δεύτερη διαμόρφωση βασίζεται σε όλες τις διαθέσιμες (3) υπερηχογραφικές εικόνες και χρησιμοποιείται σε διαμορφώσεις όπου η μελέτη επικεντρώνεται περισσότερο στην ικανότητα γενίκευσης παρά στο απόλυτο επίπεδο επιτυχίας. Περιλαμβάνει 250 δείγματα από κάθε εικόνα σε αντίστοιχες περιοχές ενδιαφέροντος μεγέθους 5x5, εφαρμόζοντας προσομοίωση παθολογίας και των δύο τύπων, με προσθετικό (λιπώδης διήθηση) και αφαιρετικό (κίρρωση) επίπεδο διαχωρισμού. Τα 2250 πρότυπα που κατασκευάζονται συνολικά αποτελούν το σύνολο εκπαίδευσης (set-B).

Αξίζει να σημειωθεί ότι, όπως έχει ήδη αναφερθεί στο θεωρητικό μέρος της μελέτης, τα νευρωνικά δίκτυα αποτελούν μη γραμμικό σύστημα προς βελτιστοποίηση ως προς το τελικό ποσοστό σφάλματος ταξινόμησης. Συνεπώς τα διαθέσιμα πρότυπα εκπαίδευσης θα πρέπει να ξεπερνούν σε πλήθος τις αντίστοιχες ελεύθερες παραμέτρους του συστήματος, δηλαδή το σύνολο των βαρών στην τρέχουσα τοπολογία, πολύ περισσότερο στην περίπτωση που απαιτείται υψηλό επίπεδο ικανότητας γενίκευσης για τον τελικό ταξινομητή. Το μέγεθος του συνόλου εκπαίδευσης σχετίζεται άμεσα με την τοπολογία του δικτύου, πάντα ως προς το συνολικό πλήθος των βαρών και σε καμία περίπτωση με τις διασυνδέσεις μεταξύ των νευρώνων. Ο παρακάτω πίνακας παρουσιάζει ενδεικτικά το ελάχιστο απαιτούμενο πλήθος εκπαιδευτικών προτύπων για τοπολογία 2 κρυμμένων επιπέδων ίδιου μεγέθους με πλήρη διασύνδεση μεταξύ τους, συναρτήσει της διάστασης του διανύσματος εισόδου και των κρυμμένων επιπέδων.

NEEDED PATTERNS FOR BPM TRAINING																				
Net = [Ki]x(Kn)x(Kn)x(2)																				
[ Kn \ Ki ]	1	2	3	4	5	6	7	8	9	10	11	12	13	14	15	16	17	18	19	20
1	8	9	10	11	12	13	14	15	16	17	18	19	20	21	22	23	24	25	26	27
2	16	18	20	22	24	26	28	30	32	34	36	38	40	42	44	46	48	50	52	54
3	26	29	32	35	38	41	44	47	50	53	56	59	62	65	68	71	74	77	80	83
4	38	42	46	50	54	58	62	66	70	74	78	82	86	90	94	98	102	106	110	114
5	52	57	62	67	72	77	82	87	92	97	102	107	112	117	122	127	132	137	142	147
6	68	74	80	86	92	98	104	110	116	122	128	134	140	146	152	158	164	170	176	182
7	86	93	100	107	114	121	128	135	142	149	156	163	170	177	184	191	198	205	212	219
8	106	114	122	130	138	146	154	162	170	178	186	194	202	210	218	226	234	242	250	258
9	128	137	146	155	164	173	182	191	200	209	218	227	236	245	254	263	272	281	290	299
10	152	162	172	182	192	202	212	222	232	242	252	262	272	282	292	302	312	322	332	342
11	178	189	200	211	222	233	244	255	266	277	288	299	310	321	332	343	354	365	376	387
12	206	218	230	242	254	266	278	290	302	314	326	338	350	362	374	386	398	410	422	434
13	236	249	262	275	288	301	314	327	340	353	366	379	392	405	418	431	444	457	470	483
14	268	282	296	310	324	338	352	366	380	394	408	422	436	450	464	478	492	506	520	534
15	302	317	332	347	362	377	392	407	422	437	452	467	482	497	512	527	542	557	572	587
16	338	354	370	386	402	418	434	450	466	482	498	514	530	546	562	578	594	610	626	642
17	376	393	410	427	444	461	478	495	512	529	546	563	580	597	614	631	648	665	682	699
18	416	434	452	470	488	506	524	542	560	578	596	614	632	650	668	686	704	722	740	758
19	458	477	496	515	534	553	572	591	610	629	648	667	686	705	724	743	762	781	800	819
20	502	522	542	562	582	602	622	642	662	682	702	722	742	762	782	802	822	842	862	882
21	548	569	590	611	632	653	674	695	716	737	758	779	800	821	842	863	884	905	926	947
22	596	618	640	662	684	706	728	750	772	794	816	838	860	882	904	926	948	970	992	1014
23	646	669	692	715	738	761	784	807	830	853	876	899	922	945	968	991	1014	1037	1060	1083
24	698	722	746	770	794	818	842	866	890	914	938	962	986	1010	1034	1058	1082	1106	1130	1154
25	752	777	802	827	852	877	902	927	952	977	1002	1027	1052	1077	1102	1127	1152	1177	1202	1227
26	808	834	860	886	912	938	964	990	1016	1042	1068	1094	1120	1146	1172	1198	1224	1250	1276	1302
27	866	893	920	947	974	1001	1028	1055	1082	1109	1136	1163	1190	1217	1244	1271	1298	1325	1352	1379
28	926	954	982	1010	1038	1066	1094	1122	1150	1178	1206	1234	1262	1290	1318	1346	1374	1402	1430	1458
29	988	1017	1046	1075	1104	1133	1162	1191	1220	1249	1278	1307	1336	1365	1394	1423	1452	1481	1510	1539
30	1052	1082	1112	1142	1172	1202	1232	1262	1292	1322	1352	1382	1412	1442	1472	1502	1532	1562	1592	1622
31	1118	1149	1180	1211	1242	1273	1304	1335	1366	1397	1428	1459	1490	1521	1552	1583	1614	1645	1676	1707
32	1186	1218	1250	1282	1314	1346	1378	1410	1442	1474	1506	1538	1570	1602	1634	1666	1698	1730	1762	1794
33	1256	1289	1322	1355	1388	1421	1454	1487	1520	1553	1586	1619	1652	1685	1718	1751	1784	1817	1850	1883
34	1328	1362	1396	1430	1464	1498	1532	1566	1600	1634	1668	1702	1736	1770	1804	1838	1872	1906	1940	1974
35	1402	1437	1472	1507	1542	1577	1612	1647	1682	1717	1752	1787	1822	1857	1892	1927	1962	1997	2032	2067
36	1478	1514	1550	1586	1622	1658	1694	1730	1766	1802	1838	1874	1910	1946	1982	2018	2054	2090	2126	2162
37	1556	1593	1630	1667	1704	1741	1778	1815	1852	1889	1926	1963	2000	2037	2074	2111	2148	2185	2222	2259
38	1636	1674	1712	1750	1788	1826	1864	1902	1940	1978	2016	2054	2092	2130	2168	2206	2244	2282	2320	2358
39	1718	1757	1796	1835	1874	1913	1952	1991	2030	2069	2108	2147	2186	2225	2264	2303	2342	2381	2420	2459
40	1802	1842	1882	1922	1962	2002	2042	2082	2122	2162	2202	2242	2282	2322	2362	2402	2442	2482	2522	2562
41	1888	1929	1970	2011	2052	2093	2134	2175	2216	2257	2298	2339	2380	2421	2462	2503	2544	2585	2626	2667
42	1976	2018	2060	2102	2144	2186	2228	2270	2312	2354	2396	2438	2480	2522	2564	2606	2648	2690	2732	2774
43	2066	2109	2152	2195	2238	2281	2324	2367	2410	2453	2496	2539	2582	2625	2668	2711	2754	2797	2840	2883
44	2158	2202	2246	2290	2334	2378	2422	2466	2510	2554	2598	2642	2686	2730	2774	2818	2862	2906	2950	2994
45	2252	2297	2342	2387	2432	2477	2522	2567	2612	2657	2702	2747	2792	2837	2882	2927	2972	3017	3062	3107
46	2348	2394	2440	2486	2532	2578	2624	2670	2716	2762	2808	2854	2900	2946	2992	3038	3084	3130	3176	3222
47	2446	2493	2540	2587	2634	2681	2728	2775	2822	2869	2916	2963	3010	3057	3104	3151	3198	3245	3292	3339
48	2546	2594	2642	2690	2738	2786	2834	2882	2930	2978	3026	3074	3122	3170	3218	3266	3314	3362	3410	3458
49	2648	2697	2746	2795	2844	2893	2942	2991	3040	3089	3138	3187	3236	3285	3334	3383	3432	3481	3530	3579
50	2752	2802	2852	2902	2952	3002	3052	3102	3152	3202	3252	3302	3352	3402	3452	3502	3552	3602	3652	3702

**Σχήμα 3.1:** Πίνακας απαιτούμενου μεγέθους συνόλου εκπαίδευσης για τοπολογία 2 κρυμμένων νευρωνικών επιπέδων

### 3.1.4 Αναλυτικά Αποτελέσματα

#### 3.1.4.1 Φάση Α – Αποτελέσματα

Η πρώτη φάση αναφέρεται στη συγκριτική απόδοση MDC και NNC σε διαφορετικά επίπεδα διαχωρισμού και σύνολα εκπαίδευσης. Τα επιμέρους στάδια εκτέλεσης είναι τα εξής:

1. Κατασκευή των προτύπων εκπαίδευσης με βάση ψηφιοποιημένη υπερηχογραφική εικόνα, σε επίπεδα διαχωρισμού (sp) 5%, 10% και 20%. Εφαρμογή όλων των διαθέσιμων (20) συναρτήσεων εξαγωγής χαρακτηριστικών.
2. Κατασκευή και αξιολόγηση ταξινομητών MDC για κάθε επίπεδο διαχωρισμού (5%, 10%, 20%)
3. Κατασκευή και αξιολόγηση ταξινομητών NNC για κάθε επίπεδο διαχωρισμού, με βάση το MDC-optimum σύνολο εκπαίδευσης.
4. Κατασκευή και αξιολόγηση ταξινομητών NNC για κάθε επίπεδο διαχωρισμού, με βάση το πλήρες T-test selected σύνολο εκπαίδευσης.


Τα συγκριτικά αποτελέσματα της φάσης αυτής παρουσιάζονται παρακάτω σε συγκεντρωτικό διάγραμμα, μαζί με τα αποτελέσματα της δεύτερης φάσης.

#### 3.1.4.2 Φάση Β – Αποτελέσματα

Η δεύτερη φάση αναφέρεται στη συγκριτική απόδοση NNC σε διαφορετικά επίπεδα διαχωρισμού με εφαρμογή της μεθόδου LHO. Τα επιμέρους στάδια εκτέλεσης είναι τα εξής:

1. Κατασκευή των συνόλων εκπαίδευσης για εφαρμογή με τη μέθοδο LHO. Τα διαθέσιμα πρότυπα διαχωρίζονται με τυχαίο τρόπο σε σύνολο εκπαίδευσης (50%) και σύνολο επικύρωσης (50%), ενώ ως σύνολο τελικής αξιολόγησης χρησιμοποιούνται όλα τα διαθέσιμα πρότυπα (100%).
2. Κατασκευή και αξιολόγηση ταξινομητών NNC για κάθε επίπεδο διαχωρισμού, με βάση το πλήρες T-test selected σύνολο εκπαίδευσης που προκύπτει από όλες τις διαθέσιμες υπερηχογραφικές εικόνες.

Για τα αντίστοιχα νευρωνικά δίκτυα χρησιμοποιήθηκε στατική τοπολογία με δύο κρυμμένα επίπεδα μεγέθους 6 νευρώνων το καθένα. Τα συγκριτικά αποτελέσματα της φάσης αυτής, καθώς και της πρώτης, παρουσιάζονται στο παρακάτω συγκεντρωτικό διάγραμμα.



**Σχήμα 3.2:** Διάγραμμα 1 = MDC & NNC classifiers

#### 3.1.4.3 Φάση Γ – Αποτελέσματα

Η τρίτη φάση αναφέρεται στη συγκριτική απόδοση NNC για 1 και 2 κρυμμένα επίπεδα νευρώνων με μεταβλητό μέγεθος (n), χρησιμοποιώντας το πλήρες MDC-optimum (mdc\_all) σύνολο εκπαίδευσης. Τα επιμέρους στάδια εκτέλεσης είναι τα εξής:

Για 1 κρυμμένο νευρωνικό επίπεδο:

1. Δοκιμή τοπολογίας 1 κρυμμένου νευρωνικού επιπέδου για κάθε επίπεδο διαχωρισμού ξεχωριστά (5%, 10%, 20%).
2. Δοκιμή τοπολογίας για 4 διαφορετικά μεγέθη του κρυμμένου νευρωνικού επιπέδου (5, 10, 15, 20) σε επίπεδο διαχωρισμού 10%.
3. Καθορισμός βέλτιστου μεγέθους για το κρυμμένο επίπεδο με βάση την απόδοση στο προηγούμενο βήμα.
4. Τελική αξιολόγηση δικτύου για βέλτιστο μέγεθος κρυμμένου επιπέδου σε επίπεδο διαχωρισμού 10%.


Για 2 κρυμμένα νευρωνικά επίπεδα:

5. Δοκιμή τοπολογίας 2 κρυμμένων νευρωνικών επιπέδων ίδιου μεγέθους για κάθε επίπεδο διαχωρισμού ξεχωριστά (5%, 10%, 20%).

6. Δοκιμή τοπολογίας για 4 διαφορετικά μεγέθη των κρυμμένων νευρωνικών επιπέδων (5, 10, 15, 20) σε επίπεδο διαχωρισμού 10%.
7. Καθορισμός βέλτιστου μεγέθους για τα κρυμμένα επίπεδα με βάση την απόδοση στο προηγούμενο βήμα.
8. Τελική αξιολόγηση δικτύου για βέλτιστο μέγεθος κρυμμένων επιπέδων σε επίπεδο διαχωρισμού 10%.

Ο καθορισμός του επιπέδου διαχωρισμού 10% ως βασικό όριο για την εκπαίδευση όλων των διαμορφώσεων επιλέχθηκε με βάση τα αποτελέσματα της παρούσας και της προηγούμενης φάσης, καθώς για επίπεδα διαχωρισμού πάνω από 10% το πρόβλημα φαίνεται να γίνεται αρκετά απλό και οποιαδήποτε αρχιτεκτονική για τον ταξινομητή δίνει πολύ υψηλά ποσοστά επιτυχίας. Η επιλογή των ορίων διακύμανσης του μεγέθους των κρυμμένων επιπέδων επιλέχθηκε με βάση προηγούμενη εμπειρία σε εφαρμογή αρχιτεκτονικών νευρωνικών δικτύων σε αντίστοιχα προβλήματα αναγνώρισης προτύπων, καθώς επίσης και από τις αντίστοιχες απαιτήσεις σε χρόνο ολοκλήρωσης της εκπαίδευσης, καθώς για μεγέθη επιπέδων από 15 νευρώνες και πάνω η διαδικασία εκπαίδευσης γίνεται εξαιρετικά πολύπλοκη.

Τα συγκριτικά αποτελέσματα της φάσης αυτής παρουσιάζονται στο παρακάτω συγκεντρωτικό διάγραμμα.



**Σχήμα 3.3:** Διάγραμμα 2 = NNC classifiers, mdc\_all

#### 3.1.4.4 Φάση Δ – Αποτελέσματα

Η τέταρτη φάση αναφέρεται στη συγκριτική απόδοση NNC για 1 και 2 κρυμμένα επίπεδα νευρώνων με μεταβλητό μέγεθος ( $n$ ), με εφαρμογή της μεθόδου LHO στο πλήρες T-test selected ( $sel\_lho$ ) σύνολο εκπαίδευσης. Τα επιμέρους στάδια εκτέλεσης είναι παρόμοια με αυτά της τρίτης φάσης και είναι τα εξής:

Για 1 κρυμμένο νευρωνικό επίπεδο:

1. Δοκιμή τοπολογίας 1 κρυμμένου νευρωνικού επιπέδου για κάθε επίπεδο διαχωρισμού ξεχωριστά (5%, 10%, 20%).
2. Δοκιμή τοπολογίας για 4 διαφορετικά μεγέθη του κρυμμένου νευρωνικού επιπέδου (5, 10, 15, 20) σε επίπεδο διαχωρισμού 10%.
3. Καθορισμός βέλτιστου μεγέθους για το κρυμμένο επίπεδο με βάση την απόδοση στο προηγούμενο βήμα.
4. Τελική αξιολόγηση δικτύου για βέλτιστο μέγεθος κρυμμένου επιπέδου σε επίπεδο διαχωρισμού 10%.


Για 2 κρυμμένα νευρωνικά επίπεδα:

5. Δοκιμή τοπολογίας 2 κρυμμένων νευρωνικών επιπέδων ίδιου μεγέθους για κάθε επίπεδο διαχωρισμού ξεχωριστά (5%, 10%, 20%).
6. Δοκιμή τοπολογίας για 4 διαφορετικά μεγέθη των κρυμμένων νευρωνικών επιπέδων (5, 10, 15, 20) σε επίπεδο διαχωρισμού 10%.
7. Καθορισμός βέλτιστου μεγέθους για τα κρυμμένα επίπεδα με βάση την απόδοση στο προηγούμενο βήμα.
8. Τελική αξιολόγηση δικτύου για βέλτιστο μέγεθος κρυμμένων επιπέδων σε επίπεδο διαχωρισμού 10%.

Όπως και στην τρίτη φάση, ο καθορισμός του επιπέδου διαχωρισμού 10% ως βασικό όριο για την εκπαίδευση όλων των διαμορφώσεων επιλέχθηκε με βάση τα αποτελέσματα της παρούσας και της δεύτερης φάσης, καθώς για επίπεδα διαχωρισμού πάνω από 10% το πρόβλημα φαίνεται να γίνεται αρκετά απλό και οποιαδήποτε αρχιτεκτονική για τον ταξινομητή δίνει πολύ υψηλά ποσοστά επιτυχίας. Η επιλογή των ορίων διακύμανσης του μεγέθους των κρυμμένων επιπέδων επιλέχθηκε με βάση προηγούμενη εμπειρία σε εφαρμογή αρχιτεκτονικών νευρωνικών δικτύων σε αντίστοιχα προβλήματα αναγνώρισης προτύπων, καθώς επίσης και από τις αντίστοιχες απαιτήσεις σε χρόνο ολοκλήρωσης της εκπαίδευσης, καθώς για μεγέθη επιπέδων από 15 νευρώνες και πάνω η διαδικασία εκπαίδευσης γίνεται εξαιρετικά πολύπλοκη.

Τα συγκριτικά αποτελέσματα της φάσης αυτής παρουσιάζονται στο παρακάτω συγκεντρωτικό διάγραμμα.





**Σχήμα 3.4:** Διάγραμμα 3 = NNC classifiers, sel\_lho

Σε όλα τα παραπάνω αποτελέσματα η απόδοση αναφέρεται στο τελικό ποσοστό επιτυχίας κάθε ταξινομητή, όπως διαμορφώνεται με βάση τους αντίστοιχους πίνακες αλήθειας που παρουσιάζουν αναλυτικά τα ποσοστά σε κάθε περίπτωση σωστής ή εσφαλμένης ταξινόμησης των προτύπων εκπαίδευσης. Παραδείγματα παρόμοιων πινάκων αλήθειας, τόσο για ταξινομητή MDC, όσο και για ταξινομητές NNC, παρουσιάζονται παρακάτω.

#### ΠΙΝΑΚΕΣ ΑΠΟΦΑΣΗΣ – TRUTH TABLES

MDC: sp=10%, p=750 (LOO)

	CN	CA
PN	117	133
PA	82	418

Correct = 71,3%

NNC (L=1,n=15): sp=10%, p=750

	CN	CA
PN	119	131
PA	116	384

Correct = 67,1%

NNC (L=2,n=15): sp=10%, p=750

	CN	CA
PN	152	98
PA	111	389

Correct = 72,1%

NNC (L=1,n=15): sp=10%, p=2250 (LHO)

	CN	CA
PN	626	124
PA	149	1351

Correct = 87,9%

NNC (L=2,n=15): sp=10%, p=2250 (LHO)

	CN	CA
PN	618	132
PA	129	1371

Correct = 88,4%

**Σχήμα 3.5:** Πίνακες αλήθειας για ταξινομητές MDC & NNC (truth tables)

### 3.2 Αξιολόγηση Απόδοσης Ταξινομητών

#### 3.2.1 Αξιολόγηση MDC

Τα χαρακτηριστικά της απόδοσης του ταξινομητή ελάχιστης απόστασης γίνονται φανερά κατά την πρώτη φάση της μελέτης. Ο ταξινομητής MDC αποτελεί τη βάση σύγκρισης για τα αποτελέσματα των διαμορφώσεων του NNC. Όπως φαίνεται στο διάγραμμα των συγκεντρωτικών αποτελεσμάτων της πρώτης και δεύτερης φάσης, ο ταξινομητής MDC εμφανίζει σταθερή αύξηση της απόδοσης, ξεκινώντας από ποσοστά επιτυχίας 61% για επίπεδο διαχωρισμού 5% και φτάνοντας σε ποσοστά κοντά στο 92% για επίπεδο διαχωρισμού 20%. Από αναλυτική διερεύνηση κάθε διαμόρφωσης ξεχωριστά προκύπτει ότι τα ποσοστά αυτά δεν επηρεάζονται από την ακριβή επιλογή χαρακτηριστικών παραμέτρων της περιοχής ενδιαφέροντος, κάτι που επιβεβαιώνεται τόσο σε περιορισμένο (set-A), όσο και σε ευρύτερο (set-B) σύνολο εκπαίδευσης. Επιπλέον, παρατηρείται μια ελάχιστη βελτίωση της απόδοσης στην περίπτωση χρησιμοποίησης όλο και περισσότερων εκπαιδευτικών προτύπων (set-B) της τάξης του +4%, κάτι που παρόλα αυτά είναι αναμενόμενο ως αποτέλεσμα της πληρέστερης αναπαράστασης του χώρου διερεύνησης και δεν αποτελεί σημαντικό στοιχείο για τις ιδιότητες του συγκεκριμένου ταξινομητή.

Οι πίνακες αλήθειας παρουσιάζουν μεγαλύτερα ποσοστά επιτυχίας στην σωστή αναγνώριση παθογένειας παρά στη σωστή αναγνώριση μη παθογένειας, ενώ τα ποσοστά αποτυχίας είναι περίπου τα ίδια για τις δύο περιπτώσεις εσφαλμένης ταξινόμησης. Η απόκλιση αυτή μπορεί να ερμηνευτεί εν μέρει από το ποσοστό των προτύπων παθογένειας (500-1500) σε σχέση με τα φυσιολογικά πρότυπα (250-750) στο σύνολο των προτύπων στο σύνολο εκπαίδευσης (750-2250), καθώς επίσης από την μεγαλύτερη διασπορά των προτύπων παθογένειας στο χώρο διερεύνησης καθώς προκύπτουν από δύο διαφορετικούς τύπους παθογένειας (λιπώδης διήθηση, κίρρωση) που τοποθετούνται σε διαφορετικές περιοχές του χώρου.

Σε κάθε περίπτωση, αν και η απόδοση του ταξινομητή MDC είναι αξιόλογη για επίπεδα διαχωρισμού πάνω από 10%, παρόλα αυτά δεν μπορεί να θεωρηθεί ικανοποιητική σε πρακτική χρήση.

#### 3.2.2 Αξιολόγηση NNC

Η απόδοση του ταξινομητή NNC αποτελεί θέμα μελέτης και για τις τέσσερις φάσεις αξιολόγησης που παρουσιάστηκαν παραπάνω. Κατά την πρώτη φάση γίνεται η συγκριτική αξιολόγηση του ταξινομητή NNC με βάση την απόλυτη απόδοση, σε σχέση με τον αντίστοιχο ταξινομητή MDC. Όπως προκύπτει από τα επιμέρους αποτελέσματα, ο ταξινομητής NNC εμφανίζει σαφώς μεγαλύτερα ποσοστά επιτυχίας για το ίδιο σύνολο εκπαίδευσης που χρησιμοποιεί ο βέλτιστος MDC ταξινομητής, ποσοστά που αυξάνονται πολύ περισσότερο στην περίπτωση χρησιμοποίησης ευρύτερου συνόλου χαρακτηριστικών παραμέτρων στα

πρότυπα, κάτι που δεν ισχύει για τον ταξινομητή MDC. Το γεγονός αυτό επιβεβαιώνει την εν γένει ιδιότητα των νευρωνικών δικτύων σχετικά με την ικανότητα αυτόματης εξαγωγής της χρήσιμης πληροφορίας διαχωρισμού των κλάσεων. Η εφαρμογή της μεθόδου LHO έχει ως αποτέλεσμα την αύξηση της ικανότητας γενίκευσης του δικτύου, με κόστος μια αναμενόμενη πτώση στην απόδοση της τάξης του -5%. Η απόδοση αυτή είναι ο πλέον ρεαλιστικός τρόπος εκτίμησης της πραγματικής απόδοσης του τελικού νευρωνικού ταξινομητή.

Όπως φαίνεται στο διάγραμμα των συγκεντρωτικών αποτελεσμάτων της πρώτης και δεύτερης φάσης, ο ταξινομητής MDC εμφανίζει σχετικά σταθερή αύξηση της απόδοσης, ξεκινώντας από ποσοστά επιτυχίας 67% για επίπεδο διαχωρισμού 5% και φτάνοντας σε ποσοστά κοντά στο 99% για επίπεδο διαχωρισμού 20%. Από αναλυτική διερεύνηση κάθε διαμόρφωσης ξεχωριστά προκύπτει ότι τα ποσοστά αυτά δεν επηρεάζονται από την ακριβή επιλογή χαρακτηριστικών παραμέτρων της περιοχής ενδιαφέροντος. Οι πίνακες αλήθειας παρουσιάζουν μεγαλύτερα ποσοστά επιτυχίας στην σωστή αναγνώριση παθολογίας παρά στη σωστή αναγνώριση μη παθολογίας, ενώ τα ποσοστά αποτυχίας είναι περίπου τα ίδια για τις δύο περιπτώσεις εσφαλμένης ταξινόμησης. Η απόκλιση αυτή, όπως και στην περίπτωση του ταξινομητή MDC, μπορεί να ερμηνευτεί εν μέρει από το ποσοστό των προτύπων παθολογίας (500-1500) σε σχέση με τα φυσιολογικά πρότυπα (250-750) στο σύνολο των προτύπων στο σύνολο εκπαίδευσης (750-2250), καθώς επίσης από την μεγαλύτερη διασπορά των προτύπων παθολογίας στο χώρο διερεύνησης καθώς προκύπτουν από δύο διαφορετικούς τύπους παθολογίας (λιπώδης διήθηση, κίρρωση) που τοποθετούνται σε διαφορετικές περιοχές του χώρου. Αξίζει να σημειωθεί πως στην περίπτωση του νευρωνικού ταξινομητή η απόκλιση αυτή είναι αρκετά μικρότερη και είναι ουσιαστικά ίση με την αναλογία φυσιολογικών και παθολογικών προτύπων στο σύνολο εκπαίδευσης, κάτι που προφανώς καταδεικνύει ότι η απόδοση του νευρωνικού ταξινομητή επηρεάζεται ελάχιστα από την ακριβή κατανομή των προτύπων στο χώρο έρευνας.

Κατά τη τρίτη και τέταρτη φάση της μελέτης διερευνάται η δυνατότητα καθορισμού κάποιων τυπικών ορίων βέλτιστης τοπολογίας για το νευρωνικό δίκτυο του ταξινομητή. Στην τρίτη φάση η εκπαίδευση γίνεται με βάση το MDC-optimum περιορισμένο (set-A) σύνολο εκπαίδευσης χωρίς τη χρήση της μεθόδου LHO, ενώ στην τέταρτη και τελευταία φάση η εκπαίδευση γίνεται με βάση το πλήρες T-test selected διευρυμένο (set-B) σύνολο εκπαίδευσης με χρήση της μεθόδου LHO.

Και στις δύο περιπτώσεις τα αποτελέσματα φανερώνουν την δραματική αύξηση της απόδοσης του νευρωνικού ταξινομητή σε τοπολογίες με δύο κρυμμένα επίπεδα. Παρόλο που ακόμα και με τοπολογίες ενός κρυμμένου επιπέδου η απόδοση ξεπερνά την αντίστοιχη απόδοση των ταξινομητών MDC, τοπολογίες με δύο επίπεδα εμφανίζουν περισσότερο ομαλή συμπεριφορά ως προς την απόδοση και ως προς τη σύγκλιση κατά τη διάρκεια της εκπαίδευσης. Στην περίπτωση του MDC-optimum συνόλου, η τελική απόδοση καταδεικνύει ότι για ένα κρυμμένο επίπεδο η τελική απόδοση είναι σχετικά ανεξάρτητη του μεγέθους του και αγγίζει το 67%. Αντίθετα, για τοπολογίες δύο κρυμμένων επιπέδων η τελική απόδοση φαίνεται να σχετίζεται άμεσα με το μέγεθός τους, με βέλτιστη διαμόρφωση τους 10 νευρώνες και για τα δύο κρυμμένα επίπεδα. Στην περίπτωση του T-test selected διευρυμένου εκπαιδευτικού συνόλου, η απόδοση

του νευρωνικού ταξινομητή ξεπερνά το 88%. Επιπλέον, η εφαρμογή της μεθόδου LHO προσδίδει μεγαλύτερη αξιοπιστία στα τελικά αποτελέσματα, μια και η τελική αξιολόγηση του ταξινομητή γίνεται σε ευρύτερο σύνολο προτύπων (2250). Η διαφορά στην απόδοση μεταξύ τοπολογιών ενός και δύο κρυμμένων επιπέδων δεν είναι της ίδιας κλίμακας όπως στην περίπτωση χρήσης του MDC-optimum συνόλου, όμως τοπολογίες δύο κρυμμένων επιπέδων εξακολουθούν να υπερτερούν σαφώς σε τελικό ποσοστό επιτυχίας. Η μικρότερη διαφορά μεταξύ της αντίστοιχης απόδοσης των δύο τοπολογιών οφείλεται προφανώς στη χρήση ευρύτερου συνόλου προτύπων εκπαίδευσης σε σχέση με την περίπτωση του MDC-optimum, καθώς επίσης και στην εφαρμογή της μεθόδου LHO που δίνει την δυνατότητα καλύτερης ικανότητας γενίκευσης σε κάθε περίπτωση.

Στο διάγραμμα αποτελεσμάτων της τέταρτης φάσης με τη συγκριτική απόδοση των διαμορφώσεων του νευρωνικού ταξινομητή για τοπολογίες ενός και δύο κρυμμένων επιπέδων, παρατηρείται αρκετά μεγάλη διακύμανση και αστάθεια στην απόδοση του ταξινομητή. Συγκεκριμένα, τοπολογίες με μέγεθος κρυμμένων επιπέδων 5 και 15 εμφανίζουν τα μεγαλύτερα ποσοστά επιτυχίας (88%), ενώ αντίθετα τοπολογίες με μέγεθος κρυμμένων επιπέδων 10 και 20 εμφανίζουν τα μικρότερα ποσοστά επιτυχίας (81%-85%). Οι τέσσερις υπό εξέταση διαμορφώσεις δεν επαρκούν για την ακριβή περιγραφή της απόδοσης του ταξινομητή σε κάθε δυνατή διαμόρφωση, όμως η πολυπλοκότητα του προβλήματος, το μέγεθος των εκπαιδευτικών συνόλων, καθώς και το μέγεθος του νευρωνικού δικτύου απαιτεί πολύ μεγάλο χρόνο για την ολοκλήρωση της εκπαίδευσης σε κάθε διαμόρφωση και κατά συνέπεια είναι αδύνατη η αναλυτική μελέτη αποκλειστικά με μεθόδους δοκιμής και αξιολόγησης. Παρόλα αυτά, προσεκτική παρατήρηση των αποτελεσμάτων επιβεβαιώνει ουσιαστικά εν γένει χαρακτηριστικά των νευρωνικών δικτύων. Η υψηλή απόδοση στην τοπολογία με κρυμμένα επίπεδα 5 νευρώνων προκύπτει από την υψηλή ικανότητα γενίκευσης που επιτυγχάνει το δίκτυο, μια και τα εκπαιδευτικά πρότυπα είναι σχεδόν μια τάξη μεγέθους περισσότερα από το συνολικό πλήθος των βαρών στο δίκτυο, κάτι που αξιοποιείται κατά βέλτιστο τρόπο από την μέθοδο LHO. Αντίθετα, η υψηλή απόδοση στην τοπολογία με κρυμμένα επίπεδα 15 νευρώνων μοιάζει περισσότερο με τη συμπεριφορά του βέλτιστου δικτύου στο MDC-optimum σύνολο, δηλαδή υψηλή εξειδίκευση στο συγκεκριμένο σύνολο εκπαίδευσης. Η χαμηλή απόδοση στην περίπτωση κρυμμένων επιπέδων 10 νευρώνων αποτελεί κάποια ενδιάμεση κατάσταση, ενώ στην περίπτωση 20 νευρώνων το σύνολο εκπαίδευσης αρχίζει να είναι ανεπαρκές για την εκπαίδευση του δικτύου.

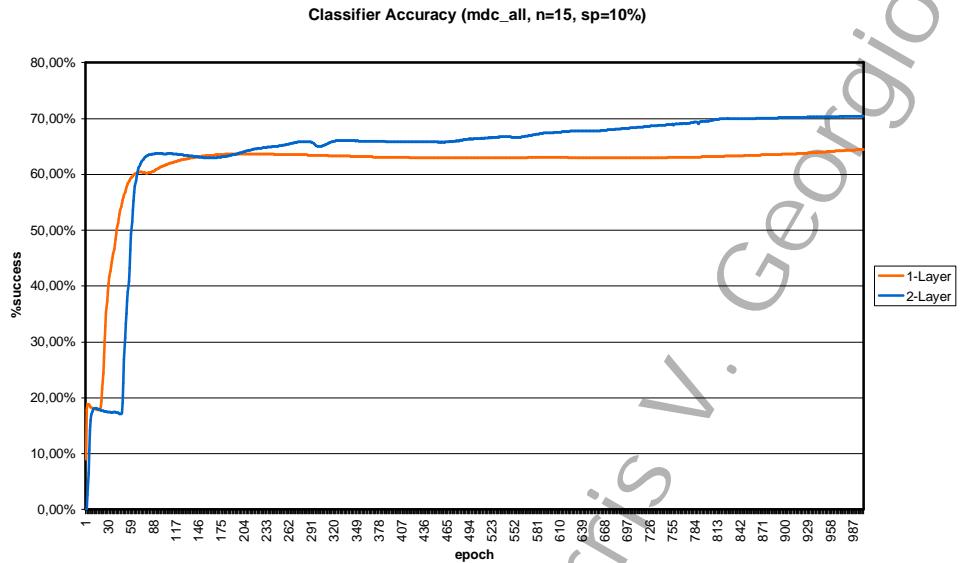
Διαγράμματα μεταβολής του σφάλματος εκπαίδευσης και του τρέχοντος ποσοστού επιτυχίας στα σύνολα επικύρωσης κατά τη διάρκεια της εκπαίδευσης φανερώνουν επίσης σημαντικά στοιχεία για τη συμπεριφορά της διαδικασίας εκπαίδευσης του νευρωνικού δικτύου. Τόσο στην περίπτωση του MDC-optimum συνόλου, όσο και στην περίπτωση του T-test selected διευρυμένου συνόλου εκπαίδευσης, γίνεται φανερό ότι το μεγαλύτερο ποσοστό της εκπαίδευσης ολοκληρώνεται εντός των πρώτων 250-500 κύκλων εκπαίδευσης. Αυτό σημαίνει ότι η διαδικασία εκπαίδευσης συγκλίνει σχετικά γρήγορα και αρκετά ομαλά για μικρούς συντελεστές μάθησης. Στην πράξη, για όλες τις διαμορφώσεις η σύγκλιση ολοκληρώθηκε σε λιγότερους από 1000 κύκλους εκπαίδευσης. Η σύγκλιση είναι αρκετά ομαλότερη για τοπολογίες δύο κρυμμένων επιπέδων, ενώ σε κάθε περίπτωση η αύξηση της απόδοσης μετά τους πρώτους 200 κύκλους είναι ελάχιστη ή ασήμαντη. Ειδικά για την περίπτωση του T-test selected

διευρυμένου συνόλου, η σύγκλιση διατηρεί τα ίδια βασικά χαρακτηριστικά παρόλο που είναι λιγότερο σταθερή σε σχέση με το σύνολο MDC-optimum. Η αστάθεια στη σύγκλιση εμφανίζεται μετά τους πρώτους 400 κύκλους εκπαίδευσης, δηλαδή μετά την ολοκλήρωση του μεγαλύτερου ποσοστού της, και αναφέρεται στην συνεχή εξισορρόπηση της τάσης υπερ-εκπαίδευσης του δικτύου με την γενίκευση που επιβάλλει η εφαρμογή της μεθόδου LHO. Ουσιαστικά η τελική απόδοση του ταξινομητή μετά από το στάδιο αυτό είναι σταθερή και η διαδικασία εκπαίδευσης μπορεί να τερματιστεί πολύ πριν τους 1000 κύκλους εκπαίδευσης.




**Σχήμα 3.6:** Διάγραμμα εκπαίδευσης NNC, training error (mdc\_all)

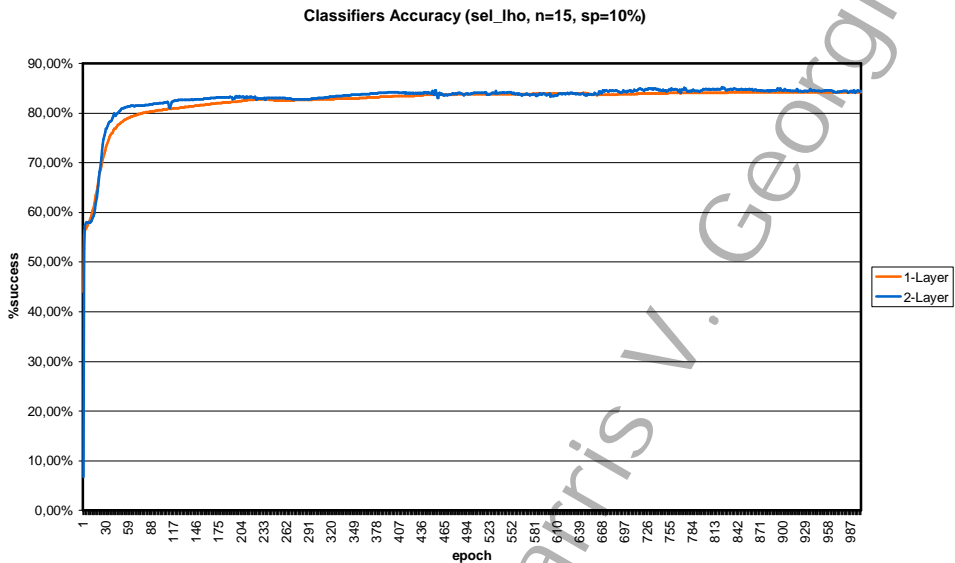
### ΜΕΡΟΣ-3: Παρουσίαση & Σχολιασμός Αποτελεσμάτων



Σχήμα 3.7: Διάγραμμα εκπαίδευσης NNC, accuracy (mdc\_all)



Σχήμα 3.8: Διάγραμμα εκπαίδευσης NNC, training error (sel\_lho)



**Σχήμα 3.9:** Διάγραμμα εκπαίδευσης NNC, accuracy (sel\_lho)

Σε κάθε περίπτωση ο νευρωνικός ταξινομητής εμφανίζει ικανοποιητικά ποσοστά επιτυχίας και ταυτόχρονα υψηλό βαθμό γενίκευσης μέσω της μεθόδου LHO, η οποία εξασφαλίζει τόσο την σωστή και ομαλή εκπαίδευση του νευρωνικού δικτύου, όσο και μια αντικειμενική αξιολόγηση της τελικής επίδοσής του στον ευρύτερο χώρο των προτύπων εισόδου.

### 3.3 Σχολιασμός Αποτελεσμάτων

Έχοντας καταλήξει σε ένα σύνολο αποτελεσμάτων που περιγράφουν τη συμπεριφορά των δύο ταξινομητών (MDC, NNC) σε διάφορες διαμορφώσεις, είναι δυνατή η διατύπωση κάποιων γενικότερων συμπερασμάτων σχετικά με τη φύση του προβλήματος και τη δυνατότητα εφαρμογής παρόμοιων τεχνικών για την επίλυσή του.

Η ολοκλήρωση της μελέτης εφικτότητας έδειξε πως είναι δυνατή η κατασκευή ταξινομητή για την ανάλυση και αυτόματο χαρακτηρισμό παθολογιών σε ψηφιοποιημένες υπερηχογραφικές εικόνες ήπατος, με ποσοστά επιτυχίας που ξεπερνούν το 85% και αγγίζουν το 88% για δομές βασισμένες σε νευρωνικά δίκτυα. Είναι επίσης φανερό ότι μη γραμμικές δομές όπως τα νευρωνικά δίκτυα υπερτερούν σαφώς (2%-20%) σε σχέση με γραμμικές δομές όπως οι κλασικοί ταξινομητές ελάχιστης απόστασης και φαίνεται πως το επιπλέον κόστος όσο αφορά την πολυπλοκότητα της δομής και του αλγορίθμου εκπαίδευσης αντισταθμίζεται από το κέρδος σε απόδοση.



Εκτός του σχετικά υψηλού ποσοστού επιτυχίας των νευρωνικών ταξινομητών, ένα εξίσου σημαντικό χαρακτηριστικό που εξετάζεται και ενισχύεται κατάλληλα κατά τη διαδικασία της εκπαίδευσης είναι η ικανότητα γενίκευσης. Η προσαρμοστικότητα των νευρωνικών ταξινομητών μπορεί να επιτευχθεί αφ' ενός από εν γένει χαρακτηριστικά των νευρωνικών δικτύων, όπως η ανθεκτικότητα στο θόρυβο και η αυτόματη εξαγωγή χρήσιμης πληροφορίας διαχωρισμού των κλάσεων, και αφ' ετέρου με την εφαρμογή κατάλληλων μεθόδων για τη βελτιστοποίηση της σύγκλισης κατά τη διάρκεια της εκπαίδευσης, όπως η μέθοδος LHO. Τόσο η ικανότητα γενίκευσης, όσο και το τελικό ποσοστό επιτυχίας του ταξινομητή βελτιώνεται σε μεγάλο βαθμό με την υιοθέτηση τοπολογιών με 2 κρυμμένα επίπεδα νευρώνων με πρακτικά εφικτό μέγεθος υλοποίησης (5-15 νευρώνες σε κάθε ένα με πλήρη διασύνδεση μεταξύ των επιπέδων).

Ένα ακόμη σημαντικό συμπέρασμα που προκύπτει από τη μελέτη των επιμέρους διαμορφώσεων, τόσο για ταξινομητές MDC, όσο και για ταξινομητές NNC, αποτελεί το γεγονός ότι δεν εντοπίζεται κάποιο σαφές σύνολο χαρακτηριστικών παραμέτρων που να καθορίζουν τον διαχωρισμό των κλάσεων ταξινόμησης κατά βέλτιστο τρόπο. Αντίθετα, η επιλογή των αποδοτικότερων χαρακτηριστικών διαφέρει κάθε φορά κατά περίπτωση, ανάλογα με το εκάστοτε σύνολο εκπαίδευσης και το επίπεδο διαχωρισμού που χρησιμοποιείται κατά την κατασκευή των προτύπων. Όπως είναι φυσικό, κάποια χαρακτηριστικά που ευνοούνται από τον τρόπο χρησιμοποίησης του επιπέδου διαχωρισμού για την προσομοίωση των προτύπων παθογένειας, όπως για παράδειγμα η μέση τιμή των τόνων του γκρι στην περιοχή ενδιαφέροντος. Παρόλα αυτά, η αποτελεσματικότητά τους δεν είναι σταθερή και πολύ συχνά υπερκαλύπτεται από άλλες χαρακτηριστικές παραμέτρους, όπως αυτές που σχετίζονται με τη χωρική διακύμανση της κλίμακας αποχρώσεων τόνων του γκρι (run-length features).

Η αναλυτική αξιολόγηση της απόδοσης διαφόρων διαμορφώσεων ταξινομητών NNC αποκαλύπτει ότι η χρήση του MDC-optimum συνόλου για την εκπαίδευση του αντίστοιχου νευρωνικού ταξινομητή δεν οδηγεί αναγκαστικά σε βέλτιστη διαμόρφωση. Αντίθετα, η χρήση περισσότερων χαρακτηριστικών παραμέτρων στα πρότυπα εκπαίδευσης, όπως το T-test selected σύνολο εκπαίδευσης, οδηγεί την αυτόματη αφομοίωση της αξιοποιήσιμης πληροφορίας διαχωρισμού από το νευρωνικό δίκτυο και κατά συνέπεια την επίτευξη καλύτερης τελικής απόδοσης. Φυσικά η επιλογή αποτελεσματικών χαρακτηριστικών μέσω στατιστικών μεθόδων δοκιμής όπως το T-test παραμένει χρήσιμη, καθώς η αύξηση της διάστασης των διανυσμάτων εισόδου οδηγεί αναπόφευκτα σε περαιτέρω αύξηση της πολυπλοκότητας της δομής του νευρωνικού ταξινομητή στο επίπεδο εισόδου.

Ως προς τα πρότυπα εκπαίδευσης και γενικότερα σε σχέση με τα δεδομένα εισόδου, μπορεί να διαπιστωθεί η μεγάλη αποτελεσματικότητα και των ταξινομητών για επίπεδα διαχωρισμού από 20% και άνω, όπου ουσιαστικά η ταξινόμηση γίνεται με ελάχιστο σφάλμα (<2%). Το κύριο μέρος της μελέτης σχετικά με την απόδοση των ταξινομητών μπορεί να επικεντρωθεί σε επίπεδα διαχωρισμού 10% ή λιγότερο, καθώς στα επίπεδα αυτά είναι δυνατή η αντικειμενικότερη αξιολόγησή τους. Αξίζει επιπλέον να σημειωθεί ότι η κατανομή του ποσοστού επιτυχίας (και αποτυχίας) των νευρωνικών

ταξινομητών ανάμεσα στις πιθανές περιπτώσεις σωστής ταξινόμησης προτύπων, είναι ομοιόμορφη και σύμφωνα με την σχετική αναλογία των αντίστοιχων προτύπων στο σύνολο εκπαίδευσης, όπως αναλύθηκε διεξοδικά προηγούμενα στην ενότητα αξιολόγησης των ταξινομητών.

Σε σχέση με την υλοποίηση των ταξινομητών σε πρακτικό επίπεδο, αξίζει να αναφερθεί πως η δομή των νευρωνικών ταξινομητών και του αντίστοιχου αλγορίθμου εκπαίδευσης παρουσιάζει πολυπλοκότητα σε χώρο και χρόνο τουλάχιστον μιας τάξης μεγέθους μεγαλύτερη από αυτή των γραμμικών ταξινομητών ελάχιστης απόστασης. Επιπλέον, το ζήτημα του καθορισμού της βέλτιστης τοπολογίας για το νευρωνικό δίκτυο παραμένει ανοικτό, καθώς δεν υπάρχει αντίστοιχο θεωρητικό υπόβαθρο για τη σαφή καθοδήγηση της αναζήτησης. Πάντως, για όλες τις τοπολογίες που αξιολογήθηκαν κατά τη σχεδίαση ταξινομητών NNC αποδείχθηκε ότι η σύγκλιση στη διαδικασία εκπαίδευσης επιτυγχάνεται σχετικά γρήγορα (στους πρώτους 400-500 κύκλους), γεγονός που επιβεβαιώνει την αρχική εκτίμηση ότι το σχετικό κέρδος σε απόδοση από τη χρήση νευρωνικών ταξινομητών υπερκαλύπτει το αντίστοιχο κόστος σε πολυπλοκότητα για την κατασκευή τους.

### 3.4 Συμπεράσματα

Η παρούσα εργασία επικεντρώθηκε στη διερεύνηση της δυνατότητας εφαρμογής τεχνικών αναγνώρισης προτύπων στο πεδίο της ανάλυσης ιατρικής εικόνας μέσω υπολογιστή, και συγκεκριμένα τον αυτόματο χαρακτηρισμό παθολογείας σε δείγματα ιστού όπως παρουσιάζονται σε ψηφιοποιημένες υπερηχογραφικές εικόνες ανθρώπινου ήπατος.

Η μελέτη εφικτότητας του υπό μελέτη προβλήματος, κατέληξε στο συμπέρασμα ότι η εφαρμογή απλών δομών γραμμικών ταξινομητών ελάχιστης απόστασης ή πιο σύνθετων αρχιτεκτονικών όπως νευρωνικών ταξινομητών, είναι δυνατό να προσφέρει σημαντική απόδοση και αξιοποιήσιμα συμπεράσματα για την υλοποίηση πρακτικά χρήσιμων συστημάτων. Τα ποσοστά επιτυχίας των διαφόρων ταξινομητών και διαμορφώσεων που εξετάστηκαν συμβαδίζουν και συμπληρώνουν όσα έχουν μέχρι τώρα δημοσιευτεί στη διεθνή βιβλιογραφία [01, 02, 06, 09]. Τα πειραματικά αποτελέσματα είναι άκρως ενθαρρυντικά και υποδεικνύουν ότι περαιτέρω έρευνα στο συγκεκριμένο πεδίο ενδείκνυται για ακόμα καλύτερη εκτίμηση και αξιοποίησή τους.

Οι νευρωνικοί ταξινομητές αποδεικνύονται αποτελεσματικοί για την κατασκευή πρακτικά χρήσιμων συστημάτων, ειδικότερα σε σχέση με το απόλυτο ποσοστό επιτυχίας και ως προς το βαθμό ικανότητας γενίκευσης. Η μελέτη στατιστικών παραμέτρων της υφής της εικόνας είναι ικανές να προσφέρουν σε μεγάλο ποσοστό την απαραίτητη πληροφορία διαχωρισμού των κλάσεων. Επιπλέον, οι αναλυτικές μέθοδοι εκπαίδευσης των ταξινομητών με συστηματικό τρόπο προσφέρουν τη δυνατότητα ελεγχιμότητας των αποτελεσμάτων, καθώς επίσης και αντικειμενικότητα σε σχέση με εξειδικευμένους παρατηρητές.

Η περαιτέρω μελέτη στο συγκεκριμένο πεδίο θα επιτρέψει την υλοποίηση διάγνωσης σε πολλαπλά επίπεδα παθολογείας, στη βελτίωση των μεθόδων κατασκευής των ταξινομητών, καθώς επίσης και στην αύξηση της απόδοσης σε

### ΜΕΡΟΣ-3: Παρουσίαση & Σχολιασμός Αποτελεσμάτων

ακόμα υψηλότερα ποσοστά επιτυχίας, ικανά να οδηγήσουν στην επιτυχημένη εφαρμογή παρόμοιων συστημάτων σε κλινικό επίπεδο.

## **Παράρτημα – Α**

### **Τεκμηρίωση Λογισμικού**

#### **Α. Προγραμματιστικές Βιβλιοθήκες Συναρτήσεων**

Στην παρούσα ενότητα αναφέρονται λεπτομέρειες σχετικά με την δομή και το σύνολο των ρουτινών που αποτελούν τον κώδικα των προγραμμάτων του πακέτου λογισμικού, που χρησιμοποιήθηκαν για την σχεδίαση, κατασκευή και εκπαίδευση των ταξινομητών ελάχιστης απόστασης και νευρωνικού δικτύου. Πληροφορίες σχετικά με τη δομή και τον τρόπο λειτουργίας των προγραμμάτων τους παρουσιάζονται στην αντίστοιχη ενότητα περιγραφής του λογισμικού.

##### **A.1 SIFX: Sample Image Feature Extractor**

###### **A.1.1 Εισαγωγή**

Το πρόγραμμα SIFX αποτελεί το εργαλείο προεπεξεργασίας της αρχικής ψηφιοποιημένης υπερηχογραφικής εικόνας και της εξαγωγής των δεδομένων προς ανάλυση από τα προγράμματα σχεδίασης ταξινομητή. Με βάση κάποια αρχική ψηφιακή εικόνα και ένα σύνολο περιοχών δειγματοληψίας, χρησιμοποιεί ένα σύνολο συναρτήσεων για την ποσοτικοποίηση των πληροφοριών υψής σε κάθε μια περιοχή και την μετέπειτα χρησιμοποίησή τους για τη σχεδίαση του ταξινομητή. Η εφαρμογή είναι ανεπτυγμένη με τέτοιο τρόπο ώστε η χρησιμότητα και η πρακτική εφαρμογή της να μπορεί να επεκταθεί εύκολα, εκτός από υπερηχογραφικές, και σε άλλου τύπου εικόνες.

###### **A.1.2 Ανάλυση κώδικα**

Παρακάτω αναφέρονται οι βασικότερες δομές και συναρτήσεις που χρησιμοποιούνται για την υλοποίηση της εφαρμογής. Η αναλυτική τεκμηρίωση των διεπαφών έχει ως σκοπό την πληρέστερη τεκμηρίωση του κώδικα και την ευκολότερη επέκταση ή επαναχρησιμοποίησή του σε ανάλογα προγράμματα.

Αρχείο: CONST.H

Περιγραφή: Συμβολικές σταθερές, βοηθητικές παράμετροι, μακροεντολές

Το συγκεκριμένο αρχείο δεν περιλαμβάνει ρουτίνες του προγράμματος.

Αρχείο: FEATURES.H

Περιγραφή: Υλοποίηση συναρτήσεων υφής

```
double tfc_def( int *img, int sx, int sy )
```

Desc: Null feature function

Input: img = δεδομένα δείγματος εικόνας (256 greyscale)  
sx, sy = διαστάσεις δείγματος εικόνας

Output: return = 0, χρησιμοποιείται ως null function

```
double tfc_f01( int *img, int sx, int sy )
```

Desc: Greylevels mean value feature function

Input: img = δεδομένα δείγματος εικόνας (256 greyscale)  
sx, sy = διαστάσεις δείγματος εικόνας

Output: return = greylevels mean value

```
double tfc_f02( int *img, int sx, int sy, double fv1 )
```

Desc: Greylevels variance feature function

Input: img = δεδομένα δείγματος εικόνας (256 greyscale)  
sx, sy = διαστάσεις δείγματος εικόνας  
fv1 = τιμή της συνάρτησης tfc\_f01() για το ίδιο δείγμα

Output: return = greylevels variance

```
double tfc_f03( int *img, int sx, int sy, double fv1 )
```

Desc: Greylevels skewness feature function

Input: img = δεδομένα δείγματος εικόνας (256 greyscale)  
sx, sy = διαστάσεις δείγματος εικόνας  
fv1 = τιμή της συνάρτησης tfc\_f01() για το ίδιο δείγμα

Output: return = greylevels skewness

```
double tfc_f04( int *img, int sx, int sy, double fv1 )
```

Desc: Greylevels curtosis feature function  
 Input: img = δεδομένα δείγματος εικόνας (256 greyscale)  
       sx, sy = διαστάσεις δείγματος εικόνας  
       fv1 = τιμή της συνάρτησης tfc\_f01() για το ίδιο δείγμα  
 Output: return = greylevels curtosis

double tfc\_f05( int \*img, int sx, int sy )

Desc: Angular second moment feature function  
 Input: img = δεδομένα μητρώου SDM του δείγματος εικόνας  
       sx, sy = διαστάσεις μητρώου SDM  
 Output: return = angular second moment

double tfc\_f06( int \*img, int sx, int sy )

Desc: Contrast feature function  
 Input: img = δεδομένα μητρώου SDM του δείγματος εικόνας  
       sx, sy = διαστάσεις μητρώου SDM  
 Output: return = contrast

double tfc\_f07( int \*img, int sx, int sy )

Desc: Correlation feature function  
 Input: img = δεδομένα μητρώου SDM του δείγματος εικόνας  
       sx, sy = διαστάσεις μητρώου SDM  
 Output: return = correlation

double tfc\_f08( int \*img, int sx, int sy, double fv1 )

Desc: Sum of squares variance feature function  
 Input: img = δεδομένα μητρώου SDM του δείγματος εικόνας  
       sx, sy = διαστάσεις μητρώου SDM  
       fv1 = τιμή της συνάρτησης tfc\_f01() για το αντίστοιχο δείγμα

εικόνας

Output: return = sum of squares variance

double tfc\_f09( int \*img, int sx, int sy )

Desc: Inverse difference moment feature function  
 Input: img = δεδομένα μητρώου SDM του δείγματος εικόνας  
       sx, sy = διαστάσεις μητρώου SDM  
 Output: return = inverse difference moment

```
double tfc_f10( int *img, int sx, int sy )
```

Desc: Sum average feature function

Input: img = δεδομένα μητρώου SDM του δείγματος εικόνας  
sx, sy = διαστάσεις μητρώου SDM

Output: return = sum average

```
double tfc_f11( int *img, int sx, int sy, double fv6 )
```

Desc: Sum variance feature function

Input: img = δεδομένα μητρώου SDM του δείγματος εικόνας  
sx, sy = διαστάσεις μητρώου SDM  
fv6 = τιμή της συνάρτησης tfc\_f06() για το αντίστοιχο δείγμα

Output: return = sum variance

```
double tfc_f12( int *img, int sx, int sy )
```

Desc: Sum entropy feature function

Input: img = δεδομένα μητρώου SDM του δείγματος εικόνας  
sx, sy = διαστάσεις μητρώου SDM

Output: return = sum entropy

```
double tfc_f13( int *img, int sx, int sy )
```

Desc: Entropy feature function

Input: img = δεδομένα μητρώου SDM του δείγματος εικόνας  
sx, sy = διαστάσεις μητρώου SDM

Output: return = entropy

```
double tfc_f14( int *img, int sx, int sy )
```

Desc: Difference variance feature function

Input: img = δεδομένα μητρώου SDM του δείγματος εικόνας  
sx, sy = διαστάσεις μητρώου SDM

Output: return = difference variance

```
double tfc_f15( int *img, int sx, int sy )
```

Desc: Difference entropy feature function

Input: img = δεδομένα μητρώου SDM του δείγματος εικόνας  
sx, sy = διαστάσεις μητρώου SDM

Output: return = difference entropy

```
double tfc_f16( int *rlm, int gsz, int rsz )
```

Desc: Short runs emphasis feature function

Input: rlm = δεδομένα μητρώου RLM του δείγματος εικόνας  
gsz, rsz = διαστάσεις μητρώου RLM (greyscale, maxrun)

Output: return = short runs emphasis

```
double tfc_f17( int *rlm, int gsz, int rsz )
```

Desc: Long runs emphasis feature function

Input: rlm = δεδομένα μητρώου RLM του δείγματος εικόνας  
gsz, rsz = διαστάσεις μητρώου RLM (greyscale, maxrun)

Output: return = long runs emphasis

```
double tfc_f18( int *rlm, int gsz, int rsz )
```

Desc: Greylevels non-uniformity feature function

Input: rlm = δεδομένα μητρώου RLM του δείγματος εικόνας  
gsz, rsz = διαστάσεις μητρώου RLM (greyscale, maxrun)

Output: return = greylevels non-uniformity

```
double tfc_f19( int *rlm, int gsz, int rsz )
```

Desc: Run-lengths non-uniformity feature function

Input: rlm = δεδομένα μητρώου RLM του δείγματος εικόνας  
gsz, rsz = διαστάσεις μητρώου RLM (greyscale, maxrun)

Output: return = run-lengths non-uniformity

```
double tfc_f20( int *rlm, int gsz, int rsz )
```

Desc: Run percentage feature function

Input: rlm = δεδομένα μητρώου RLM του δείγματος εικόνας  
gsz, rsz = διαστάσεις μητρώου RLM (greyscale, maxrun)

Output: return = run percentage

```
void calcfeatures( int *img, int ix, int iy, int *sdm, int sx, int sy, int  
*rlm, int gsz, int rsz, double *FeatValue )
```

Desc: Υπολογισμός διανύσματος συναρτήσεων υφής (feature vector)  
για δείγμα εικόνας

Input: img = δεδομένα δείγματος εικόνας (256 greyscale)  
ix, iy = διαστάσεις δείγματος εικόνας



sdm = δεδομένα μητρώου SDM δείγματος εικόνας  
 sx, sy = διαστάσεις μητρώου SDM  
 rlm = δεδομένα μητρώου RLM δείγματος εικόνας  
 gsz, rsz = διαστάσεις μητρώου RLM (greyscale, maxrun)

Output: FeatValue = διάνυσμα με τις τιμές όλων των συναρτήσεων υφής  
 (feature vector)

#### Αρχείο: SIFX.CPP

Περιγραφή: κώδικας κυρίως προγράμματος (έκδοση κονσόλας)

int \*readimage( char \*filename )

Desc: Ανάγνωση εικόνας bitmap στη μνήμη

Input: filename = όνομα αρχείου bitmap (.bmp) προς ανάγνωση

Output: return = δεδομένα εικόνας που διαβάστηκε ή NULL σε αποτυχία

int \*gsn\_image( int \*im, int gscale )

Desc: Κανονικοποίηση δεδομένων εικόνας

Input: im = δεδομένα εικόνας

int = εύρος κλίμακας τόνων γκρι (2...256)

Output: return = δεδομένα κανονικοποιημένης εικόνας

int copysample(int \*img, int cx, int cy, int sx, int sy, int \*box)

Desc: αντιγραφή περιοχής εικόνας σε δείγμα

Input: img = δεδομένα εικόνας

cx, cy = διαστάσεις εικόνας

sx, sy = διαστάσεις παραθύρου δείγματος

Output: box = δεδομένα παραθύρου δείγματος

return = 0 σε επιτυχία

int \*calculate\_sdm( int \*box\_dat, int sx, int sy, int gsc )

Desc: Υπολογισμός μητρώου SDM για δείγμα εικόνας

Input: box\_dat = δεδομένα δείγματος εικόνας

sx, sy = διαστάσεις δείγματος

gsc = εύρος κλίμακας τόνων γκρι (2...256)

Output: return = δεδομένα μητρώου SDM, ή NULL σε αποτυχία

int \*calculate\_rlm( int \*box\_dat, int sx, int sy, int gsc )

Desc: Υπολογισμός μητρώου RLM για δείγμα εικόνας  
 Input: box\_dat = δεδομένα δείγματος εικόνας  
       sx, sy = διαστάσεις δείγματος  
       gsc = εύρος κλίμακας τόνων γκρι (2...256)  
 Output: return = δεδομένα μητρώου RLM, ή NULL σε αποτυχία

int createpatterns(FILE \*fout, int \*ns\_dat, int sx, int sy, int gscale, double noiselev, double bias, int pat\_types )

Desc: Δημιουργία και αποθήκευση πρότυπου διανύσματος για δείγμα εικόνας  
 Input: fout = stream εξόδου για αποστολή δεδομένων  
       ns\_dat = δεδομένα δείγματος εικόνας (φυσιολογικός ιστός)  
       sx, sy = διαστάσεις δείγματος  
       gscale = εύρος κλίμακας τόνων γκρι (2...256)  
       noiselev = επίπεδο ποσοστού ομοιόμορφου θορύβου (0...1)  
       bias = επίπεδο διαχωρισμού ομοιόμορφου θορύβου (0...1)  
       pat\_types = προσομοιομένα δείγματα (0=none, 1=noise+, 2=noise-, 3=both)  
 Output: return = 0 σε επιτυχία

long convertpatternfile( FILE \*ffrom, FILE \*fto )

Desc: Προσθήκη επικεφαλίδας σε αρχείο προτύπων διανυσμάτων  
 Input: ffrom = stream εισόδου (αρχείο προέλευσης)  
       fto = stream εξόδου (αρχείο προορισμού)  
 Output: return = πλήθος διανυσμάτων που γράφτηκαν (0 σε αποτυχία)

long writepatternfile( double \*pattern, long patlen, long patsize, FILE \*fto )

Desc: Μεταφορά προτύπων διανυσμάτων σε αρχείο κειμένου (χρήση από FCD)  
 Input: pattern = πίνακας προτύπων διανυσμάτων  
       patlen = μέγεθος πίνακα διανυσμάτων  
       patsize = μέγεθος πρότυπου διανύσματος  
       fto = stream εξόδου (αρχείο προορισμού)  
 Output: return = πλήθος διανυσμάτων που γράφτηκαν (0 σε αποτυχία)

long writeauxfile0( double \*pattern, long patlen, long patsize, int clscount, FILE \*fto )

Desc: Μεταφορά προτύπων διανυσμάτων σε αρχείο κειμένου (χρήση από BPM)

Input: pattern = πίνακας προτύπων διανυσμάτων  
 patlen = μέγεθος πίνακα διανυσμάτων  
 patsize = μέγεθος πρότυπου διανύσματος  
 clscount = πλήθος κατηγοριών προτύπων διανυσμάτων  
 fto = stream εξόδου (αρχείο προορισμού)

Output: return = πλήθος διανυσμάτων που γράφτηκαν (0 σε αποτυχία)

double \* readpatterns( FILE \*ffrom, long \*patlen, long \*patsize )

Desc: Ανάγνωση προτύπων διανυσμάτων από αρχείο κειμένου (τύπου FCD)

Input: ffrom = stream εισόδου (αρχείο προέλευσης)

Output: patlen = μέγεθος πίνακα διανυσμάτων  
 patsize = μέγεθος πρότυπου διανύσματος  
 return = πίνακας προτύπων διανυσμάτων (NULL σε αποτυχία)

long normpatterns( double \*pattern, long patlen, long patsize )

Desc: Κανονικοποίηση προτύπων διανυσμάτων (μέθοδος mean/variance)

Input: pattern = πίνακας προτύπων διανυσμάτων  
 patlen = μέγεθος πίνακα διανυσμάτων  
 patsize = μέγεθος πρότυπου διανύσματος

Output: return = πλήθος διανυσμάτων που κανονικοποιήθηκαν (0 σε αποτυχία)

long normpatterns2( double \*pattern, long patlen, long patsize )

Desc: Κανονικοποίηση προτύπων διανυσμάτων (μέθοδος min/max)

Input: pattern = πίνακας προτύπων διανυσμάτων  
 patlen = μέγεθος πίνακα διανυσμάτων  
 patsize = μέγεθος πρότυπου διανύσματος

Output: return = πλήθος διανυσμάτων που κανονικοποιήθηκαν (0 σε αποτυχία)

Αρχείο: SIFXW.CPP

Περιγραφή: κώδικας κυρίως προγράμματος (έκδοση γραφικού περιβάλλοντος)

Το πρόγραμμα της έκδοσης γραφικού περιβάλλοντος χρησιμοποιεί ουσιαστικά τον ίδιο πυρήνα με αυτό της έκδοσης κονσόλας. Εκτός από την προσθήκη ορισμένων βοηθητικών δομών και συναρτήσεων για την ενημέρωση της απεικόνισης, το πρόγραμμα καλεί μια τροποποιημένη έκδοση της ρουτίνας main() του κώδικα της έκδοσης κονσόλας. Η αρχιτεκτονική και η λειτουργικότητα της έκδοσης γραφικού περιβάλλοντος καλύπτεται πλήρως από την περιγραφή του κώδικα της έκδοσης κονσόλας.

**A.1.3 Τεχνικές πληροφορίες**

Γλώσσα προγραμματισμού:	ANSI C/C++
Πλατφόρμα ανάπτυξης:	Win32 (sifx/sifxw), Windows SDK (sifxw)
Περιβάλλον ανάπτυξης:	Microsoft Visual C++ 5.0
Σύστημα ανάπτυξης/δοκιμής:	h/w: AMD K7 Athlon, iPentium-II, iPentium-III, iPentium MMX s/w: MS-Windows95, MS-Windows98, MS-WindowsNT
Πηγαίος κώδικας:	SIFX = 1398 γραμμές, SIFXW = 2051 γραμμές
Πρόσθετες βιβλιοθήκες:	-

**A.2 FCD: Feature Classifier Design****A.2.1 Εισαγωγή**

Το πρόγραμμα FCD αποτελεί το βασικό εργαλείο σχεδίασης και κατασκευής γραμμικών ταξινομητών ελάχιστης απόστασης (Minimum Distance Classifier – MDC). Με βάση κάποιο σύνολο προτύπων διανυσμάτων δύο κατηγοριών, κατασκευάζει τον ταξινομητή βέλτιστης διαχωριστικής ικανότητας με βάση την (ελάχιστη) απόσταση του άγνωστου προτύπου από τα αντιπροσωπευτικά διανύσματα των δύο κατηγοριών. Η εφαρμογή είναι ανεπτυγμένη με τέτοιο τρόπο ώστε η χρησιμότητα και η πρακτική εφαρμογή της να μπορεί να επεκταθεί εύκολα σε κάθε είδους εφαρμογή που απαιτεί τη σχεδίαση γραμμικών ταξινομητών ελάχιστης απόστασης (MDC) με βάση κάποια πρότυπα διανύσματα.

**A.2.2 Ανάλυση κώδικα**

Παρακάτω αναφέρονται οι βασικότερες δομές και συναρτήσεις που χρησιμοποιούνται για την υλοποίηση της εφαρμογής. Η αναλυτική τεκμηρίωση των διεπαφών έχει ως σκοπό την πληρέστερη τεκμηρίωση του κώδικα και την ευκολότερη επέκταση ή επαναχρησιμοποίησή του σε ανάλογα προγράμματα.

Αρχείο: CONST.H

Περιγραφή: Συμβολικές σταθερές, βοηθητικές παράμετροι, μακροεντολές

long ncombs( int n )

Desc: Υπολογισμός πλήθους διαμορφώσεων για (n) συνιστώσες ανά 2, 3, 4.

Input: n = πλήθος συνιστωσών προς συνδυασμό

Output: result = Combin(n,2) + Combin(n,3) + Combin(n,4)

Αρχείο: STATLIB.H

Περιγραφή: Υλοποίηση στατιστικών συναρτήσεων

double Q( double x )

Desc: Βασική στατιστική συνάρτηση (βοηθητική)

Input: x = τιμή εισόδου

Output: result = τιμή εξόδου

double QInv( double x )

Desc: Αντίστροφη βασικής στατιστικής συνάρτησης (βοηθητική)

Input: x = τιμή εισόδου

Output: result = τιμή εξόδου

double T( double x, double df )

Desc: Συνάρτηση στατιστικής κατανομής T

Input: x = τιμή μεταβλητής

df = βαθμοί ελευθερίας

Output: result = τιμή κατανομής

double TInv( double x )

Desc: Αντίστροφη συνάρτηση στατιστικής κατανομής T

Input: x = τιμή κατανομής

df = βαθμοί ελευθερίας

Output: result = τιμή μεταβλητής

double Chi( double x, double df )

Desc: Συνάρτηση στατιστικής κατανομής Χ

Input: x = τιμή μεταβλητής

df = βαθμοί ελευθερίας

Output: result = τιμή κατανομής

double ChiInv( double x )

Desc: Αντίστροφη συνάρτηση στατιστικής κατανομής Χ

Input: x = τιμή κατανομής

df = βαθμοί ελευθερίας

Output: result = τιμή μεταβλητής

double F( double x, double df1, double df2 )

Desc: Συνάρτηση στατιστικής κατανομής F

Input: x = τιμή μεταβλητής

df1, df2 = βαθμοί ελευθερίας

Output: result = τιμή κατανομής

double FInv( double x )

Desc: Αντίστροφη συνάρτηση στατιστικής κατανομής F

Input: x = τιμή κατανομής

df1, df2 = βαθμοί ελευθερίας

Output: result = τιμή μεταβλητής

#### Αρχείο: MDC.H

Περιγραφή: υλοποίηση ταξινομητή ελάχιστης απόστασης (MDC)

Δομή: πληροφορίες MDC για μια κατηγορία

```
typedef struct tagMDCinfo {
    int          dim;
    int          fvec[MINFEATSELECT];
    double       avg[MINFEATSELECT];
    double       var[MINFEATSELECT]; } TMDInfo;
```

Δομή: διαμόρφωση MDC

```
typedef struct tagCPMInfo {
    long    total;
    long    count[MAX_CLASS][MAX_CLASS];
    TMDCInfo    cls[MAX_CLASS]; }   TCPMInfo;
```

void MDC\_init( TMDCInfo &mdc )

Desc: Αρχικοποίηση δομής MDC

Input: mdc = δομή προς αρχικοποίηση

Output: mdc = αρχικοποιημένη δομή

void MDC\_copy( TMDCInfo &from, TMDCInfo &to )

Desc: Αντιγραφή μιας δομής MDC σε μια άλλη

Input: from = δομή προέλευσης

to = δομή προορισμού

Output: to = αντίγραφο της δομής from

int MDC\_writetofile( TMDCInfo &mdc, FILE \*mfh )

Desc: Αποθήκευση δομής MDC σε αρχείο

Input: mdc = δομή προς αποθήκευση

mfh = stream εξόδου (αρχείο προορισμού)

Output: result = 0 σε επιτυχία

void MDC\_printtostream( TMDCInfo &mdc, FILE \*out )

Desc: Παρουσίαση περιεχομένων δομής MDC

Input: mdc = δομή προς παρουσίαση

out = stream εξόδου (προορισμού)

Output: -

double MDC\_distance( TMDCInfo &mdc, double \*vec, int mode )

Desc: Υπολογισμός απόστασης διανύσματος από την κατηγορία του  
MDC

Input: mdc = δομή μέσου εκπροσώπου κατηγορίας

vec = διάνυσμα εισόδου (άγνωστης κατηγορίας)

mode = συνάρτηση απόστασης (1 = Euclidean, 2 =

Mahalanobis)

Output: result = απόλυτη απόσταση διανύσματος από εκπρόσωπο  
κατηγορίας

```
void CPM_init( TCPMinfo &cpm )
```

Desc: Αρχικοποίηση δομής CPM

Input: cpm = δομή προς αρχικοποίηση

Output: cpm = αρχικοποιημένη δομή

```
void CPM_copy( TCPMinfo &from, TCPMinfo &to )
```

Desc: Αντιγραφή μιας δομής CPM σε μια άλλη

Input: from = δομή προέλευσης

to = δομή προορισμού

Output: to = αντίγραφο της δομής from

```
int CPM_writetofile( TCPMinfo &cpm, FILE *cfh )
```

Desc: Αποθήκευση δομής CPM σε αρχείο

Input: cpm = δομή προς αποθήκευση

cfh = stream εξόδου (αρχείο προορισμού)

Output: result = 0 σε επιτυχία

```
void CPM_printtostream( TCPMinfo &cpm, FILE *out )
```

Desc: Παρουσίαση περιεχομένων δομής CPM (χωρίς τις επιμέρους δομές MDC)

Input: cpm = δομή προς παρουσίαση

out = stream εξόδου (προορισμού)

Output: -

```
void CPM_printalltostream( TCPMinfo &cpm, FILE *out )
```

Desc: Παρουσίαση περιεχομένων δομής CPM (όλα τα περιεχόμενα)

Input: cpm = δομή προς παρουσίαση

out = stream εξόδου (προορισμού)

Output: -

```
int CPM_create_lvo( double *pattern, long pcount, int *select, int  
scount, long lvo_pos, TCPMinfo &cpm1 )
```

Desc: Υλοποίηση ενός κύκλου Leave-1-Out σχεδίασης ταξινομητή

Input: pattern = πίνακας διανυσμάτων εκπαίδευσης

pcount = μέγεθος πίνακα διανυσμάτων

select = διάνυσμα με θέσεις επιλεγμένων συνιστωσών (0 ή 1 σε

κάθε θέση)



scount = μέγεθος διανυσμάτων εκπαίδευσης

Ivoros = θέση του leave-out διανύσματος

cpm1 = τρέχουσα δομή CPM

Output: cpm1 = ενημερωμένη δομή CPM

result = 0 σε επιτυχία

int CPM\_create\_all( double \*pattern, long pcount, int \*select, int  
scount, TCPMinfo &cpm1 )

Desc: Υλοποίηση όλων των κύκλων Leave-1-Out σχεδίασης  
ταξινομητή

Input: pattern = πίνακας διανυσμάτων εκπαίδευσης  
pcount = μέγεθος πίνακα διανυσμάτων  
select = διάνυσμα με θέσεις επιλεγμένων συνιστωσών (0 ή 1 σε

κάθε θέση)

scount = μέγεθος διανυσμάτων εκπαίδευσης

cpm1 = τρέχουσα δομή CPM

Output: cpm1 = ενημερωμένη δομή CPM

result = 0 σε επιτυχία

int CPM\_selectclass( TCPMinfo &cpm, double \*vec, int mode )

Desc: Επιλογή κατηγορίας με βάση την ελάχιστη απόσταση

Input: cpm = τρέχουσα δομή CPM

vec = διάνυσμα εισόδου (άγνωστης κατηγορίας)

mode = συνάρτηση απόστασης (1 = Euclidean, 2 =

Mahalanobis)

Output: result = επιλεγείσα κατηγορία

double CPM\_create( double \*pattern, long pcount, int \*select, int  
scount, int mode, TCPMinfo &cpm )

Desc: Υλοποίηση ολόκληρης της σχεδίασης ταξινομητή

Input: pattern = πίνακας διανυσμάτων εκπαίδευσης

pcount = μέγεθος πίνακα διανυσμάτων

select = διάνυσμα με θέσεις επιλεγμένων συνιστωσών (0 ή 1 σε

κάθε θέση)

scount = μέγεθος διανυσμάτων εκπαίδευσης

mode = συνάρτηση απόστασης (1 = Euclidean, 2 =

Mahalanobis)

Output: cpm = ενημερωμένη δομή CPM

result = τελικό ποσοστό επιτυχίας (0...1)

```
double CPM_optimum( double *pattern, long pcount, long slen, int
*FeatConfig, int mode, TCPMinfo &cpm )
```

Desc: Σχεδίαση βέλτιστου MDC ταξινομητή

Input: pattern = πίνακας διανυσμάτων εκπαίδευσης  
pcount = μέγεθος πίνακα διανυσμάτων  
slen = μέγεθος διανυσμάτων εκπαίδευσης  
FeatConfig = πίνακας διαμορφώσεων συνόλων εκπαίδευσης  
ταξινομητή  
mode = συνάρτηση απόστασης (1 = Euclidean, 2 = Mahalanobis)

Output: cpm = ενημερωμένη (βέλτιστη) δομή CPM  
result = τελικό ποσοστό επιτυχίας (0..1)

Αρχείο: FCD.CPP

Περιγραφή: κώδικας κυρίως προγράμματος (έκδοση κονσόλας)

```
long writeauxfile1( double *pattern, long patlen, long patsize, int
clscount, int *fset, int fszize, FILE *fto )
```

Desc: Μεταφορά προτύπων διανυσμάτων σε αρχείο, T-test επιλογή (χρήση από BPM)

Input: pattern = πίνακας προτύπων διανυσμάτων  
patlen = μέγεθος πίνακα διανυσμάτων  
patsize = μέγεθος πρότυπου διανύσματος  
clscount = πλήθος κατηγοριών προτύπων διανυσμάτων  
fset = διάνυσμα επιλεγέντων συνιστωσών (μέσω T-test)  
fszize = μέγεθος διανύσματος επιλεγέντων συνιστωσών  
fto = stream εξόδου (αρχείο προορισμού)

Output: return = πλήθος διανυσμάτων που γράφτηκαν (0 σε αποτυχία)

```
long writeauxfile2( double *pattern, long patlen, long patsize, int
clscount, int *fset, int fszize, FILE *fto )
```

Desc: Μεταφορά προτύπων διανυσμάτων σε αρχείο, MDC επιλογή (χρήση από BPM)

Input: pattern = πίνακας προτύπων διανυσμάτων  
patlen = μέγεθος πίνακα διανυσμάτων  
patsize = μέγεθος πρότυπου διανύσματος  
clscount = πλήθος κατηγοριών προτύπων διανυσμάτων

fset = διάνυσμα επιλεγέντων συνιστωσών (optimum MDC)

fsize = μέγεθος διανύσματος επιλεγέντων συνιστωσών

fto = stream εξόδου (αρχείο προορισμού)

Output: return = πλήθος διανυσμάτων που γράφτηκαν (0 σε αποτυχία)

double \* readpatterns( FILE \*ffrom, long \*patlen, long \*patsize )

Desc: Ανάγνωση προτύπων διανυσμάτων από αρχείο κειμένου (τύπου FCD)

Input: ffrom = stream εισόδου (αρχείο προέλευσης)

Output: patlen = μέγεθος πίνακα διανυσμάτων

patsize = μέγεθος πρότυπου διανύσματος

return = πίνακας προτύπων διανυσμάτων (NULL σε αποτυχία)

int Ptvalue\_compare(const void \*elem1, const void \*elem2)

Desc: Συνάρτηση σύγκρισης για ζεύγη τιμών (χρήση από την qsort())

Input: elem1, elem2 = τιμές προς σύγκριση

Output: result = -1, 0, +1 για: elem1 < elem2, elem1 = elem2, elem1 > elem2 αντίστοιχα.

long selectfeatures( double critical, int leastsel, double \*tfunc, int \*selection, TPtvalue \*fvec, double \*pattern, long patlen, long patsz )

Desc: Εκτέλεση T-test και επιλογή αποδοτικών συνιστωσών

Input: critical = όριο σημαντικότητας για το T-test (παράμετρος «α»)

leastsel = ελάχιστο πλήθος επιλεγέντων συνιστωσών

pattern = πίνακας προτύπων διανυσμάτων

patlen = μέγεθος πίνακα διανυσμάτων

patsz = μέγεθος προτύπων διανυσμάτων

Output: tfunc = αντίστοιχη τιμή αντίστροφης κατανομής T

selection = διάνυσμα επιλεγέντων συνιστωσών (τιμές 0 ή 1)

fvec = ταξινομημένο διάνυσμα ζευγών συνιστώσας-τιμής T

result = πλήθος επιλεγέντων συνιστωσών

long createfeaturecombs4( int max\_features, int \*FeatComb, long fcombs, long \*FeatCombN )

Desc: Κατασκευή συνδυασμών συνιστωσών (διαμορφώσεων)

Input: max\_features = μέγιστο πλήθος συνιστωσών

fcombs = πλήθος συνδυασμών για δεδομένο (max\_features) πλήθος συνιστωσών

Output:     FeatComb = πίνακας επιλεγμένων συνιστωσών ανά διαμόρφωση  
               FeatCombN = διάνυσμα μετρητών διαμορφώσεων ανά διάσταση  
               result = συνολικό πλήθος διαμορφώσεων

int mapfeatures( int \*sel\_features, int \*SelfFeatMap, int maxfeat )

Desc:       Μετατροπή διανύσματος επιλεγμένων συνιστωσών σε επιλεγμένες θέσεις

Input:       sel\_features = διάνυσμα επιλεγμένων συνιστωσών  
               max\_features = μέγιστο πλήθος συνιστωσών

Output:      SelfFeatMap = διάνυσμα επιλεγμένων θέσεων  
               result = μετατροπές που έγιναν

void translatefeatcombin4( long combs, int \*FeatComb, int \*SelfFeatMap, int maxfeat )

Desc:       Προετοιμασία διανύσματος συνιστωσών διαμόρφωσης

Input:       combs = πλήθος συνδυασμών (διαμορφώσεων)  
               FeatComb = πίνακας επιλεγμένων συνιστωσών ανά διαμόρφωση  
               SelfFeatMap = διάνυσμα επιλεγμένων θέσεων  
               maxfeat = μέγιστο πλήθος συνιστωσών

Output:      FeatComb = μετασχηματισμένος πίνακας επιλεγμένων συνιστωσών ανά διαμόρφωση

long writeselcombins( char \*prefix, long combs, int \*FeatComb, double \*pattern, long patlen )

Desc:       Αποθήκευση συνόλων προτύπων διανυσμάτων για κάθε διαμόρφωση

Input:       prefix = πρόθεμα για τα αρχεία εξόδου  
               combs = πλήθος συνδυασμών (διαμορφώσεων)  
               FeatComb = πίνακας επιλεγμένων συνιστωσών ανά διαμόρφωση  
               pattern = πίνακας προτύπων διανυσμάτων  
               patlen = μέγεθος πίνακα διανυσμάτων

Output:      result = πλήθος αρχείων που δημιουργήθηκαν

long storeselcombins( long combs, int \*FeatComb, long fcombs, int \*FeatConfig )

Desc:       Προετοιμασία διαμορφώσεων

Input:       combs = πλήθος συνδυασμών (διαμορφώσεων)  
               FeatComb = πίνακας επιλεγμένων συνιστωσών ανά διαμόρφωση

fcombs = μέγεθος διανύσματος διαμόρφωσης

Output: FeatConfig = πίνακας διαμορφώσεων

result = διαμορφώσεις που κατασκευάστηκαν

Αρχείο: FCDW.CPP

Περιγραφή: κώδικας κυρίως προγράμματος (έκδοση γραφικού περιβάλλοντος)

Το πρόγραμμα της έκδοσης γραφικού περιβάλλοντος χρησιμοποιεί ουσιαστικά τον ίδιο πυρήνα με αυτό της έκδοσης κονσόλας. Εκτός από την προσθήκη ορισμένων βοηθητικών δομών και συναρτήσεων για την ενημέρωση της απεικόνισης, το πρόγραμμα καλεί μια τροποποιημένη έκδοση της ρουτίνας main() του κώδικα της έκδοσης κονσόλας. Η αρχιτεκτονική και η λειτουργικότητα της έκδοσης γραφικού περιβάλλοντος καλύπτεται πλήρως από την περιγραφή του κώδικα της έκδοσης κονσόλας.

### **A.2.3 Τεχνικές πληροφορίες**

Γλώσσα προγραμματισμού:	ANSI C/C++
Πλατφόρμα ανάπτυξης:	Win32 (fcd/fcdw), Windows SDK (fcdw)
Περιβάλλον ανάπτυξης:	Microsoft Visual C++ 5.0
Σύστημα ανάπτυξης/δοκιμής:	h/w: AMD K7 Athlon, iPentium-II, iPentium-III, iPentium MMX s/w: MS-Windows95, MS-Windows98, MS-WindowsNT
Πηγαίος κώδικας:	FCD = 1237 γραμμές, FCDW = 1884 γραμμές
Πρόσθετες βιβλιοθήκες:	-

## **A.3 BPM: Neural Network Classifier Design**

### **A.3.1 Εισαγωγή**

Το πρόγραμμα BPM αποτελεί το βασικό εργαλείο σχεδίασης και κατασκευής ταξινομητών βασισμένων σε Τεχνητά Νευρωνικά Δίκτυα (ΤΝΔ). Με βάση κάποιο σύνολο προτύπων διανυσμάτων, κατασκευάζει την βέλτιστη διαμόρφωση μιας δεδομένης τοπολογίας νευρωνικού (μη γραμμικού) ταξινομητή για την

κατηγοριοποίηση του άγνωστου προτύπου σε μια από τις διαθέσιμες κατηγορίες. Η εφαρμογή είναι ανεπτυγμένη με τέτοιο τρόπο ώστε η χρησιμότητα και η πρακτική εφαρμογή της να μπορεί να επεκταθεί εύκολα σε κάθε είδους εφαρμογή που απαιτεί τη σχεδίαση νευρωνικών ταξινομητών με βάση κάποια πρότυπα διανύσματα.

### A.3.2 Ανάλυση κώδικα

Παρακάτω αναφέρονται οι βασικότερες δομές και συναρτήσεις που χρησιμοποιούνται για την υλοποίηση της εφαρμογής. Η αναλυτική τεκμηρίωση των διεπαφών έχει ως σκοπό την πληρέστερη τεκμηρίωση του κώδικα και την ευκολότερη επέκταση ή επαναχρησιμοποίησή του σε ανάλογα προγράμματα.

Αρχείο: BPM\_CNST.H

Περιγραφή: Συμβολικές σταθερές, βοηθητικές παράμετροι, μακροεντολές

Δομή: Νευρώνας

```
typedef struct {
    TWeight      *w;
    TWeight *wprev;
    TCount wnum;
    TWeight h;
    TValue eval; } TNeuron;
```

Δομή: Νευρωνικό επίπεδο

```
typedef struct {
    TNeuron      *neu;
    TCount nnum; } TLayer;
```

Δομή: Νευρωνικό δίκτυο

```
typedef struct {
    TLayer *lay;
    TCount lnum; } TNet;
```

Δομή: Ενδιάμεση μνήμη προσωρινής αποθήκευσης (I/O)

```
typedef struct {
    FILE *fh;
    float **inpvec, **outvec;
```

```
TCount nvec, ivec, ovec, pos; } Tmembuf;
```

### Αρχείο: BPM\_IMP2.H

Περιγραφή: Υλοποίηση βασικών λειτουργιών νευρωνικού δικτύου

```
void __inline fatal( const char *mes )
```

Desc: Εμφάνιση μηνύματος σφάλματος και τερματισμός

Input: mes = μήνυμα σφάλματος

Output: Έξοδος στο σύστημα με ένδειξη σφάλματος (exit(1))

```
int initialize_buffers( Tmembuf *trn_buf, Tmembuf *val_buf,
Tmembuf *tst_buf )
```

Desc: Αρχικοποίηση περιοχών προσωρινής αποθήκευσης και ανάγνωση αρχείων

Input: trn\_buf = μνήμη για αρχείο εκπαίδευσης

val\_buf = μνήμη για αρχείο επικύρωσης

tst\_buf = μνήμη για αρχείο αξιολόγησης

Output: 0 με επιτυχία

```
void close_buffers( Tmembuf *trn_buf, Tmembuf *val_buf,
Tmembuf *tst_buf )
```

Desc: Αποδέσμευση περιοχών προσωρινής αποθήκευσης

Input: trn\_buf = μνήμη για αρχείο εκπαίδευσης

val\_buf = μνήμη για αρχείο επικύρωσης

tst\_buf = μνήμη για αρχείο αξιολόγησης

Output: -

```
void openfiles( char *patfname, TCount *npat, char *valfname,
TCount *nval, char *testfname, TCount *ntest )
```

Desc: Διαδικασία ανάκτησης αρχείων προτύπων

Input: -

Output: patfname = όνομα αρχείου εκπαίδευσης

npat = πλήθος προτύπων στο αρχείο εκπαίδευσης

valfname = όνομα αρχείου επικύρωσης

nval = πλήθος προτύπων στο αρχείο επικύρωσης

testfname = όνομα αρχείου αξιολόγησης

ntest = πλήθος προτύπων στο αρχείο αξιολόγησης

```
int initfiles( char *patfname, FILE **pat, Tmembuf *trn_buf,
TCount npat, char *valfname, FILE **val, Tmembuf *val_buf, TCount
nval, char *testfname, FILE **test, Tmembuf *tst_buf, TCount ntest )
```

Desc: Διαδικασία ανοίγματος αρχείων προτύπων

Input: patfname = όνομα αρχείου εκπαίδευσης  
pat = stream εισόδου (αρχείο εκπαίδευσης)  
trn\_buf = μνήμη για αρχείο εκπαίδευσης  
npat = πλήθος προτύπων στο αρχείο εκπαίδευσης  
valfname = όνομα αρχείου επικύρωσης  
val = stream εισόδου (αρχείο επικύρωσης)  
val\_buf = μνήμη για αρχείο επικύρωσης  
nval = πλήθος προτύπων στο αρχείο επικύρωσης  
testfname = όνομα αρχείου αξιολόγησης  
test = stream εισόδου (αρχείο αξιολόγησης)  
tst\_buf = μνήμη για αρχείο αξιολόγησης  
ntest = πλήθος προτύπων στο αρχείο αξιολόγησης

Output: 0 με επιτυχία

```
void __inline closefiles( FILE **pat, FILE **val, FILE **test )
```

Desc: Κλείσιμο αρχείων προτύπων

Input: pat = stream εισόδου (αρχείο εκπαίδευσης)  
val = stream εισόδου (αρχείο επικύρωσης)  
test = stream εισόδου (αρχείο αξιολόγησης)

```
void __inline readpat_buffered( Tmembuf *patbuff, float *vec, int
vecsize, float *dis, int dis_size)
```

Desc: Ανάγνωση επόμενου προτύπου από αρχείο

Input: patbuff = μνήμη τρέχοντος αρχείου προτύπων  
vec = διάνυσμα εισόδου (προς συμπλήρωση)  
vecsize = μέγεθος διανύσματος εισόδου  
dis = διάνυσμα εξόδου (προς συμπλήρωση)  
size = μέγεθος διανύσματος εξόδου

Output: vec = διάνυσμα εισόδου (συμπληρωμένο)  
dis = διάνυσμα εξόδου (συμπληρωμένο)

```
void __inline rewind_buffered( Tmembuf *patbuff )
```

Desc: Επιστροφή δείκτη τρέχουσας θέσης ανάγνωσης στην αρχή

Input: patbuff = μνήμη τρέχοντος αρχείου προτύπων



Output: -

```
int __inline init_neuron( TNeuron *neu, TCount nweights, TWeight
*weights, TWeight theta)
```

Desc: Αρχικοποίηση δομής νευρώνα

Input: nweights = μέγεθος διανύσματος βαρών  
theta = αρχική τιμή threshold

Output: neu = αρχικοποιημένη δομή νευρώνα  
weights = αρχικοποιημένο διάνυσμα βαρών νευρώνα  
result = 0 με επιτυχία

```
int __inline init_layer( TLayer *lay, TCount nneurons )
```

Desc: Αρχικοποίηση δομής νευρωνικού επιπέδου

Input: nneurons = μέγεθος διανύσματος νευρώνων

Output: lay = αρχικοποιημένη δομή νευρωνικού επιπέδου  
result = 0 με επιτυχία

```
int __inline init_net( TNet *net, TCount nlayers )
```

Desc: Αρχικοποίηση δομής νευρωνικού δικτύου

Input: nlayers = μέγεθος διανύσματος νευρωνικών επιπέδων

Output: net = αρχικοποιημένη δομή νευρωνικού δικτύου  
result = 0 με επιτυχία

```
void create_net( TNet *BP_net, TNet *aux_net, TWeight *coeff,
TWeight *mcoeff, TCount *maxiters, TValue *goodvalptg, Tmembuf
*trn_buf, Tmembuf *val_buf, Tmembuf *tst_buf )
```

Desc: Διαδικασία καθορισμού τοπολογίας και αρχικοποίησης δικτύου

Input: -

Output: BP\_net = αρχικοποιημένη δομή νευρωνικού δικτύου (κύρια δομή)

aux\_net = αρχικοποιημένη δομή νευρωνικού δικτύου (βοηθητική δομή)

coeff = συντελεστής μάθησης ( $\lambda$ : 0...1)

mcoeff = συντελεστής momentum ( $\mu$ : 0...1)

maxiters = μέγιστος πλήθος κύκλων εκπαίδευσης

goodvalptg = όριο τερματισμού εκπαίδευσης από σύνολο επικύρωσης (0...1)

trn\_buf = μνήμη για αρχείο εκπαίδευσης

val\_buf = μνήμη για αρχείο επικύρωσης  
 tst\_buf = μνήμη για αρχείο αξιολόγησης

void \_\_inline done\_neuron( TNeuron \*neu )

Desc: Αποδέσμευση δομής νευρώνα

Input: neu = τρέχουσα δομή νευρώνα

Output: -

void \_\_inline done\_layer( TLayer \*lay )

Desc: Αποδέσμευση δομής νευρωνικού επιπέδου

Input: lay = τρέχουσα δομή νευρωνικού επιπέδου

Output: -

void \_\_inline ddone\_net( TNet \*net )

Desc: Αποδέσμευση δομής νευρωνικού δικτύου

Input: net = τρέχουσα δομή νευρωνικού δικτύου

Output: -

void \_\_inline done\_net(TNet \*bp, TNet \*aux)

Desc: Αποδέσμευση δομών τρέχοντος νευρωνικού δικτύου

Input: bp, aux = δομές τρέχοντος νευρωνικού δικτύου

Output: -

void print\_net(TNet \*net)

Desc: Παρουσίαση τρέχουσας δομής νευρωνικού δικτύου

Input: net = τρέχουσα δομή νευρωνικού δικτύου

Output: -

long quicksave\_net( TNet \*opt\_net, char \*fname )

Desc: Αποθήκευση δομής νευρωνικού δικτύου σε αρχείο κειμένου

Input: opt\_net = τρέχουσα δομή νευρωνικού δικτύου

fname = όνομα (νέου) αρχείου

Output: result = αντικείμενα που γράφτηκαν (0 με σφάλμα)

void copy\_net(TNet \*s, TNet \*t)

Desc: Αντιγραφή δομής νευρωνικού δικτύου σε μια άλλη.

Input: s = δομή νευρωνικού δικτύου (προέλευση)

t = δομή νευρωνικού δικτύου (προορισμός)

Output: t = αντίγραφο αρχικής δομής νευρωνικού δικτύου

TValue \_\_inline sigmoid( TValue val )

Desc: Σιγμοειδής συνάρτηση μεταφοράς (νευρώνες)

Input: val = τρέχουσα τιμή μεταβλητής

Output: return = τιμή συνάρτησης

void calc\_output( TNet \*bp, const float \*vec )

Desc: Υπολογισμός εξόδου δομής νευρωνικού δικτύου

Input: bp = τρέχουσα δομή νευρωνικού δικτύου

vec = τρέχον διάνυσμα εισόδου

Output: (ενημέρωση εσωτερικών μεταβλητών της δομής bp)

void update\_weights( TNet \*bp, const float \*vec, const float \*dis, const TWeight coeff, const TWeight mcoeff )

Desc: Αναπροσαρμογή των βαρών του δικτύου με βάση το τρέχον σφάλμα

Input: bp = τρέχουσα δομή νευρωνικού δικτύου

vec = τρέχον διάνυσμα εισόδου

dis = τρέχον διάνυσμα επιθυμητής εξόδου

coeff = συντελεστής μάθησης ( $\lambda$ )

mcoeff = συντελεστής momentum ( $\mu$ )

Output: -

void print\_out(TNet \*bp, float \*dis)

Desc: Παρουσίαση τρέχουσας εξόδου του δικτύου

Input: bp = τρέχουσα δομή νευρωνικού δικτύου

dis = τρέχον διάνυσμα επιθυμητής εξόδου

Output: -

int recognised(TNet \*bp, float \*dis)

Desc: Σύγκριση τρέχουσας εξόδου του δικτύου με την επιθυμητή

Input: bp = τρέχουσα δομή νευρωνικού δικτύου

dis = τρέχον διάνυσμα επιθυμητής εξόδου

Output: result = 1 αν αναγνωρίστηκε σωστά, 0 διαφορετικά

TValue \_\_inline calcerror(TNet \*bp, float \*dis, int ds)

Desc: Υπολογισμός τρέχοντος σφάλματος εξόδου του δικτύου (SSE)

Input: bp = τρέχουσα δομή νευρωνικού δικτύου

dis = τρέχον διάνυσμα επιθυμητής εξόδου

ds = μέγεθος διανύσματος επιθυμητής εξόδου

Output: result = άθροισμα τετραγώνων επιμέρους σφαλμάτων (SSE)

int check\_validation( Tmembuf \*val\_buf, int valsize, TValue \*meanerr, TNet \*bp, TNet \*aux)

Desc: Έλεγχος απόδοσης δικτύου στο σύνολο επικύρωσης

Input: val\_buf = μνήμη αρχείου επικύρωσης

valsize = πλήθος διανυσμάτων επικύρωσης

bp, aux = τρέχουσες δομές νευρωνικού δικτύου

Output: meanerr = μέσο τετραγωνικό σφάλμα ταξινόμησης

aux = ενημερωμένη βέλτιστη δομή δικτύου (αν αυξήθηκε η συνολική απόδοση)

result = πλήθος σωστά ταξινομημένων προτύπων

TCount check\_testset( Tmembuf \*tst\_buf, int testsize, TValue \*meanerr, TNet \*bp )

Desc: Έλεγχος απόδοσης δικτύου στο σύνολο αξιολόγησης

Input: tst\_buf = μνήμη αρχείου αξιολόγησης

testsize = πλήθος διανυσμάτων αξιολόγησης

bp = τρέχουσα δομή νευρωνικού δικτύου

Output: meanerr = μέσο τετραγωνικό σφάλμα ταξινόμησης

result = πλήθος σωστά ταξινομημένων προτύπων

TCount check\_testset\_c2( Tmembuf \*tst\_buf, int testsize, TValue \*meanerr, TCount \*result, TNet \*bp )

Desc: Έλεγχος απόδοσης δικτύου στο σύνολο αξιολόγησης με κατασκευή πίνακα αλήθειας

Input: tst\_buf = μνήμη αρχείου αξιολόγησης

testsize = πλήθος διανυσμάτων αξιολόγησης

result = διάνυσμα πίνακα αλήθειας με αποτελέσματα (2x2)

bp = τρέχουσα δομή νευρωνικού δικτύου

Output: meanerr = μέσο τετραγωνικό σφάλμα ταξινόμησης

result = πλήθος σωστά ταξινομημένων προτύπων

```
int __inline allpaterns( Tmembuf *trn_buf, TCount *howmany,
TCount *patcount, TCount npat, TCount *iter)
```

Desc: Έλεγχος ολοκλήρωσης εκπαίδευσης και διαχείριση αρχείου εκπαίδευσης

Input: trn\_buf = μνήμη αρχείου εκπαίδευσης  
npat = πλήθος διανυσμάτων εκπαίδευσης

Output: howmany = πλήθος σωστά αναγνωρισμένων προτύπων  
patcount = τρέχουσα θέση στο αρχείο εκπαίδευσης  
iter = τρέχον κύκλος εκπαίδευσης  
result = 1 αν όλα αναγνωρίστηκαν, 0 διαφορετικά

```
void teach_net(TNet *bp, TNet *aux, Tmembuf *trn_buf, TCount
npat, Tmembuf *val_buf, TCount valsize, TWeight coeff, TWeight
mcoeff, TCount maxiters, TValue goodvalptg )
```

Desc: Διαδικασία εκπαίδευσης δομής νευρωνικού δικτύου

Input: BP\_net = δομή νευρωνικού δικτύου (κύρια δομή)  
aux\_net = δομή νευρωνικού δικτύου (βοηθητική δομή)  
trn\_buf = μνήμη για αρχείο εκπαίδευσης  
npat = πλήθος προτύπων εκπαίδευσης  
val\_buf = μνήμη για αρχείο επικύρωσης  
valsize = πλήθος προτύπων επικύρωσης  
coeff = συντελεστής μάθησης ( $\lambda$ : 0...1)  
mcoeff = συντελεστής momentum ( $\mu$ : 0...1)  
maxiters = μέγιστος πλήθος κύκλων εκπαίδευσης  
goodvalptg = όριο τερματισμού εκπαίδευσης από σύνολο

επικύρωσης (0...1)

Output: (εκπαιδευμένο δίκτυο bp)

```
void test_net(TNet *bp, Tmembuf *tst_buf, TCount ntest, TWeight
lcoeff, TWeight mcoeff )
```

Desc: Διαδικασία αξιολόγησης δομής νευρωνικού δικτύου

Input: BP\_net = δομή νευρωνικού δικτύου (κύρια δομή)  
tst\_buf = μνήμη για αρχείο αξιολόγησης  
ntest = πλήθος προτύπων αξιολόγησης  
lcoeff = συντελεστής μάθησης ( $\lambda$ : 0...1)  
mcoeff = συντελεστής momentum ( $\mu$ : 0...1)

Αρχείο: BPM.CPP

Περιγραφή: κώδικας κυρίως προγράμματος (έκδοση κονσόλας)

Περιλαμβάνει μονάχα το κύριο πρόγραμμα της εφαρμογής, κανέναν ορισμό δομής, ρουτίνας ή μακροεντολής.

Αρχείο: BPMW.CPP

Περιγραφή: κώδικας κυρίως προγράμματος (έκδοση γραφικού περιβάλλοντος)

Το πρόγραμμα της έκδοσης γραφικού περιβάλλοντος χρησιμοποιεί ουσιαστικά τον ίδιο πυρήνα με αυτό της έκδοσης κονσόλας. Εκτός από την προσθήκη ορισμένων βοηθητικών δομών και συναρτήσεων για την ενημέρωση της απεικόνισης, το πρόγραμμα καλεί μια τροποποιημένη έκδοση της ρουτίνας main() του κώδικα της έκδοσης κονσόλας. Η αρχιτεκτονική και η λειτουργικότητα της έκδοσης γραφικού περιβάλλοντος καλύπτεται πλήρως από την περιγραφή του κώδικα της έκδοσης κονσόλας.

**A.3.3 Τεχνικές πληροφορίες**

Γλώσσα προγραμματισμού:	ANSI C/C++
Πλατφόρμα ανάπτυξης:	Win32 (bpm/bpmw), Windows SDK (bpmw)
Περιβάλλον ανάπτυξης:	Microsoft Visual C++ 5.0
Σύστημα ανάπτυξης/δοκιμής:	h/w: AMD K7 Athlon, iPentium-II, iPentium-III, iPentium MMX s/w: MS-Windows95, MS-Windows98, MS-WindowsNT
Πηγαίος κώδικας:	BPM = 1089 γραμμές, BPMW = 1814 γραμμές
Πρόσθετες βιβλιοθήκες:	-

**A.4 MLP: Neural Network Executor****A.4.1 Εισαγωγή**

Το πρόγραμμα MLP αποτελεί το βοηθητικό εργαλείο για την αξιολόγηση και πρακτική χρήση νευρωνικών δικτύων που έχουν προηγουμένως σχεδιαστεί και εκπαιδευτεί από το αντίστοιχο πρόγραμμα του πακέτου (BPM). Η εφαρμογή είναι ανεπτυγμένη με τέτοιο τρόπο ώστε η χρησιμότητα και η πρακτική εφαρμογή της να μπορεί να επεκταθεί εύκολα σε κάθε είδους εφαρμογή που χρησιμοποιεί δομές νευρωνικών ταξινομητών με βάση κάποια πρότυπα διανύσματα.

**A.4.2 Ανάλυση κώδικα**

Ο κώδικας του προγράμματος ακολουθεί την ίδια ακριβώς αρχιτεκτονική και δομή με αυτή του προγράμματος για την εκπαίδευση του νευρωνικού δικτύου (BPM). Τμήματα του κώδικα της εφαρμογής εκπαίδευσης έχουν χρησιμοποιηθεί αυτούσια ή με ελάχιστες τροποποιήσεις για την μετατροπή της φάσης αξιολόγησης σε αυτόνομη εφαρμογή. Η αναλυτική τεκμηρίωση των δομών και των ρουτινών καλύπτεται πλήρως από τα αντίστοιχα τμήματα του προγράμματος εκπαίδευσης (bpm.c, bpm\_cnst.h, bpm\_imp2.h).

**A.4.3 Τεχνικές πληροφορίες**

Γλώσσα προγραμματισμού:	ANSI C/C++
Πλατφόρμα ανάπτυξης:	Win32 (mlp)
Περιβάλλον ανάπτυξης:	Microsoft Visual C++ 5.0
Σύστημα ανάπτυξης/δοκιμής:	h/w: AMD K7 Athlon, iPentium-II, iPentium-III, iPentium MMX s/w: MS-Windows95, MS-Windows98, MS-WindowsNT
Πηγαίος κώδικας:	MLP = 732 γραμμές
Πρόσθετες βιβλιοθήκες:	-

## A.5 SHUFFLE: Patterns Set Randomizer

### A.5.1 Εισαγωγή

Το πρόγραμμα SHUFFLE αποτελεί το βοηθητικό εργαλείο για την προετοιμασία των αρχείων των προτύπων εκπαίδευσης, πριν τη χρησιμοποίησή τους από την αντίστοιχη εφαρμογή σχεδίασης και εκπαίδευσης του νευρωνικού δικτύου. Η προεπεξεργασία των συνόλων εκπαίδευσης δεν είναι υποχρεωτική, αλλά σε μερικές περιπτώσεις προτείνεται για την καλύτερη σύγκλιση κατά της φάση της εκπαίδευσης. Η εφαρμογή είναι ανεπτυγμένη με τέτοιο τρόπο ώστε η χρησιμότητα και η πρακτική εφαρμογή της να μπορεί να επεκταθεί εύκολα σε αρχεία κειμένου με πρότυπα εισόδου-εξόδου μορφής μίας, δύο ή περισσότερων γραμμών.

### A.5.2 Ανάλυση κώδικα

Ο κώδικας του προγράμματος είναι πολύ απλός σε δομή και λειτουργία, μια και είναι οργανωμένος κατά τρόπο κατάλληλο για την υλοποίηση ως αυτόνομο εργαλείο και όχι σαν προγραμματιστική βιβλιοθήκη. Αρχικά δημιουργείται ένας πίνακας τυχαίας αναδιάταξης με βάση τον οποίο θα γίνει στη συνέχεια η δόμηση του νέου αρχείου προτύπων. Για την επιτάχυνση των διαδικασιών ανάγνωσης και εγγραφής σε αρχεία κειμένου, η αναδιάταξη των διανυσμάτων (γραμμών κειμένου) γίνεται αποκλειστικά σε περιοχές της κύριας μνήμης και με τη χρήση μονάχα των αρχικών δεδομένων, χωρίς δηλαδή αντιγραφές δεδομένων.

### A.5.3 Τεχνικές πληροφορίες

Γλώσσα προγραμματισμού:	ANSI C/C++
Πλατφόρμα ανάπτυξης:	Win32 (shuffle)
Περιβάλλον ανάπτυξης:	Microsoft Visual C++ 5.0
Σύστημα ανάπτυξης/δοκιμής:	h/w: AMD K7 Athlon, iPentium-II, iPentium-III, iPentium MMX s/w: MS-Windows95, MS-Windows98, MS-WindowsNT
Πηγαίος κώδικας:	SHUFFLE = 246 γραμμές
Πρόσθετες βιβλιοθήκες:	-



Copyright (c) 2012, Harris V. Georgiou

## Βιβλιογραφία – Αναφορές

- [01] Raeth, Schalaps, Limberg, Zuna, Lorenz, Kaick, J. Lorenz, Kommerell  
“Diagnostic Accuracy of Computerized B-Scan Texture Analysis and Conventional Ultrasonography in Diffuse Parenchymal and Malignant Liver Disease”  
J Clin Ultrasound 13:87-99, Feb. 1985
- [02] Bocchi, Coppini, Dominics, Valli  
“Tissue characterization from X-ray images”  
Med. Eng. Phys. Vol. 19, No 4, pp. 336-342, 1997
- [03] Ahmet, Rao  
“Feature Selection in Pattern Recognition” (section, p.225-253)  
“Orthogonal Transforms for Digital Signal Processing”  
Springer-Verlag (NY), 1975
- [04] Haralick, Shanmugam, Dinstein  
“Textural Features for Image Classification”  
IEEE Trans. on Systems, Man and Cybernetics, Vol.smc-3, No.6, Nov. '73
- [05] Lerski, Smith, Morley, Barnett, Mills, Watkinson, MacSween  
“Discriminant Analysis of Ultrasonic Texture Data in Diffuse Alcoholic Liver Disease”  
Ultrasonic Imaging 3, 164-172, 1981
- [06] Galloway  
“Texture Analysis Using Gray Level Run Lengths”  
Computer Graphics and Image Processing 4, 172-179, 1975
- [07] Bleck, Ranft, Gebel, Hecker, Westhoff, Thiesemann, Wanger, Manns  
“Random Field Models in the Textural Analysis of Ultrasonic Images of the Liver”  
IEEE Trans. on Medical Imaging, Vol. 15, No 6, Dec. '96

- [08] Haralick  
"Statistical and Structural Approaches to Texture"  
Proceedings of the IEEE, Vol. 67, No 5, May '79
- [09] Khotaznad  
"Classification of Invariant Image Representations Using a Neural Network"  
IEEE Trans. on Acoustics, Speech, and Signal Proc., Vol. 38, No 6, 1990
- [10] Σ. Θεοδωρίδης  
"Αναγνώριση Προτύπων και Εφαρμογές σε Ανάλυση Εικόνων"  
Πανεπιστημιακές σημειώσεις (Τμ. Πληροφ. Πανεπ. Αθ.) – 1996
- [11] A. Tanenbaum, Y. Langsam, M. Augenstein  
"Data Structures Using C"  
Prentice-Hall International Ed. – 1990
- [12] Γ. Παπαδουράκης, Γ. Μπέμης  
"Τεχνητά Νευρωνικά Δίκτυα – I"  
Ενημερωτικό Άρθρο Τεχν. Χρον. Β, τόμος 11, τεύχος 3 – 1991
- [13] Γ. Παπαδουράκης, Γ. Μπέμης  
"Τεχνητά Νευρωνικά Δίκτυα – II"  
Ενημερωτικό Άρθρο Τεχν. Χρον. Β, τόμος 12, τεύχος 1 – 1992
- [14] 3<sup>ο</sup> Πανελλήνιο Συνέδριο Πληροφορικής  
"3<sup>ο</sup> Πανελλήνιο Συνέδριο Πληροφορικής – Πρακτικά"  
Ελληνική Εταιρία Επιστήμης Η/Υ & Πληροφορικής – 1990
- [15] I. Guyon, J. Makhoui  
"What size test set gives good error rate estimates?"  
IEEE CS 105690 – 1998
- [16] Χ. Γεωργίου, Σ. Μελισσόβας, Δ. Παπαδόπουλος  
"Μέθοδοι Εκπαίδευσης και Μοντέλα Τεχνητών Νευρωνικών Δικτύων"  
Πανεπιστημιακή εργασία (Τμ. Πληροφ. Πανεπ. Ιωαν.) – 1995

- [17] Γ. Ρίζος  
“Τεχνητά Νευρωνικά Δίκτυα: Θεωρία & Εφαρμογές”  
Παπασωτηρίου - 1996
- [18] Κ. Κουτρούμπας  
“Νευρωνικά Δίκτυα”  
Πανεπιστημιακές σημειώσεις (ΜΠΣ) – 1999
- [19] Π. Λιγομενίδης, Jyh-Shyan Lin, Yun-Shu Chiou  
“Εγκαιρή Διάγνωση του Καρκίνου των Πνευμόνων με Ψηφιακή-  
Νευρωνική Τεχνολογία”  
Πρακτικά της Ακαδημίας Αθηνών – Έτος 1994, Τόμος 69<sup>ος</sup>  
Γραφείο Δημοσιευμάτων της Ακαδημίας Αθηνών – 1994
- [20] R. Gonzalez, R. Woods  
“Digital Image Processing”  
Addison-Wesley Publishing Company – 1992
- [21] Lori Mann Bruce, Reza R. Adhami  
“Classifying Mamographic Mass Shapes Using the Wavelet Transform  
Modulus-Maxima Method”  
IEEE Transactions on Medical Imaging, vol.18, No.12, Dec. 1999
- [22] Jong Kook Kim, Hyun Wook Park  
“Statistical Textural Features for Detection of Microcalcifications in  
Digitized Mammograms”  
IEEE Transactions on Medical Imaging, vol.18, No.3, Mar. 1999
- [23] Baoyu Zheng, Wei Qian, Laurence Clarke  
“Digital Mammography: Mixed Feature Neural Network with Spectral  
Entropy Decision for Detection of Microcalcifications”  
IEEE Transactions on Medical Imaging, vol.15, No.5, Oct. 1996
- [24] Songyang Yu, Ling Guan  
“A CAD System for the Automatic Detection of Clustered  
Microcalcifications in Digitized Mammogram Films”  
IEEE Transactions on Medical Imaging, vol.19, No.2, Feb. 2000

- [25] Δ. Καρράς  
"Εισαγωγή στα Νευρωνικά Δίκτυα"  
Πανεπιστημιακές σημειώσεις (Τμ. Πληροφ. Πανεπ. Ιωαν.) – 1996
- [26] Simon Haykin  
"Adaptive Filter Theory" – 3<sup>rd</sup>/ed.  
Prentice-Hall Inc. – 1996
- [27] Σ. Θεοδωρίδης  
"Προσαρμοστικοί Αλγόριθμοι Επεξεργασίας Σήματος"  
Πανεπιστημιακές σημειώσεις (ΜΠΣ Τμ. Πληροφ. Πανεπ. Αθ.) – 1998
- [28] Timothy Masters  
"Practical Neural Network Recipes in C++"  
Academic Press Inc. – 1993
- [29] Namir C. Shamma  
"C/C++ Mathematical Algorithms for Scientists & Engineers"  
McGraw-Hill Inc. – 1996
- [30] Russell Reed  
"Pruning Algorithms – A Survey"  
IEEE Transactions on Neural Networks, Vol.4, No.5, Sept. 1993
- [31] Χ. Γεωργίου, Γ. Κούτσιας  
"Μελέτη και Αξιολόγηση Εφαρμογών Feed-Forward ΤΝΔ με Χρήση Αλγορίθμων Back-Propagation με Momentum"  
Πανεπιστημιακή εργασία (ΜΠΣ Τμ. Πληροφ. Πανεπ. Αθ.) – 1999
- [32] Ε. Κοσσιονίδης, Γ. Λεγάτος, Γ. Παντελίδης, Σ. Στεφάνου  
"Εγκυκλοπαίδεια Μαθηματικών" – Τόμος Ε'  
Εκδ. Παγουλάτος – 1975
- [33] "K-fold cross-validation techniques"  
Δημοσιευμένα άρθρα στο Διαδίκτυο (1999-2000)  
[news://comp.ai.neural-nets](http://news://comp.ai.neural-nets)

<ftp://ftp.sas.com/pub/neural/FAQ3.html>

- [34] Χρ. Μεταξάκη – Κοσιονίδου  
“Επεξεργασία Εικόνας”  
Πανεπιστημιακές σημειώσεις (ΜΠΣ Τμ. Πληροφ. Πανεπ. Αθ.) – 1999
- [35] A. K. Jain  
“Fundamentals of Digital Image Processing”  
Prentice-Hall NJ – 1989
- [36] Steve Rimmer  
“Bit-Mapped Graphics”  
Windcrest & McGraw-Hill – 1990
- [37] Εμμ. Σαγκριώτης  
“Εισαγωγή στην Τεχνητή Όραση”  
Πανεπιστημιακές σημειώσεις (ΜΠΣ Τμ. Πληροφ. Πανεπ. Αθ.) – 1999
- [38] S. Theodoridis, K. Koutroumbas  
“Pattern Recognition” (3rd edition)  
Academic Press, San Diego, USA – 2006
- [39] “Mammographic Mass Shape Characterization using Neural Networks”  
H. Georgiou, D. Cavouras, N. Dimitropoulos, S. Theodoridis  
2nd European Symposium in Biomedical Engineering and Medical Physics (2nd ES-BME 2001), 6-8 Oct 2001, BME-13 @ Patras, Greece.
- [40] “Neoplasm Characterization in Mammography by Boundary Shape Analysis Using Neural Networks” (in Greek)  
H. Georgiou, D. Cavouras, N. Dimitropoulos, S. Theodoridis  
12th Hellenic Radiology Conference, 18-22 Oct 2001 @ Athens, Greece.

Copyright (c) 2012, Harris V. Georgiou

Το βιβλίο «Αλγόριθμοι Ανάλυσης Ιατρικής Εικόνας – Τόμος Α: Προγραμματισμός Εφαρμογών» αποτελεί το πρώτο μέρος ενός δίτομου έργου που αφορά σε όλα τα στάδια επεξεργασίας σε ένα σύστημα υποβοηθούμενης (*Computer Aided Diagnosis – CAD*) ή πλήρως αυτοματοποιημένης διάγνωσης (*Automated Computer Diagnosis – ACD*), εστιασμένο κυρίως στην ανάπτυξη αντίστοιχου λογισμικού εφαρμογών, καλύπτοντας παράλληλα όλες τις απαραίτητες θεωρητικές έννοιες και αλγορίθμους Ανάλυσης Ιατρικής Εικόνας (*Image Analysis & Medical Imaging*) και Αναγνώρισης Προτύπων (*Pattern Recognition*). Το υλικό του βιβλίου είναι πλήρως αυτόνομο και επικεντρώνεται στην ανάλυση υπερηχογραφικής εικόνας ανθρώπινου ήπατος με σκοπό τον αυτόματο χαρακτηρισμό δειγμάτων ιστού, χρησιμοποιώντας μεθοδολογίες που βασίζονται στο ευρύτερο πεδίο της Μηχανικής Μάθησης. Το υλικό που παρουσιάζεται έχει χρησιμοποιηθεί ως βάση διδασκαλίας σε προπτυχιακό και μεταπτυχιακό επίπεδο, τόσο σε ότι αφορά αλγορίθμους Μηχανικής Μάθησης και Ανάλυσης Εικόνας, όσο και προγραμματισμού (ANSI C/C++) αλγορίθμων Αναγνώρισης Προτύπων. Συνοδεύεται από πηγαίο κώδικα έκτασης πάνω από 12.000 γραμμές και πλήρη περιγραφή για όλα τα προγράμματα που παρουσιάζονται ως υλοποιήσεις συγκεκριμένων αλγορίθμων και μεθοδολογιών.

Ο Χαρίλαος Β. Γεωργίου είναι Πτυχιούχος Πληροφορικής του Πανεπιστημίου Ιωαννίνων, κάτοχος πτυχίου MSc και διδακτορικού (PhD) από το Εθνικό Καποδιστριακό Πανεπιστήμιο Αθηνών (ΕΚΠΑ) στους τομείς «Ψηφιακή Επεξεργασία Σήματος» και «Ανάλυση Ιατρικής Εικόνας & Μηχανική Μάθηση», αντίστοιχα. Στα ερευνητικά του ενδιαφέροντα περιλαμβάνονται μεταξύ άλλων: Συστήματα Βιοϊατρικής & Βιοπληροφορικής, Επεξεργασία Σήματος, Ανάλυση Εικόνας, Ανάλυση & Σχεδίαση Πληροφοριακών Συστημάτων, Μηχανική Μάθηση, Soft Computing, Τεχνητή Νοημοσύνη & Νευρωνικά Δίκτυα, Εξελικτικοί Αλγόριθμοι, Θεωρία Παιγνίων, Διαχείριση Ρίσκου, Ιατρικά Πληροφοριακά Συστήματα.

Από το 1998 μέχρι και σήμερα εργάζεται ως ερευνητής Πληροφορικής σε συνεργασία με Πανεπιστήμια και ερευνητικά ινστιτούτα της Ελλάδας και του εξωτερικού. Έχει δημοσιεύσει περισσότερες από 40 επιστημονικές εργασίες σε διεθνή περιοδικά και συνέδρια (*peer-reviewed*), κυρίως στο χώρο της Βιοϊατρικής, Ανάλυσης Ιατρικής Εικόνας, και Μηχανικής Μάθησης. Τα τελευταία δέκα χρόνια διδάσκει στον ιδιωτικό τομέα σε προγράμματα προπτυχιακού και μεταπτυχιακού επιπέδου, συμμετέχει σε ομάδες συνεργασίας για την ανάπτυξη των Τεχνολογιών Πληροφορικής & Τηλεπικοινωνιών (ΤΠΕ) στην Ελλάδα και σε χώρες του αναπτυσσόμενου κόσμου (ICT4D), και αρθρογραφεί σε περιοδικά επιστημονικού περιεχομένου.